

Pesquisa Operacional

Notas de aula do curso de Pesquisa Operacional do Dept. de Ciência da Computação da UFMG

Versão de 29 de abril de 2026

Bibliografia

Boa parte do material nestas notas de aula é baseada em capítulos e passagens das seguintes referências. Alguns exemplos foram copiados *ipsis literis*.

- (i) Bertrand Guenin, Jochen Könemann, and Levent Tunçel. *A gentle introduction to optimization*. Cambridge University Press, 2014.
- (ii) Marco Cesar Goldbarg, and Henrique Pacca L. Luna. *Otimização combinatória e programação linear: modelos e algoritmos*. Elsevier, 2005.
- (iii) Christos Papadimitriou, and Kenneth Steiglitz. *Combinatorial optimization: algorithms and complexity*. Courier Corporation, 1998.
- (iv) Václav Chvátal. *Linear programming*. W.H. Freeman and Company, 1983.
- (v) Michele Conforti, Gérard Cornuéjols, and Giacomo Zambelli. *Integer programming*. Springer, 2014.

Sumário

1	Programações lineares	3
1.1	Introdução ao curso	3
1.1.1	Otimização neste curso	3
1.2	Introdução à Programação linear	4
1.2.1	Exemplo	5
1.2.2	Exemplo prático	7
1.3	Programação linear - formalização	8
1.4	Modelagem	8
1.5	Possibilidades para uma PL	12
1.5.1	PLs inviáveis	12
1.5.2	PLs ilimitadas	13
1.5.3	Resultados possíveis de uma PL	13
1.6	Forma padronizada	14
1.7	Certificados	17
1.7.1	PLs inviáveis	18
1.7.2	PLs ilimitadas	19
1.7.3	PLs com soluções ótimas	19
1.7.4	Resumo	20
2	Simplex	22
2.1	Poliedros e convexidade	22
2.1.1	Convexidade	22
2.1.2	Pontos extremos	23
2.2	Soluções básicas	24
2.3	Simplex	29
2.4	PLs ilimitadas	32
2.4.1	Como encontrar um certificado de ilimitada	33
2.5	Formalização do Simplex	33
2.6	O Simplex via tableaus	35
2.6.1	Múltiplas soluções ótimas	37
2.6.2	Soluções degeneradas	38
2.7	Simplex 2-fases: o problema de achar soluções viáveis	39
2.8	Pseudo-código	42
2.9	Versão estendida com registro de operações (VERO™)	43

3	Dualidade	46
3.1	Dualidade	46
3.2	A PL dual	47
3.3	Teorema fraco da Dualidade	49
3.4	Interpretação do tableau estendido	51
3.5	Teorema Forte da Dualidade	53
3.6	PLs inviáveis ou ilimitadas	54
3.7	Folgas complementares	56
3.8	Certificados de otimalidade e inviabilidade	58
3.8.1	Certificado de otimalidade	58
3.8.2	Certificado de inviabilidade	58
3.9	Método Simplex Dual	60
3.10	Análise de sensibilidade	63
3.11	Teoria de jogos	68
3.11.1	Estratégias	69
3.11.2	Teorema Minimax	70
3.12	Interpretação econômica	73
4	Geometria e teorema de alternativas	75
4.1	Geometria de poliedros	75
4.2	Teorema de alternativas e dualidade	79
4.3	Geometria de otimização poliédrica	82
5	Programações inteiras	83
5.1	Programações inteiras	83
5.2	Modelagem	85
5.3	Escrevendo uma PI como uma PL	88
5.4	Planos de corte	90
5.5	Branch and bound	92
6	Formulando programações inteiras	99
6.1	Problema do caixeiro viajante	99
6.1.1	Formulação matemática	99
6.1.2	Formulação alternativa: MTZ (opcional)	105
6.2	Problema da mochila	108
6.3	Problema das “várias mochilas”, ou geração de colunas	109
6.4	Alguns truques de formulação	112
7	Otimização em grafos	115
7.1	Grafos	115
7.2	Fluxos	119
7.3	Matrizes totalmente unimodulares	120
7.3.1	Exemplo	123
7.4	O método de Ford e Fulkerson — um algoritmo primal-dual (leitura opcional) . . .	124
7.5	Emparelhamentos e coberturas	129
7.5.1	Cobertura por vértices em grafos quaisquer	133
7.5.2	Um algoritmo primal-dual para emparelhamento perfeito de menor custo . .	134

7.6	Caminho mínimo	136
7.7	Problema do transporte	139
7.8	Cobertura por conjuntos	141
7.8.1	Algoritmo primal-dual	143
7.8.2	Algoritmo guloso para o problema de cobertura de conjuntos sem pesos . . .	146
7.9	Empacotamento, partição e coberturas — uma revisão	148
7.10	Colorações	149
7.11	Localização de instalações (facility location)	151
7.11.1	Algoritmo primal-dual	152
7.12	Árvores geradoras	153

Capítulo 1

Programações lineares

1.1 Introdução ao curso

Apesar de o nome do curso ser Pesquisa Operacional, talvez seria mais descritivo se fosse chamado “Introdução à otimização”. Problemas de otimização são uma (grande) sub-área da Pesquisa Operacional. Matematicamente falando, um problema de otimização é um problema em que se busca achar o máximo ou o mínimo de uma função dentro de um determinado conjunto. Por exemplo:

- Quais são os valores máximo e mínimo da função $f(x) = x^2$ com $x \in \mathbb{R}$?
- E se o intervalo for limitado a $[1, 5]$? Qual seu mínimo e máximo neste intervalo?

Chamamos o primeiro caso de um problema de otimização **irrestrita**, isto é, não há condições restringindo o domínio. O segundo caso é conhecido como um problema de otimização **restrita** uma vez que restrições são impostas no conjunto possível de valores que x pode assumir. Buscamos a **solução ótima**, isto é, o ponto onde a função atinge o valor máximo ou mínimo dentre os valores possíveis do domínio.

A dificuldade de um problema de otimização pode estar na descrição da função, ou na compreensão do conjunto. Ou em ambos. Por exemplo:

- Qual o máximo da função $f(x, y) = x^2/y^y$ se x e y estão entre -1 e 1?
- Qual o máximo da função $f(x) = \sin(x)$ entre os números racionais?

Funções como as que descrevemos acima tipicamente necessitam do uso do cálculo para estudarmos seus pontos de máximo e mínimo. Neste curso, entretanto, nossas funções serão mais simples.

1.1.1 Otimização neste curso

Neste curso estamos interessados em duas sub-áreas da Pesquisa Operacional, chamadas **Programação Linear (PL)** e **Programação Inteira (PI)**. Ambas estas técnicas buscam reescrever matematicamente problemas do mundo real através de problemas de otimização restritos. Um termo mais amplo que engloba tanto PL quanto PI é a **Programação Matemática**, definido como a utilização de ferramentas matemáticas para a alocação ótima de recursos limitados quando planejamos (**programamos**) atividades.

Tanto em PL quanto PI, estamos interessados somente em otimizar **funções lineares**. Uma função f é linear se, para vetores $\mathbf{x}$ e $\mathbf{y}$ e um número a ,

$$f(\mathbf{x} + \mathbf{y}) = f(\mathbf{x}) + f(\mathbf{y}) \quad \text{e} \quad f(a \cdot \mathbf{x}) = a \cdot f(\mathbf{x})$$

Por exemplo,

$$f(x) = 2x \quad f(x_1, x_2) = 2x_1 + 3x_2 \quad f(x_1, x_2, x_3) = x_1 - x_2 + 5x_3$$

são funções lineares, ao passo que

$$f(x) = x + 5 \quad f(x_1, x_2) = x_1 x_2 \quad f(x_1, x_2, x_3) = x_1^2 + x_3$$

não são.

Exercício 1. Prove estes fatos.

Otimizar uma função linear (ou decidir que não é possível achar o seu ótimo) é a princípio uma tarefa simples. Por exemplo:

- Qual o máximo de $f(x) = 2x$?
- Qual o máximo da mesma função no intervalo $[-4, 10]$?

Problemas de otimização linear se tornam difíceis quando há mais variáveis. Neste caso, a dificuldade estará sempre na compreensão do conjunto onde a função está sendo definida, ou nas restrições que as variáveis da função devem satisfazer. Neste curso, essas restrições serão também sempre lineares, mas ainda assim veremos que os problemas podem ser bem difíceis.

1.2 Introdução à Programação linear

A primeira parte do curso trata apenas de Programação Linear (PL), o mais “simples” dos modelos de programação matemática. Há centenas de aplicações práticas de PL em uma vasta gama de áreas, incluindo problemas de logística na indústria, mercados financeiros, ciências sociais e naturais, e muitas outras. A teoria e suas aplicações começou por volta da Segunda Guerra Mundial, com Leonid Kantorovich utilizando-a para modelar a economia centralizada da União Soviética e George Dantzig utilizando-a para modelar problemas de logística decorrentes da guerra. Dantzig também desenvolveu o primeiro algoritmo efetivo para resolver problemas de PL - o chamado algoritmo **Simplex** - que ainda hoje é largamente utilizado em *solvers* comerciais e *open-source* de problemas de programação matemática. O enorme aumento de poder computacional nas últimas décadas permite hoje resolver eficientemente problemas de PL com centenas de milhares de variáveis.

Um problema de PL é descrito por três componentes importantes:

- **Variáveis de decisão**, que representam efetivamente a decisão que deve ser tomada no problema modelado,
- **Função objetivo**, que representa em um valor numérico o benefício ou custo associado às decisões que devem ser tomadas. É a função que deve ser maximizada ou minimizada.
- **Restrições**, que representam a limitação dos recursos do mundo real. As restrições impõem que a solução deve obedecer certas regras.

Em um problema de PL, a função objetivo e as restrições são sempre lineares e as variáveis de decisão são sempre variáveis reais (possivelmente dentro de um intervalo).

1.2.1 Exemplo


Ache o máximo da função $f(x_1, x_2) = x_1 + x_2$ supondo que x_1 e x_2 satisfaçam

$$x_1 \geq 0 \quad ; \quad x_2 \geq 0 \quad ; \quad 2x_1 + x_2 \leq 4 \quad ; \quad x_1 + 2x_2 \leq 3.$$

No caso, as variáveis de decisão são dadas por x_1 e x_2 e a função objetivo é maximizar $x_1 + x_2$. Abaixo, reescrevemos este PL utilizando a notação mais comum:

$$\begin{array}{ll} \max & x_1 + x_2 \\ \text{sujeito a} & 2x_1 + x_2 \leq 4 \\ & x_1 + 2x_2 \leq 3 \\ & x_1 \geq 0 \\ & x_2 \geq 0 \end{array}$$

Ao desenhar estas desigualdades no gráfico, a região delimitada é dada por:




Observe que qualquer ponto à direita da reta azul torna a desigualdade $2x_1 + x_2 \leq 4$ inválida. Por exemplo, considere o ponto $(2, 2)$ - neste caso temos que $6 \not\leq 4$ e diz-se que a desigualdade foi **violada**. Já para qualquer ponto à esquerda da reta azul o oposto ocorre. Por exemplo, ao substituírmos o ponto $(1, 1)$ na desigualdade obtemos $3 \leq 4$.

Desta forma, temos que:

- Apenas pontos à esquerda e abaixo da reta azul respeitam a desigualdade $2x_1 + x_2 \leq 4$,
- Apenas pontos à esquerda e abaixo da reta vermelha respeitam a desigualdade $x_1 + 2x_2 \leq 3$,
- Apenas pontos à direita do eixo x_2 respeitam a desigualdade $x_1 \geq 0$ e

- Apenas pontos acima do eixo x_1 respeitam a desigualdade $x_2 \geq 0$.

A união destes conjuntos é chamada de **região viável** ou **área viável** e pode ser vista no gráfico abaixo:



Todos os pontos da região viável são soluções válidas para o problema. A principal questão de um problema de PL é encontrar, dentre todos os pontos válidos, qual é aquele que maximiza ou minimiza a função objetivo desejada.

Exercício 2. Dentro da área viável acima, qual par de pontos (x_1, x_2) maximiza $x_1 + x_2$? E $3x_1 + x_2$? E $x_1 - x_2$? E minimizar?

Três comentários importantes:

- Se você prestou atenção, o máximo ou mínimo sempre acabou sendo um dos vértices. Isto nem sempre é o caso, por exemplo, se quiséssemos o máximo de $f(x_1, x_2) = 2x_1 + x_2$ ou o mínimo de $f(x_1, x_2) = x_1$. Mas sempre será o caso de que o máximo ocorrerá num ponto de fronteira entre o conjunto e o seu complemento.
- Nem sempre problemas deste tipo terão solução, mas isto sempre dependerá do conjunto em que estamos otimizando, nunca da função. Por exemplo, qual o máximo de $f(x_1, x_2) = x_1 + x_2$ no conjunto

$$x_1 \geq 0 \quad ; \quad x_2 \geq 0 \quad ; \quad x_1 - x_2 \leq 2 \quad ?$$

E em

$$x_1 \geq 0 \quad ; \quad x_2 \geq 0 \quad ; \quad x_1 + x_2 \leq -2 \quad ?$$

- Problemas deste tipo possuem grande aplicabilidade prática. Veremos logo mais um exemplo. Infelizmente, a grande parte dos problemas ocorre com muitas variáveis, ou seja, é impossível termos uma visualização gráfica fiel ao problema. Entretanto, procure manter sempre uma intuição geométrica: dentro de um conjunto limitado por retas, ou planos, ou hiperplanos, você estará procurando o canto onde um plano, ou hiperplano, atinge seu máximo ou mínimo.

1.2.2 Exemplo prático

Suponha uma empresa que produza 4 tipos de produto. A empresa possui duas máquinas diferentes e a produção de cada produto requer horas em ambas as máquinas, além de horas operacionais e horas em um processo de controle de qualidade. A tabela abaixo especifica, para cada produto, quantas horas são necessárias em cada máquina/atividade. A tabela inclui também o preço de venda (assuma demanda infinita):

Produto	Máquina 1	Máquina 2	Operacional	Qualidade	Preço de venda
1	11	4	8	7	300
2	7	6	5	8	260
3	6	5	5	7	220
4	5	4	6	4	180

Por mês, a máquina 1 pode funcionar no máximo 700 horas, e a 2 por no máximo 500 horas. A empresa pode comprar no máximo 600 horas de trabalho operacional ao custo de 8 reais a hora, e 650 horas de controle de qualidade ao custo de 6 reais a hora. Quantos itens de cada produto a empresa deve produzir de forma a maximizar seu lucro?

Vamos formular esse problema como uma PL.

- (i) **Variáveis de decisão:** Temos que decidir quantas unidades de cada produto serão produzidas. Para isso, vamos criar variáveis x_1, x_2, x_3, x_4 representando estes valores. Ou seja, x_1 é uma variável ainda desconhecida cujo valor é o número de unidades que devem ser produzidas do produto 1. Estas são as únicas incertezas a respeito deste problema, e todos os demais valores associados (por exemplo: quantas horas usar de uma determinada máquina?) serão determinados por $x_1, \dots, x_4$.

Entretanto, muitas vezes o uso de variáveis adicionais facilita a compreensão e expressão do problema. Neste caso, vamos introduzir variáveis y_1 e y_2 que representam as quantidades de horas de trabalho operacional e controle de qualidade utilizadas. Ao final, veremos também que teria sido possível modelar o problema sem usar essas variáveis.

- (ii) **Função objetivo:** A empresa busca maximizar o lucro. A função matemática que representa o lucro é dada por:

$$300x_1 + 260x_2 + 220x_3 + 180x_4 - 8y_1 - 6y_2.$$

- (iii) **Restrições:**

Podemos utilizar no máximo 700 horas da máquina 1:

$$11x_1 + 7x_2 + 6x_3 + 5x_4 \leq 700.$$

E no máximo 500 horas na máquina 2:

$$4x_1 + 6x_2 + 5x_3 + 4x_4 \leq 500.$$

Trabalho operacional:

$$8x_1 + 5x_2 + 5x_3 + 6x_4 \leq y_1$$

Controle de qualidade:

$$7x_1 + 8x_2 + 7x_3 + 4x_4 \leq y_2.$$

As limitações na quantidade de horas que podem ser contratadas:

$$y_1 \leq 600 \quad \text{e} \quad y_2 \leq 650.$$

Não faz sentido que as variáveis possam ter valores negativos, logo:

$$x_1, x_2, x_3, x_4, y_1, y_2 \geq 0.$$

Estas últimas restrições são geralmente chamadas de restrições de **não-negatividade**.

Exercício 3. Como ficaria este modelo caso optássemos por não utilizar as variáveis y_1 e y_2 ?

Exercício 4. Resolva esta PL.

1.3 Programação linear - formalização

Uma programação linear (PL) é definida como um problema de maximizar ou minimizar uma função linear (ou afim) sujeita a um número finito de restrições lineares. Considerando o exemplo:

$$\begin{aligned} \max \quad & 3x_1 + 2x_2 - x_3 + 5 \\ \text{sujeito a} \quad & x_1 + x_2 \leq 9 \\ & x_3 \leq 3 \\ & x_1, x_2, x_3 \geq 0, \end{aligned} \tag{1.1}$$

estamos **maximizando** a **função objetivo** $f(x_1, x_2, x_3) = 3x_1 + 2x_2 - x_3 + 5$ sujeita às **restrições** $x_1 + x_2 \leq 9$, $x_3 \leq 3$, $x_1 \geq 0$, $x_2 \geq 0$, $x_3 \geq 0$.

Importante: uma restrição linear é sempre uma inequação da forma

$$f(\mathbf{x}) \leq \beta, \quad f(\mathbf{x}) \geq \beta, \quad f(\mathbf{x}) = \beta,$$

onde $\mathbf{x}$ é um vetor de variáveis e β é um escalar. Note que

$$3x_1 + 5x_2 - x_3 + x_4 < 5$$

não é uma restrição linear, já que a desigualdade é estrita.

Uma **solução** para a formulação (1.1) é uma atribuição de valores às variáveis (x_1, x_2, x_3) . Uma solução é **viável** se possui a propriedade de que todas as restrições são satisfeitas. Uma solução é **ótima** se é viável e maximiza (ou minimiza se o problema for de minimização) a função objetivo.

1.4 Modelagem

Como dito anteriormente, a PL modela diversos problemas da vida real. Nesta seção, incluímos alguns exercícios e exemplos de aplicações.

Exemplo 1. Considere o seguinte problema de demanda, armazenamento e distribuição. Uma companhia local, Pompéu Insumos, de revenda de insumos agrícolas prevê que nos próximos meses, a demanda por seu principal insumo seja a seguinte:

mês	1	2	3	4
demanda em litros	5000	8000	9000	6000

No começo de cada mês, esta empresa pode comprar este insumo de um distribuidor regional pelos seguintes valores:

mês	1	2	3	4
custo por litro	0.75	0.72	0.92	0.90

A Pompéu Insumos possui um tanque de armazenamento de 4000 litros, que atualmente já contém 2000 litros. A empresa deseja saber quantos litros de insumo deve comprar no começo de cada mês para suprir a demanda e ao mesmo tempo minimizar seus custos. Note que se o insumo é comprado e revendido imediatamente, não é preciso armazená-lo no tanque. Somente o excedente para o mês seguinte é armazenado. Para simplificar, assumimos que o custo de armazenamento é zero (o que pode não ser verdade na prática).

- Variáveis de decisão: Cada mês, Pompéu Insumos precisa determinar (1) quantos litros comprar e (2) quantos armazenar do insumo. Estes valores são incertos e devem ser decididos pela empresa: são os candidatos ideais para as variáveis de decisão.

Introduzimos então 8 variáveis: $p_1, \dots, p_4$ referentes a quanto comprar, e $t_1, \dots, t_4$ referentes à capacidade ocupada do tanque. Note que já fomos informados que $t_1 = 2000$.

- Função objetivo: Como informado, a Pompéu Insumos deseja minimizar o custo de compra dos insumos. Então a função objetivo é

$$\min \quad 0.75p_1 + 0.72p_2 + 0.92p_3 + 0.90p_4.$$

- Restrições: No começo do primeiro mês, a quantidade de insumos comprada, acrescida da quantidade que já havia no tanque, deve ser igual ou exceder a demanda do primeiro mês, e este excedente corresponde exatamente ao que é armazenado para o segundo mês. Portanto

$$p_1 + t_1 = 5000 + t_2.$$

A restrição acima impõe a **consistência** dos valores envolvidos. Igualmente

$$p_2 + t_2 = 8000 + t_3, \quad p_3 + t_3 = 9000 + t_4, \quad p_4 + t_4 \geq 6000.$$

Exercício 5. Termine de formular esta PL, incluindo condições iniciais e demais restrições, e escreva no formato de (1.1). Qual você acredita ser a solução ótima para o problema? Como o problema seria alterado se o custo de armazenamento fosse 0.10 por litro de insumo por mês?

Exercício 6. Considere a seguinte tabela nutricional de alguns tipos de comida:

Comida	preço / porção	calorias / p.	gordura / p.	proteína / p.	carbs / p.
Cenoura	0.14	23	0.1	0.6	6
Batata	0.12	171	0.2	3.7	30
Pão integral	0.20	65	0.0	2.2	13
Queijo	0.75	112	9.3	7.0	0
Amendoim	0.15	188	16.0	7.7	2

Uma nutricionista deseja montar um cardápio que minimize os custos diários, ao mesmo tempo que as seguintes demandas nutricionais são satisfeitas:

- pelo menos 2000 calorias
- pelo menos 50g de gordura
- pelo menos 100g de proteína
- pelo menos 250g de carboidratos.

Modele este problema com uma PL (é possível fracionar porções).

Exercício 7. Um banco faz quatro tipos de empréstimos para seus clientes pessoais. Cada tipo de empréstimo rende os seguintes juros anuais para o banco:

- Primeira hipoteca a 14%
- Segunda hipoteca a 20%
- Reforma residencial a 20%
- Empréstimos pessoais a 10%

O banco pode emprestar no máximo 250 milhões, sendo também restrito pelas seguintes políticas:

- A primeira hipoteca deve ser pelo menos 55% de todas as hipotecas e pelo menos 25% de todos os empréstimos.
- A segunda hipoteca não deve exceder 25% de todos os empréstimos.
- Para evitar descontentamento do público, a taxa de juros média não deve exceder 15%.

Formule o problema de empréstimos bancários como uma PL visando maximizar o recebimento de juros e satisfazendo as limitações impostas.

Note que estas condições impostas potencialmente limitam o lucro que o banco pode ter, mas também limitam sua exposição a risco em uma área particular. É um princípio fundamental do gerenciamento de risco que o risco é reduzido ao dividir o dinheiro apropriadamente em diferentes áreas.

Exercício 8. Uma refinaria processa três tipos diferentes de petróleo. Cada tipo de petróleo possui uma planilha de custos diferente, expressando condições de transporte e preços na origem. A planilha de custos e a quantidade máxima disponível é dada abaixo:

Tipo de petróleo	Quantidade máxima disponível (barril/dia)	Custo por barril/dia
1	3500	19
2	2200	24
3	4200	20

Por outro lado, cada tipo de petróleo é mais ou menos apropriado para a produção de três tipos de gasolina diferentes: amarela, azul e superazul. As especificações de cada tipo de gasolina são dadas abaixo:

Tipo de gasolina	Especificação	preço de venda R\$/barril
Amarela	não mais que 70% de 1	22
Azul	não mais que 30% de 1 não menos que 10% de 2	28
Superazul	não mais que 30% de 1 não menos que 40% de 2 não mais que 50% de 3	35

Formule este problema como uma PL que calcule quanto de cada gasolina a empresa deve produzir, e quais tipos de petróleo deve utilizar em cada de forma a maximizar seus lucros. Suponha que não há perda volumétrica no processo da refinaria.

DICA: use 9 variáveis, cada variável correspondendo a quanto de cada tipo de petróleo será usado em cada tipo de gasolina.

Exercício 9. Você administra uma empreiteira, e projeta construir uma casa. As seguintes atividades devem ser feitas

- B - escavar e fazer a fundação.
- F - subir as paredes
- E - parte elétrica
- P - encanamento
- D - acabamento das paredes e pisos
- L - jardim.

Você possui equipes na sua empreiteira que realizam cada uma das atividades. O tempo em dias para concluir tudo é:

tarefa	B	F	E	P	D	L
tempo	3	2	3	4	1	2

Infelizmente as tarefas não podem ser realizadas todas simultaneamente. Se baseie na lista de restrições abaixo e formule o problema de construir a casa no menor tempo possível como uma PL.

- F só pode começar após B.
- L só pode começar após B.
- E só pode começar após F.
- P só pode começar após F.
- D só pode começar após E e P.

Exercício 10. Tente resolver o seguinte sistema de equações:

$$\begin{aligned}2x + y &= -1 \\x + y &= 1 \\x + 3y &= 4 \\-2x + 4y &= 3\end{aligned}$$

Tentou? Vamos então tentar encontrar os valores que mais se aproximam de ser uma solução do sistema. Formule o problema de achar um vetor (x, y) que mais se aproxime de resolver este sistema como uma PL. Ou seja, você deseja achar (x, y) tal que a soma

$$|2x + y + 1| + |x + y - 1| + |x + 3y - 4| + |-2x + 4y - 3|$$

seja mínima.

E se ao invés de minimizar a soma, você desejasse minimizar o maior dos valores absolutos. Ainda é possível modelar como uma PL?

Exercício 11. Em um restaurante, os funcionários trabalham 5 dias consecutivos e folgam 2. Como há dias de mais e menos movimento, a tabela abaixo indica quantos funcionários devem trabalhar em cada dia da semana:

Dia	Seg	Ter	Qua	Qui	Sex	Sab	Dom
Demanda	17	13	15	19	14	16	11

Qual o menor número de funcionários que o restaurante deve contratar de forma a suprir a demanda de trabalho? Modele este problema como uma PL (vamos permitir que funcionários sejam “fracionários” por enquanto). E se o pagamento de funcionários que trabalham domingo fosse 1.5 vezes o pagamento nos outros dias, como a empresa poderia minimizar o custo?

1.5 Possibilidades para uma PL

Vimos, no exemplo gráfico da Seção 1.2, o caso de uma PL que possui uma solução ótima clara. Nem toda PL, porém, possui uma solução ótima, como veremos nos exemplos a seguir.

1.5.1 PLs inviáveis

Pode ser que uma PL não possua solução viável. Neste caso, dizemos que a PL é **inviável**. Considere o problema:

$$\begin{aligned}\min \quad & 2x_1 + x_2 \\ \text{sujeito a} \quad & x_1 + x_2 \leq 4 \\ & x_2 \geq 5 \\ & x_1, x_2 \geq 0\end{aligned}$$

Como pode ser facilmente observado na Figura 1.5.1, não há nenhum ponto que satisfaça todas as 4 restrições. O problema é inviável.




Figura 1.5.1: Exemplo de PL inviável

1.5.2 PLs ilimitadas

Considere o problema:

$$\begin{aligned}
 \max \quad & x_1 + x_2 \\
 \text{sujeito a} \quad & x_1 + x_2 \geq 1 \\
 & -x_1 + x_2 \leq 2 \\
 & x_1 - 2x_2 \leq 2 \\
 & x_1, x_2 \geq 0
 \end{aligned}$$

O exemplo é ilustrado na Figura 1.5.2. No gráfico, foram desenhadas linhas de contorno para diferentes valores da função objetivo. Pelo diagrama, é evidente que existem soluções viáveis para a PL com valores muito altos.

Uma PL de maximização é **ilimitada** se existem soluções viáveis com valores arbitrariamente grandes na função objetivo. Uma PL de minimização é **ilimitada** se existem soluções viáveis com valores negativos arbitrariamente pequenos na função objetivo.

Note que, por mais que uma PL possa ser matematicamente ilimitada, na vida real, uma mensagem de um *solver* indicando que o problema é ilimitado muito provavelmente indica algum erro do usuário na formulação matemática do problema. Tipicamente trata-se da omissão de uma ou mais restrições.

1.5.3 Resultados possíveis de uma PL

Para qualquer PL, ocorre exatamente **um** dos resultados a seguir:

- O problema possui solução ótima,
- O problema é inviável,
- O problema é ilimitado.




Figura 1.5.2: Exemplo de PL ilimitada

A afirmação acima, verdadeira para PLs, pode ser falsa para problemas de otimização que não são lineares. Por exemplo, considere o seguinte problema de otimização não-linear:

$$\begin{aligned} \min \quad & x_2 \\ \text{sujeito a} \quad & x_1 \cdot x_2 \geq 1 \\ & x_1, x_2 \geq 0 \end{aligned}$$

A região viável é a área acima da hipérbole da Equação $x_1 \cdot x_2 = 1$, vista na Figura 1.5.3. Podemos observar que o problema é viável (exemplo: o ponto $\mathbf{x} = (1, 1)$ é uma solução viável) e não é ilimitado, uma vez que é um problema de minimização e não possui solução menor que zero. Porém, o problema não possui solução ótima, uma vez que não há solução viável de valor zero, e ainda assim há soluções viáveis onde o valor de x_2 pode chegar arbitrariamente próximo a zero.

1.6 Forma padronizada

Dado um vetor $\mathbf{c} \in \mathbb{R}^n$, uma matriz $m \times n$ $\mathbf{A}$ e um vetor $\mathbf{b} \in \mathbb{R}^m$, considere a seguinte PL

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{A}\mathbf{x} \leq \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Significa que estamos procurando o vetor $\mathbf{x} \in \mathbb{R}^n$ que maximiza o produto interno $\mathbf{c}^T \mathbf{x}$ sujeito às desigualdades obtidas a partir de cada linha da matriz $\mathbf{A}$, além de restrições de não-negatividade.




Figura 1.5.3: Exemplo de problema de otimização não-linear

Exemplo 2. Considere a PL

$$\begin{aligned} \max \quad & x_1 + x_2 \\ \text{sujeito a} \quad & x_1 + 2x_2 \leq 2 \\ & 2x_1 + x_2 \leq 2 \\ & x_1, x_2 \geq 0. \end{aligned}$$

Esta PL pode ser expressa na forma matricial descrita acima da seguinte maneira:

$$\begin{aligned} \max \quad & (1 \ 1) \cdot \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \leq \begin{pmatrix} 2 \\ 2 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Também poderíamos ter incorporado as restrições de não-negatividade na matriz, como abaixo, mas esta não será nossa preferência geralmente.

$$\begin{aligned} \max \quad & (1 \ 1) \cdot \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ -1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \leq \begin{pmatrix} 2 \\ 2 \\ 0 \\ 0 \end{pmatrix} \end{aligned}$$

Neste exemplo:

$$\mathbf{c} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \mathbf{A} = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ -1 & 0 \\ 0 & -1 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} 2 \\ 2 \\ 0 \\ 0 \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

Exercício 12. Resolva a PL acima.

Exercício 13. Considere o primeiro exemplo de PL, (1.1). Identifique naquele exemplo quais são os vetores $\mathbf{c}$, $\mathbf{b}$, $\mathbf{x}$ e a matriz $\mathbf{A}$.

Conforme você notou no exercício, nem sempre o conjunto de desigualdades obtidos da modelagem poderá ser imediatamente agrupado em um formato matricial, e então alguns ajustes podem precisar ser feitos.

Como forma de padronizar a interpretação de PLs definimos a **forma padrão de igualdades** (FPI) a seguir.

Definição 1. Uma PL está na forma padrão de igualdades se existem vetores $\mathbf{c}$, $\mathbf{b}$ e uma matriz $\mathbf{A}$ tal que a PL se expressa como

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{Ax} = \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Em outras palavras, uma PL está na FPI se

- é um problema de maximização.
- com exceção das restrições de não-negatividade, todas as outras são igualdades.
- toda variável possui uma restrição de não negatividade.

Qualquer PL pode ser expressa na FPI. Em geral, quando uma inequação é obtida na formulação, ela pode ser substituída por uma igualdade ao adicionarmos uma variável extra.

Exercício 14. Expresse a desigualdade $2x + 3y \leq 5$ utilizando apenas igualdades e/ou restrições de não-negatividade. Dica: adicione uma variável w .

Faça o mesmo para $8x - y + z \geq 10$.

Problemas de minimização também podem ser expressos como maximização.

Exercício 15. Expresse

$$\min x + y + z$$

como

$$\max \mathbf{c}^T \mathbf{x}.$$

Ou seja, diga quais são os vetores $\mathbf{c}$ e $\mathbf{x}$.

Ainda pode haver um fator dificultador de que, ao modelarmos o problema, uma das variáveis não possua uma restrição de não-negatividade. Neste caso, a variável em questão deve ser substituída por duas outras. Note o exemplo abaixo.

Exemplo 3.

$$\begin{aligned} \min \quad & x + y \\ \text{sujeito a} \quad & x - y \leq 2 \\ & x + y \geq -1 \\ & x \geq 0 \end{aligned}$$

Note que não podemos simplesmente adicionar $y \geq 0$, porque isto alteraria a solução da PL. No caso, a PL dada possui mínimo igual a -1 referente à solução $(x, y) = (0, -1)$, onde $y < 0$. Para termos restrições de não-negatividade para todas as variáveis, vamos substituir y por duas variáveis:

$$y = y^+ - y^-,$$

e agora exigimos $y^+, y^- \geq 0$. No caso, quando $y = -1$, temos $y^+ = 0$ e $y^- = 1$, ambos não-negativos. A PL se torna então:

$$\begin{aligned} \min \quad & x + y^+ - y^- \\ \text{sujeito a} \quad & x - (y^+ - y^-) \leq 2 \\ & x + (y^+ - y^-) \geq -1 \\ & x, y^+, y^- \geq 0 \end{aligned}$$

Há portanto três passos básicos a serem realizados para transformar uma PL para a FPI.

- (i) Trocar min por max, se necessário, adicionando um sinal negativo em $\mathbf{c}$ (lembrando de multiplicar o valor objetivo encontrado no final por -1).
- (ii) Trocar todas as inequações por igualdades adicionando variáveis extras (sempre não-negativas). Estas serão chamadas de **variáveis de folga**.
- (iii) Trocar cada variável livre por duas variáveis não-negativas.

Exemplo 4. A PL do exemplo 3 se torna portanto:

$$\begin{aligned} \max \quad & (-1 \quad -1 \quad 1 \quad 0 \quad 0) \cdot \begin{pmatrix} x \\ y^+ \\ y^- \\ z_1 \\ z_2 \end{pmatrix} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & -1 & 1 & 1 & 0 \\ 1 & 1 & -1 & 0 & -1 \end{pmatrix} \cdot \begin{pmatrix} x \\ y^+ \\ y^- \\ z_1 \\ z_2 \end{pmatrix} = \begin{pmatrix} 2 \\ -1 \end{pmatrix} \\ & x, y^+, y^-, z_1, z_2 \geq 0 \end{aligned}$$

Exercício 16. Expresse as PLs obtidas nos exercícios de modelagem na FPI.

1.7 Certificados

Como vimos, ou uma PL possui solução ótima, ou não possui solução viável, ou é ilimitada. De fato, o Teorema Fundamental de Programações Lineares estabelece que essas são as únicas possibilidades. Nesta seção, vamos mostrar, mas não demonstrar, que existem “certificados” que são suficientes para determinar em qual dos três casos a PL se encaixa.

1.7.1 PLs inviáveis

Exemplo 5. Suponha que o sistema abaixo foi retirado de uma PL em FPI e descreve todas as suas restrições

$$\begin{aligned} 4x_1 + 10x_2 - 6x_3 - 2x_4 &= 6 \\ -2x_1 + 2x_2 - 4x_3 + x_4 &= 5 \\ -7x_1 - 2x_2 + 4x_4 &= 3 \\ \mathbf{x} &\geq 0. \end{aligned}$$

Você pode tentar resolver este sistema, mas notará que não é possível. Como entretanto provar isto?

A verificação de que uma PL é inviável não depende da função objetivo, dependendo apenas do conjunto de restrições. Podemos provar que um sistema de equações com restrições de não-negatividade não possui solução ao encontrarmos uma equação tal que

- (i) esta equação seja consequência de operações elementares nas equações do sistema e
- (ii) todos os coeficientes sejam não-negativos, mas o lado direito seja negativo.

Veja, por exemplo, o que acontece se multiplicarmos a primeira equação por $y_1 = 1$, a segunda por $y_2 = -2$, a terceira por $y_3 = 1$ e somarmos, obteremos

$$x_1 + 4x_2 + 2x_3 = -1.$$

Naturalmente não há quaisquer valores de $x_1, x_2, x_3, x_4 \geq 0$ que satisfaçam isso.

O vetor $\mathbf{y} = (y_1, y_2, y_3)$ obtido no exemplo acima é chamado de **certificado de inviabilidade**. Em notação matricial, tínhamos

$$\mathbf{A} = \begin{pmatrix} 4 & 10 & -6 & -2 \\ -2 & 2 & -4 & 1 \\ -7 & -2 & 0 & 4 \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} 6 \\ 5 \\ 3 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 1 \\ -2 \\ 1 \end{pmatrix}$$

e concluímos que

$$\mathbf{Ax} = \mathbf{b} \text{ não é possível pois, ao multiplicar por } \mathbf{y}, \text{ temos } \mathbf{y}^T \mathbf{Ax} = \mathbf{y}^T \mathbf{b},$$

$$\mathbf{y}^T \mathbf{Ax} \geq 0 \quad \text{e} \quad \mathbf{y}^T \mathbf{b} < 0.$$

Exercício 17. Ache um certificado de inviabilidade para o sistema determinado por

$$\begin{pmatrix} 4 & -5 \\ 6 & -2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$x_1, x_2 \geq 0.$$

1.7.2 PLs ilimitadas

Exemplo 6. Considere a PL dada por

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{Ax} = \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0} \end{aligned}$$

onde

$$\mathbf{c} = (-2 \ 2 \ 3) \quad \mathbf{A} = \begin{pmatrix} 3 & -2 & -1 \\ 1 & 0 & -1 \end{pmatrix} \quad \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \quad \mathbf{b} = \begin{pmatrix} 30 \\ 10 \end{pmatrix}.$$

Esta PL possui solução viável? E solução ótima?

Note que $x_1 = 20, x_2 = 10, x_3 = 10$ é uma solução viável. Entretanto, qualquer solução da forma

$$S(t) = \begin{pmatrix} 20 \\ 10 \\ 10 \end{pmatrix} + t \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$$

com $t \geq 0$ também será viável. Note que

$$(-2 \ 2 \ 3) \cdot S(t) = 10 + 3t,$$

portanto se $t \rightarrow \infty$, então $\mathbf{c}^T \cdot S(t) \rightarrow \infty$. Não há portanto um máximo para esta PL, e ela é chamada de ilimitada.

O vetor $\mathbf{d} = (1 \ 1 \ 1)$ encontrado acima é um certificado de que a PL é ilimitada. Note que este vetor satisfaz as propriedades de que $\mathbf{Ad} = \mathbf{0}$, $\mathbf{d} \geq \mathbf{0}$ e $\mathbf{c}^T \mathbf{d} > 0$.

Exercício 18. Demonstre que a PL abaixo é viável, porém ilimitada.

$$\begin{aligned} \max \quad & (1 \ -1 \ -3) \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & -2 & 5 \\ 2 & -4 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 4 \\ -2 \\ 1 \end{pmatrix}, \\ & x_1, x_2, x_3 \geq 0 \end{aligned}$$

1.7.3 PLs com soluções ótimas

Exemplo 7. Agora considere a PL

$$\begin{aligned} \max \quad & (-1 \ 3 \ -5 \ 2 \ 1) \cdot \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & -2 & 1 & 0 & 2 \\ 0 & 1 & -1 & 1 & 3 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 2 \\ 4 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Suponha que alguém lhe informe que $\mathbf{z} = (2 \ 0 \ 0 \ 4 \ 0)$ é uma solução ótima desta PL. Como provar isto?

Certamente $\mathbf{z}$ é solução viável. Mas para mostrar que também é ótima, precisamos mostrar que para qualquer outra solução viável $\mathbf{x}$, temos

$$\mathbf{c}^T \cdot \mathbf{x} \leq \mathbf{c}^T \cdot \mathbf{z} = 6.$$

Isto é verdade?

De fato, se $\mathbf{x}$ é viável, então

$$\begin{pmatrix} -1 & 2 \end{pmatrix} \cdot \begin{pmatrix} 1 & -2 & 1 & 0 & 2 \\ 0 & 1 & -1 & 1 & 3 \end{pmatrix} \mathbf{x} = \begin{pmatrix} -1 & 2 \end{pmatrix} \cdot \begin{pmatrix} 2 \\ 4 \end{pmatrix}$$

Logo

$$\begin{pmatrix} -1 & 4 & -3 & 2 & 4 \end{pmatrix} \mathbf{x} = 6.$$

Com esta informação, conseguimos mostrar que:

$$\begin{aligned} \mathbf{c}^T \mathbf{z} - \mathbf{c}^T \mathbf{x} &\geq 0 \\ 6 - \mathbf{c}^T \mathbf{x} &\geq 0 \\ \begin{pmatrix} -1 & 4 & -3 & 2 & 4 \end{pmatrix} \mathbf{x} - \mathbf{c}^T \mathbf{x} &\geq 0 \\ \begin{pmatrix} 0 & 1 & 2 & 0 & 3 \end{pmatrix} \mathbf{x} &\geq 0 \end{aligned}$$

Explique por quê esta última desigualdade é verdadeira.

O vetor $\begin{pmatrix} -1 & 2 \end{pmatrix}$ (que por enquanto apareceu como mágica) é um certificado de otimalidade da PL. É um vetor que satisfaz as seguintes propriedades: há uma solução viável $\mathbf{z}$ (candidata a ótima), um vetor $\mathbf{y}$ tais que $\mathbf{y}^T \mathbf{A} \geq \mathbf{c}^T$, e $\mathbf{y}^T \mathbf{b} = \mathbf{c}^T \mathbf{z}$.

Exercício 19. Coloque a PL abaixo em FPI, ache uma candidata a solução ótima, e exiba um certificado de otimalidade.

$$\begin{aligned} \max \quad & \begin{pmatrix} 1 & 1 \end{pmatrix} \cdot \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 2 \\ 2 \end{pmatrix} \\ & \mathbf{x} \geq 0. \end{aligned}$$

1.7.4 Resumo

Dada uma PL em FPI

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{A} \mathbf{x} = \mathbf{b} \\ & \mathbf{x} \geq 0, \end{aligned}$$

esta PL é

- inviável se existir um vetor $\mathbf{y}$ tal que

$$\mathbf{y}^T \mathbf{A} \geq 0 \quad \text{e} \quad \mathbf{y}^T \mathbf{b} < 0.$$

- ilimitada se for viável e se existir um vetor $\mathbf{d}$ tal que

$$\mathbf{A}\mathbf{d} = 0, \quad \mathbf{d} \geq 0 \quad \text{e} \quad \mathbf{c}^T \mathbf{d} > 0.$$

- solúvel com solução ótima $\mathbf{z}$ se $\mathbf{z}$ for viável e existir um vetor $\mathbf{y}$ tal que

$$\mathbf{y}^T \mathbf{A} \geq \mathbf{c}^T \quad \text{e} \quad \mathbf{y}^T \mathbf{b} = \mathbf{c}^T \mathbf{z}.$$

Capítulo 2

Simplex

Neste capítulo, apresentaremos o método Simplex, amplamente difundido para a resolução de problemas de programação linear. Começamos com algumas definições matemáticas importantes.

2.1 Poliedros e convexidade

Em PLs, as restrições lineares definem regiões no espaço: equações correspondem a hiperplanos, enquanto desigualdades definem semi-espacos. A região viável, a interseção destes conjuntos, é um *poliedro*. Para visualizar o conceito de poliedro, considere um problema simples em duas variáveis, x_1 e x_2 , com as desigualdades:

$$x_1 + x_2 \leq 5, \quad x_1 \geq 0, \quad x_2 \geq 0.$$

Cada uma dessas desigualdades define um semi-espaço no plano $\mathbb{R}^2$. A interseção desses semi-espacos define uma região finita no plano, que chamamos de polígono (um poliedro em duas dimensões). Poliedros generalizam polígonos em problemas de maior dimensão, com múltiplas variáveis.

Observe que as restrições lineares de uma PL sempre são da forma

$$\mathbf{a}^T \mathbf{x} \leq \beta \quad \text{ou} \quad \mathbf{a}^T \mathbf{x} = \beta \quad \text{ou} \quad \mathbf{a}^T \mathbf{x} \geq \beta.$$

Note que $\mathbf{a}^T \mathbf{x} \geq \beta$ é equivalente a $(-\mathbf{a}^T) \mathbf{x} \leq -\beta$, e que $\mathbf{a}^T \mathbf{x} = \beta$ é equivalente a simultaneamente termos $\mathbf{a}^T \mathbf{x} \leq \beta$ e $(-\mathbf{a}^T) \mathbf{x} \leq -\beta$. Portanto as restrições de uma PL sempre podem ser expressas usando $\leq$, e ao juntarmos todas elas, teremos

$$\mathbf{A}\mathbf{x} \leq \mathbf{b} \tag{*}$$

para uma certa matriz $\mathbf{A}$ e um vetor $\mathbf{b}$. O conjunto de vetores $\mathbf{x}$ satisfazendo (*) é um poliedro.

2.1.1 Convexidade

Uma **combinação convexa** de dois ou mais pontos $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k \in \mathbb{R}^n$ é uma combinação linear desses pontos na qual os coeficientes são não-negativos e somam 1. Formalmente, temos:

$$\mathbf{x} = \lambda_1 \mathbf{x}_1 + \lambda_2 \mathbf{x}_2 + \dots + \lambda_k \mathbf{x}_k$$

onde $\lambda_i \geq 0$ para todo $i = 1, \dots, k$ e $\sum_{i=1}^k \lambda_i = 1$. Em outras palavras, uma combinação convexa é uma média ponderada dos pontos que garante que o ponto $\mathbf{x}$ resultante estará “entre” os pontos $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$.

Uma função $f : \mathbb{R} \rightarrow \mathbb{R}$ é *convexa* em um intervalo $[a, b]$ se, para quaisquer dois pontos $x_1, x_2 \in [a, b]$, a função avaliada em qualquer ponto entre eles está abaixo ou sobre o segmento de reta que liga $(x_1, f(x_1))$ e $(x_2, f(x_2))$. Formalmente, temos:

$$f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2), \quad \text{para todo } \lambda \in [0, 1]$$

Isto significa que a função não apresenta concavidade entre nenhum par de pontos localizados no intervalo $[a, b]$, e que a reta secante entre dois pontos no gráfico da função não fica abaixo do próprio gráfico. Um caso particular é o das *funções lineares*, onde a igualdade acima vale para todo λ e para $[a, b] = [-\infty, \infty]$.

Um conjunto $C \subseteq \mathbb{R}^n$ é *convexo* se, para quaisquer dois pontos $x_1, x_2 \in C$, o segmento de reta que os conecta também pertence ao conjunto. Ou seja, para qualquer $\lambda \in [0, 1]$:

$$\lambda x_1 + (1 - \lambda)x_2 \in C.$$

Em outras palavras, um conjunto convexo é aquele onde toda combinação convexa de dois pontos no conjunto ainda pertence ao conjunto.

Como vimos, um poliedro é definido como a interseção de um número finito de subespaços e semi-espaços. Cada subespaço ou semi-espaço é descrito por equações ou desigualdades lineares. Temos então o seguinte teorema:

Teorema 1. *Poliedros são conjuntos convexos.*

Demonstração. Sejam $\mathbf{x}_1$ e $\mathbf{x}_2$ pontos satisfazendo $\mathbf{A}\mathbf{x} \leq \mathbf{b}$. Temos que, para todo λ tal que $0 \leq \lambda \leq 1$,

$$\mathbf{A}(\lambda \mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2) \leq \lambda \mathbf{b} + (1 - \lambda)\mathbf{b} = \mathbf{b}.$$

□

2.1.2 Pontos extremos

Uma vez estabelecido que poliedros são conjuntos convexos, introduzimos o conceito de *ponto extremo* de um poliedro. Esse conceito será essencial para compreender como o método Simplex navega pelas soluções viáveis em busca de uma solução ótima.

Dizemos que um ponto $\mathbf{x}^* \in P$ (onde P é um poliedro) é um *ponto extremo* de P se ele não pode ser expresso como uma combinação convexa de dois outros pontos distintos de P . Ou seja, se não existem $\mathbf{x}_1, \mathbf{x}_2 \in P$, com $\mathbf{x}_1 \neq \mathbf{x}_2$, e $\lambda \in [0, 1]$, tal que:

$$\mathbf{x}^* = \lambda \mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2.$$

Um ponto extremo é aquele que não pode ser “dividido” em outros dois pontos do poliedro. Ele se localiza nas bordas do poliedro, e não no interior de um segmento de reta formado por dois outros pontos do conjunto.

Para ilustrar isso de maneira intuitiva, pense em um poliedro tridimensional como um cubo. Os pontos extremos do cubo são seus vértices. Nenhum vértice do cubo pode ser expresso como uma combinação convexa de outros dois vértices. No entanto, qualquer ponto ao longo de uma

aresta (ou face) do cubo pode ser escrito como uma combinação convexa dos dois vértices que formam essa aresta (ou face). Assim, somente os vértices são pontos extremos.

Uma propriedade importante de poliedros, que não demonstraremos aqui, é que qualquer ponto do poliedro pode ser escrito como uma combinação convexa de seus pontos extremos¹.

Considere agora uma PL com função objetivo $\mathbf{c}^T \mathbf{x}$, onde $\mathbf{c} \in \mathbb{R}^n$ é um vetor de coeficientes e $\mathbf{x} \in \mathbb{R}^n$ é o vetor de variáveis de decisão. Suponha que o conjunto de soluções viáveis seja representado por um poliedro $P \subseteq \mathbb{R}^n$, ou seja, o conjunto de pontos $\mathbf{x}$ que satisfazem as restrições lineares do problema. A função objetivo pode ser expressa como:

$$w = \mathbf{c}^T \mathbf{x}.$$

Teorema 2. *Se existe um ponto $\mathbf{x}^* \in P$ que maximiza w em P , então pelo menos um ponto extremo de P é um ponto de máximo.*

Demonstração. Suponha que $\mathbf{x}^*$ maximiza w sobre o poliedro P . Se $\mathbf{x}^*$ for um ponto extremo de P , já provamos o que queremos. Se $\mathbf{x}^*$ não for um ponto extremo, ele pode ser escrito como uma combinação convexa de pontos extremos (como mencionado anteriormente).

Seja $\mathbf{x}_1, \dots, \mathbf{x}_k \in P$ o conjunto finito de k de pontos extremos de P , e sejam $\lambda_1, \dots, \lambda_k \in [0, 1]$ coeficientes tais que $\sum_{i=1}^k \lambda_i = 1$. Temos então que:

$$\mathbf{x}^* = \lambda_1 \mathbf{x}_1 + \lambda_2 \mathbf{x}_2 + \dots + \lambda_k \mathbf{x}_k.$$

Como a função objetivo é linear, temos:

$$\mathbf{c}^T \mathbf{x}^* = \lambda_1 \mathbf{c}^T \mathbf{x}_1 + \lambda_2 \mathbf{c}^T \mathbf{x}_2 + \dots + \lambda_k \mathbf{c}^T \mathbf{x}_k.$$

Ou seja, o valor da função objetivo em $\mathbf{x}^*$ é uma média ponderada dos valores da função objetivo nos pontos extremos $\mathbf{x}_1, \dots, \mathbf{x}_k$. Como $\mathbf{x}^*$ é um ponto de máximo, o valor de $\mathbf{c}^T \mathbf{x}^*$ é maior ou igual ao valor em qualquer outro ponto do poliedro, o que implica que:

$$\mathbf{c}^T \mathbf{x}^* \geq \mathbf{c}^T \mathbf{x}_i \quad \text{para todo } i = 1, \dots, k.$$

Isso só é possível se pelo menos um dos pontos extremos $\mathbf{x}_i$ satisfizer $\mathbf{c}^T \mathbf{x}_i = \mathbf{c}^T \mathbf{x}^*$. Logo, um dos pontos extremos de P também maximiza a função objetivo.

2.2 Soluções básicas

Dada uma PL em FPI

$$\begin{aligned} & \max \quad \mathbf{c}^T \mathbf{x} \\ & \text{sujeito a} \quad \mathbf{A}\mathbf{x} = \mathbf{b} \\ & \quad \mathbf{x} \geq \mathbf{0}, \end{aligned}$$

podemos sempre assumir que a matriz $\mathbf{A}$ está em um formato especial. O objetivo dos exercícios dirigidos a seguir é descobrirmos que formato é este.

¹A demonstração é consequência direta do Teorema de Carathéodory.

Exercício 20. Considere a PL abaixo

$$\begin{aligned} & \max \quad (1 \ 2 \ 3) \mathbf{x} \\ & \text{sujeito a} \quad \begin{pmatrix} 4 & -1 & 0 \\ 1 & 0 & -1 \\ 1 & 1 & 1 \\ 2 & -2 & 0 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 7 \\ 2 \\ 3 \\ 2 \end{pmatrix} \\ & \quad \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

É possível escrever uma PL equivalente a esta em que a matriz $\mathbf{A}$ possua menos linhas?

Exercício 21. Considere a PL abaixo

$$\begin{aligned} & \max \quad (1 \ 2 \ 3 \ 1 \ 1) \mathbf{x} \\ & \text{sujeito a} \quad \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 2 & 1 & 0 & -1 & -2 \\ 3 & 1 & -1 & -3 & -5 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 5 \\ 0 \\ -5 \end{pmatrix} \\ & \quad \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Qual o posto dessa matriz? Ou seja, quantas colunas linearmente independentes existem? É possível reduzir o número de linhas?

Exercício 22. Considere a PL abaixo

$$\begin{aligned} & \max \quad (2 \ 3 \ 1) \mathbf{x} \\ & \text{sujeito a} \quad \begin{pmatrix} 1 & 2 & 1 \\ 2 & 4 & -1 \\ 3 & 6 & 0 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 2 \\ 1 \\ 3 \end{pmatrix} \\ & \quad \mathbf{x} \geq \mathbf{0} \end{aligned}$$

Elimine linhas, se for possível, e identifique colunas da matriz que formem uma matriz quadrada não-singular.

Exercício 23. Considere a seguinte PL em FPI

$$\begin{aligned} & \max \quad \mathbf{c}^T \mathbf{x} \\ & \text{sujeito a} \quad \mathbf{A} \mathbf{x} = \mathbf{b} \\ & \quad \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Suponha que $\mathbf{A}$ possua m linhas linearmente independentes, e n colunas. Explique por que podemos assumir, sem qualquer prejuízo à solução da PL, que se $n \geq m$, há precisamente m colunas linearmente independentes em $\mathbf{A}$.

Ao longo dos exercícios acima, vimos que sempre que uma PL estiver em FPI, podemos assumir que todas as m linhas são linearmente independentes (LI) e, conseqüentemente, que existe uma escolha de colunas para a matriz $\mathbf{A}$ que formam uma base para o espaço, ou seja, m colunas LI.

Suponha que identificamos uma base de m colunas para o espaço. Podemos então construir uma solução para a PL ao:

- Resolver o sistema linear com apenas as colunas da base,
- Fixar as demais variáveis (relativas a colunas fora da base) em zero.

Esta solução é chamada de **solução básica**, referente à base de colunas escolhida. Por exemplo, se as colunas da base são as primeiras m colunas de $\mathbf{A}$, então $\mathbf{A}$ estará na forma abaixo:

$$\mathbf{A} = \left(\begin{array}{c|c} \mathbf{A}_B & \mathbf{A}_N \end{array} \right) \quad (2.1)$$

onde $\mathbf{A}_B$ é uma matriz quadrada não singular, e $\mathbf{A}_N$ é uma matriz cujas colunas são combinações lineares das colunas de $\mathbf{A}_B$. Note que podem haver diferentes escolhas para as matrizes $\mathbf{A}_B$ e $\mathbf{A}_N$ (elas podem estar intercaladas), sempre dependendo da matriz original $\mathbf{A}$.

Quando temos $\mathbf{A}\mathbf{x}$, podemos separar as variáveis que compõem o vetor $\mathbf{x}$ entre aquelas indexadas pelas colunas linearmente independentes e as outras. As variáveis de $\mathbf{x}$ que correspondem às colunas de $\mathbf{A}_B$ são chamadas de variáveis básicas, ao passo que as demais são as variáveis não-básicas. Sempre podemos dividir o vetor $\mathbf{x}$ como

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}_B \\ \mathbf{x}_N \end{pmatrix},$$

onde o vetor $\mathbf{x}_B$ possui as variáveis básicas, e $\mathbf{x}_N$ as não-básicas. Note que, mesmo que as matrizes $\mathbf{A}_B$ e $\mathbf{A}_N$ estejam originalmente intercaladas em $\mathbf{A}$, vale a igualdade abaixo:

$$\mathbf{A}\mathbf{x} = \mathbf{A}_B \mathbf{x}_B + \mathbf{A}_N \mathbf{x}_N.$$

Exercício 24. No exercício 22, identifique as matrizes $\mathbf{A}_B$ e $\mathbf{A}_N$, e os vetores $\mathbf{x}_B$ e $\mathbf{x}_N$. Calcule $\mathbf{A}_B \mathbf{x}_B$ e $\mathbf{A}_N \mathbf{x}_N$ separadamente, e mostre que $\mathbf{A}\mathbf{x} = \mathbf{A}_B \mathbf{x}_B + \mathbf{A}_N \mathbf{x}_N$.

Dada uma matriz $\mathbf{A}$ no formato (2.1), e vetores $\mathbf{x}$ e $\mathbf{b}$ tais que

$$\mathbf{A}\mathbf{x} = \mathbf{b},$$

observe que $\mathbf{b}$ é uma combinação linear das colunas em $\mathbf{A}_B$. No caso, $\mathbf{b}$ é tratado como uma coluna extra de $\mathbf{A}$ que pode ser escrita como uma combinação linear das colunas básicas de $\mathbf{A}$. Então, existe um vetor $\mathbf{z}$ tal que $\mathbf{A}\mathbf{z} = \mathbf{b}$, e

$$\mathbf{A}_B \mathbf{z}_B = \mathbf{b} \quad \text{e} \quad \mathbf{z}_N = \mathbf{0}.$$

O vetor $\mathbf{z}$ como descrito acima é chamado de uma **solução básica da PL**.

Exercício 25. Novamente no exercício 22, ache uma solução básica.

Note que uma vez escolhida a matriz $\mathbf{A}_B$, existe uma **única solução básica** associada a $\mathbf{z}$, e ela é definida por $\mathbf{z}_B = \mathbf{A}_B^{-1}\mathbf{b}$, e $\mathbf{z}_N = \mathbf{0}$, com

$$\mathbf{z} = \begin{pmatrix} \mathbf{z}_B \\ \mathbf{z}_N \end{pmatrix}.$$

Considere então a solução básica $\mathbf{z}_B = \mathbf{A}_B^{-1}\mathbf{b}$, e $\mathbf{z}_N = \mathbf{0}$:

- Se $\mathbf{z}_B \geq 0$, então a solução é básica e **viável**.
- Se existe pelo menos um $z_i \in \mathbf{z}_B$ tal que $z_i < 0$, então a solução é básica e **inviável**, uma vez que as restrições de não-negatividade da PL em FPI não são atendidas.

Para os próximos dois teoremas, considere a PL em FPI:

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{Ax} = \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0}, \end{aligned}$$

onde $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{A}$ é uma matriz $m \times n$ com m restrições e n variáveis, $m > n$, e $\mathbf{b} \in \mathbb{R}^m$.

Teorema 3. *Qualquer solução básica viável de uma programação linear (PL) é um ponto extremo do poliedro definido pela área viável $\mathbf{Ax} = \mathbf{b}, \mathbf{x} \geq \mathbf{0}$.*

Demonstração. Suponha que $\mathbf{x}^*$ seja uma solução básica viável, mas não seja um ponto extremo. Então, para $0 < \lambda < 1$, podemos escrever:

$$\mathbf{x}^* = \lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2$$

onde $\mathbf{x}_1 \neq \mathbf{x}_2$ são soluções viáveis distintas.

Como $\mathbf{x}^*$ é uma solução básica, ela pode ser decomposta em um vetor $\mathbf{x}_B^*$ (tal que $\mathbf{A}_B \mathbf{x}_B^* = \mathbf{b}$) e outro $\mathbf{x}_N^* = \mathbf{0}$. As soluções $\mathbf{x}_1$ e $\mathbf{x}_2$ também podem ser decompostas em $(\mathbf{x}_{1B}, \mathbf{x}_{1N})$ e $(\mathbf{x}_{2B}, \mathbf{x}_{2N})$. Temos então que:

$$\mathbf{x}_N^* = \lambda \mathbf{x}_{1N} + (1 - \lambda) \mathbf{x}_{2N}$$

Como $\mathbf{x}_N^* = \mathbf{0}$, $\mathbf{x}_{1N} \geq \mathbf{0}$ e $\mathbf{x}_{2N} \geq \mathbf{0}$, a relação acima só pode ser verdade para $\mathbf{x}_{1N} = \mathbf{x}_{2N} = \mathbf{0}$.

Temos também que:

$$\mathbf{x}_B^* = \lambda \mathbf{x}_{1B} + (1 - \lambda) \mathbf{x}_{2B}$$

Porém, como as colunas da base são linearmente independentes, $\mathbf{x}_B^*$ é a solução única do sistema $\mathbf{A}_B \mathbf{x}_B = \mathbf{b}$. Como $\mathbf{x}_1$ e $\mathbf{x}_2$ são viáveis e $\mathbf{x}_{1N} = \mathbf{x}_{2N} = \mathbf{0}$, temos também que $\mathbf{A}_B \mathbf{x}_{1B} = \mathbf{b}$ e $\mathbf{A}_B \mathbf{x}_{2B} = \mathbf{b}$. Pela unicidade da solução deste sistema, a única forma disto ser verdade é se $\mathbf{x}_B^* = \mathbf{x}_{1B} = \mathbf{x}_{2B}$, contradizendo a hipótese de que $\mathbf{x}^*$ não é um ponto extremo.

Teorema 4. *Todo ponto extremo do poliedro $\mathbf{Ax} = \mathbf{b}, \mathbf{x} \geq \mathbf{0}$ é uma solução básica.*

Demonstração. Suponha que um ponto extremo $\mathbf{x}^*$ seja uma solução não básica viável (satisfazendo $\mathbf{Ax}^* = \mathbf{b}$ e $\mathbf{x}^* \geq \mathbf{0}$) com $k > m$ colunas não nulas. Seja $\mathbf{A}_K$ a submatriz retangular $k \times m$ contendo as colunas relativas às variáveis não nulas. Como o posto de $\mathbf{A}_K$ é m , é possível escrever uma combinação linear $\mathbf{d}$ de $\mathbf{A}_K$ tal que $\mathbf{A}_K \mathbf{d} = \mathbf{0}$ e $\mathbf{d}$ seja não-nulo.

Para um ε pequeno, $\mathbf{x}^* + \varepsilon \mathbf{d}$ e $\mathbf{x}^* - \varepsilon \mathbf{d}$ continuam satisfazendo $\mathbf{Ax} = \mathbf{b}$, pois $\mathbf{A}(\mathbf{x}^* \pm \varepsilon \mathbf{d}) = \mathbf{Ax}^* \pm \varepsilon \mathbf{Ad} = \mathbf{Ax}^* \pm \mathbf{0} = \mathbf{b}$. Como ε é pequeno, também temos que $\mathbf{x}^* \pm \varepsilon \mathbf{d} \geq \mathbf{0}$. Isto nos permite escrever $\mathbf{x}^*$ como a seguinte combinação convexa:

$$\mathbf{x}^* = \frac{1}{2} (\mathbf{x}^* + \varepsilon \mathbf{d}) + \frac{1}{2} (\mathbf{x}^* - \varepsilon \mathbf{d})$$

o que contradiz a premissa inicial de que $\mathbf{x}^*$ é um ponto extremo.

Para melhor visualizar esta demonstração, veja o exemplo numérico a seguir.

Exemplo 8. Considere o poliedro:

$$\begin{aligned}x_1 + x_2 &\leq 6 \\2x_1 + x_3 &\leq 8 \\ \mathbf{x} &\geq \mathbf{0}\end{aligned}$$

em FPI, fica:

$$\begin{pmatrix} 1 & 1 & 1 & 0 \\ 2 & 1 & 0 & 1 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 6 \\ 8 \end{pmatrix} \\ \mathbf{x} \geq \mathbf{0}.$$

Possuímos uma base trivial em $(x_3 \ x_4)$, mas considere a solução não básica $\mathbf{x}^{*T} = (0 \ 1 \ 5 \ 7)$, que claramente satisfaz a área viável definida pelo poliedro. As variáveis não nulas são $(x_2 \ x_3 \ x_4)$. Então, seja:

$$\mathbf{A}_K = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}$$

Através do vetor $\mathbf{d}^T = (-1 \ 1 \ 1)$, temos que $\mathbf{A}_K \mathbf{d} = \mathbf{0}$. Seja $\varepsilon = 0.1$. Observe que:

$$\begin{aligned}\mathbf{x}_K^* + \varepsilon \mathbf{d} &= \begin{pmatrix} 1 \\ 5 \\ 7 \end{pmatrix} + 0.1 \begin{pmatrix} -1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0.9 \\ 5.1 \\ 7.1 \end{pmatrix} \\ \mathbf{x}_K^* - \varepsilon \mathbf{d} &= \begin{pmatrix} 1 \\ 5 \\ 7 \end{pmatrix} - 0.1 \begin{pmatrix} -1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1.1 \\ 4.9 \\ 6.9 \end{pmatrix}\end{aligned}$$

Note que ambos os pontos satisfazem $\mathbf{A}_K \mathbf{x} = \mathbf{b}$, e que:

$$\begin{pmatrix} 1 \\ 5 \\ 7 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} 0.9 \\ 5.1 \\ 7.1 \end{pmatrix} + \frac{1}{2} \begin{pmatrix} 1.1 \\ 4.9 \\ 6.9 \end{pmatrix}$$

Como pode ser escrito como combinação convexa de outros dois pontos distintos, sabemos que o ponto $(0 \ 1 \ 5 \ 7)$ não é extremo.

A conclusão que podemos tirar das últimas duas seções é que **se** uma PL possuir solução ótima, então pelo menos uma solução básica será ótima. Assim, podemos concentrar nossa busca pelo ótimo **apenas** nas soluções básicas viáveis. É exatamente isso que o método Simplex faz, como veremos na próxima seção.

2.3 Simplex

Considere a seguinte PL de exemplo:

$$\begin{aligned} \max \quad & 3x_1 + 2x_2 \\ \text{sujeito a} \quad & 2x_1 + x_2 \leq 8 \\ & x_1 + 2x_2 \leq 8 \\ & x_1 + x_2 \leq 5 \\ & \mathbf{x} \geq \mathbf{0} \end{aligned}$$

Definição 2. Uma PL em FPI tal que a base canônica do espaço de colunas aparece inteiramente como colunas da matriz $\mathbf{A}$, e tal que as entradas correspondentes a estas colunas no vetor $\mathbf{c}$ são todas iguais a 0, é uma PL em *forma canônica*.

Ou seja, será tal que $\mathbf{A}_B = \mathbf{I}$ (as colunas podem estar trocadas), e $\mathbf{c}_B = \mathbf{0}$.

Quando uma PL está em forma canônica e há uma solução básica *viável*, sempre é possível (tentar) melhorar a solução! Portanto o problema de achar a solução ótima de uma PL se reduz ao problema de colocar uma PL em forma canônica para uma solução básica viável. Confira como no exemplo abaixo.

Exemplo 9. Começamos colocando a PL em FPI. No caso, basta adicionar uma variável de folga por restrição:

$$\begin{aligned} \max \quad & w = (3 \ 2 \ 0 \ 0 \ 0) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 2 & 1 & 1 & 0 & 0 \\ 1 & 2 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 1 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 8 \\ 8 \\ 5 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

- (i) Esta PL já está em forma canônica. Note que as colunas 3, 4 e 5 formam uma base, e que nesta base, $\mathbf{A}_B = \mathbf{I}$, e as entradas correspondentes de $\mathbf{c}$ são 0.
- (ii) Acharmos a solução básica - no caso, $\mathbf{x} = (0 \ 0 \ 8 \ 8 \ 5)^T$, cujo valor associado na função objetivo é $w = 0$. Ela é viável uma vez que todo o vetor $\mathbf{x} \geq \mathbf{0}$, e portanto prosseguimos.
- (iii) Identificamos no vetor $\mathbf{c}$ uma entrada positiva. Uma entrada positiva i em $\mathbf{c}$ em um problema de maximização implica que se x_i correspondente fosse maior, o valor da função objetivo também seria maior. Escolhemos então esta entrada em $\mathbf{c}$, que corresponde a uma coluna. No caso, escolhemos arbitrariamente a primeira (poderia ter sido a segunda).
- (iv) O próximo passo é alterar a solução aumentando o valor da variável x_1 , deixando x_2 fixo e reduzindo os valores das variáveis básicas x_3, x_4, x_5 .

Quanto maior o valor de x_1 , maior será o aumento do valor da função objetivo. Porém, x_1 não pode aumentar indefinidamente pois temos que garantir que as variáveis básicas continuem com valores viáveis, isto é, continuem sendo não-negativas. Devemos então descobrir qual é o máximo valor possível de x_1 de forma que estas condições sejam satisfeitas.

Para cada restrição, encontramos o maior valor que x_1 pode obter de forma que a variável básica correspondente (aquela que possui coeficiente 1 na restrição i na PL em forma canônica) seja no mínimo zero:

- Restrição 1: Ignorando os coeficientes das variáveis não básicas fixas, temos que $2x_1 + x_3 = 8$. O maior valor possível de $x_1 = 4$, senão x_3 teria que ser negativo. Este valor é obtido ao dividir o valor de b_1 pelo coeficiente A_{11} , $8/2$.
- Restrição 2: Temos que $x_1 + x_4 = 8$, o maior valor possível de $x_1 = 8$.
- Restrição 3: Temos que $x_1 + x_5 = 5$, o maior valor possível de $x_1 = 5$.

O máximo que podemos aumentar em x_1 é o mínimo dos três valores acima, 4. Com este incremento, obtemos a nova solução

$$\mathbf{x} = (4 \ 0 \ 0 \ 4 \ 1),$$

cujo valor associado na função objetivo é $\mathbf{c}^T \mathbf{x} = 12$ (maior que a anterior).

Em resumo: para encontrar o maior incremento possível da variável x_1 , que entrará na base, devemos calcular o mínimo b_i/A_{i1} para toda restrição i . Após recalculer os valores das variáveis básicas, temos que $x_3 = 0$. Neste caso ela deixa de ser básica, sendo substituída por x_1 . Assim, $\mathbf{x}_B^T = (x_1 \ x_4 \ x_5)$ e $\mathbf{x}_N^T = (x_2 \ x_3)$.

Observação importante: pode ser que para uma restrição i o coeficiente A_{ij} da nova variável x_j a entrar na base seja negativo, neste caso $b_i/A_{ij} < 0$. Isto significa que a restrição i não limitaria o valor máximo que x_j pode obter. Portanto, o maior incremento possível de x_j deve ser o mínimo b_i/A_{ij} para toda restrição i tal que $A_{ij} > 0$.

- (v) O próximo passo é garantir que esta nova solução se torne uma solução básica viável para uma PL em forma canônica equivalente à original. Logo devemos alterar a PL de modo que
- (a) as colunas 1, 4 e 5 correspondam a uma matriz identidade.
 - (b) a função objetivo seja 0 nas entradas 1, 4 e 5.

Para (a), fazemos eliminação Gaussiana. Teremos

$$\begin{aligned} \max \quad & (3 \ 2 \ 0 \ 0 \ 0) \mathbf{x} = w \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 1/2 & 1/2 & 0 & 0 \\ 0 & 3/2 & -1/2 & 1 & 0 \\ 0 & 1/2 & -1/2 & 0 & 1 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 4 \\ 4 \\ 1 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Para (b), subtraímos a função objetivo por 3 vezes a primeira equação. Como isto altera o valor da função objetivo, compensamos adicionando $3 \times 4 = 12$. Portanto o problema de otimização não se altera, e teremos

$$\begin{aligned} \max \quad & (0 \ 1/2 \ -3/2 \ 0 \ 0) \mathbf{x} = w - 12 \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 1/2 & 1/2 & 0 & 0 \\ 0 & 3/2 & -1/2 & 1 & 0 \\ 0 & 1/2 & -1/2 & 0 & 1 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 4 \\ 4 \\ 1 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Note que a função objetivo não é mais linear, mas a adição de uma constante não afeta em qualquer maneira o problema de otimização. De fato, a solução básica

$$\mathbf{x} = (4 \ 0 \ 0 \ 4 \ 1)$$

satisfaz as equações da PL e possui valor objetivo igual a $w = 12$.

(vi) Repetimos os itens (iii) e (iv). Agora só faz sentido aumentar x_2 pois é a única cujo valor na função objetivo é positivo, ou seja, a única que poderia contribuir para melhorar a solução final. Calculando os valores dos coeficientes b_i/A_{i2} :

- Restrição 1: $b_1/A_{12} = \frac{4}{1/2} = 8$.
- Restrição 2: $b_2/A_{22} = \frac{4}{3/2} = 8/3$.
- Restrição 3: $b_3/A_{32} = \frac{1}{1/2} = 2$.

O mínimo dentre os valores é 2, correspondente à restrição 3. Assim, a nova solução será

$$\mathbf{x} \begin{pmatrix} 3 & 2 & 0 & 1 & 0 \end{pmatrix},$$

cujo novo valor na função objetivo atualizada é $w = 13$. A variável x_5 deixa de ser básica, assim, $\mathbf{x}_B^T = (x_1 \ x_2 \ x_4)$ e $\mathbf{x}_N^T = (x_3 \ x_5)$.

(vii) Repetimos o item (v) - faça o passo a passo como exercício!

$$\begin{aligned} \max \quad & (0 \ 0 \ -1 \ 0 \ -1) \mathbf{x} = w - 13 \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 0 & 1 & 0 & -1 \\ 0 & 1 & -1 & 0 & 2 \\ 0 & 0 & 1 & 1 & -3 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 3 \\ 2 \\ 1 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Note que a solução básica

$$\mathbf{x} = \begin{pmatrix} 3 & 2 & 0 & 1 & 0 \end{pmatrix}$$

satisfaz as equações da PL e possui valor objetivo igual a $w = 13$.

(viii) Repetimos (ou tentamos repetir) os itens (iii) e (iv). Note entretanto que não existe variável que faça sentido aumentar em $\mathbf{x}$ tendo em vista o atual formato do vetor $\mathbf{c}$.

(ix) A PL está resolvida. Este foi o método Simplex.

Exercício 26. Refaça este exemplo, mas na primeira vez que chegar ao passo (iii), comece aumentando x_2 , deixando x_1 fixo. Daí pra frente, faça como achar melhor. Note que no final, o valor de ótimo precisa ser o mesmo.

Algumas observações:

- Este método sempre resolverá uma PL. Nós entretanto não demonstraremos isto formalmente agora.
- Geometricamente, cada iteração dos pontos (ii)-(iv) correspondem a: achar uma solução na região viável, caminhar até uma face aumentando o valor da função objetivo, depois achar o melhor caminho para caminhar pela face até a próxima face.
- Na próxima seção, veremos uma maneira esquemática de repetirmos esses passos.

Exercício 27. Considere o sistema de equações abaixo

$$\begin{pmatrix} 1 & 1 & 0 & 2 & 1 & 1 & 1 \\ 0 & 2 & 2 & 0 & 0 & -2 & 1 \\ 1 & 2 & 1 & 5 & 4 & 3 & 3 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 2 \\ 2 \\ 6 \end{pmatrix}$$

e os vetores

(a) $(1 \ 1 \ 0 \ 0 \ 0 \ 0 \ 0)$

(b) $(2 \ -1 \ 2 \ 0 \ 1 \ 0 \ 0)$

(c) $(1 \ 0 \ 1 \ 0 \ 1 \ 0 \ 0)$

(d) $(0 \ 0 \ 1 \ 1 \ 0 \ 0 \ 0)$

(e) $(0 \ 1/2 \ 0 \ 0 \ 1/2 \ 0 \ 1)$

Para cada um deles, decida se é uma solução básica ou não, e se for, se é viável ($\geq \mathbf{0}$) ou não.

Exercício 28. Considere a PL em FPI abaixo.

$$\begin{aligned} \max \quad & (1 \ -2 \ 0 \ 1 \ 3) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & -1 & 2 & -1 & 0 \\ 2 & 0 & 1 & -1 & 1 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 1 \\ -1 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Construa PL equivalente em forma canônica para as bases formadas pelas colunas $\{1, 4\}$ e pelas colunas $\{3, 5\}$. A solução básica correspondente é viável?

Decida se esta PL é viável ou inviável. Se for viável, construa uma PL equivalente em forma canônica cuja solução básica associada seja viável. Se for inviável, apresente um certificado.

2.4 PLs ilimitadas

Vamos ver agora como é possível, através do método Simplex, identificar que uma PL é ilimitada. Considere o exemplo abaixo:

$$\begin{aligned} \max \quad & (5 \ 3 \ 0 \ 0 \ 1) \cdot \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} -2 & 4 & 1 & 0 & 1 \\ -3 & 7 & 0 & 1 & 1 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 1 \\ 3 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Esta PL está na forma canônica para as colunas 3 e 4. Vamos aplicar o método Simplex do Exemplo (9) para resolvê-la.

Escolhemos a coluna com c_i mais positivo. No caso, a 1a coluna com $c_1 = 5$. Note porém que os dois coeficientes são negativos. Isso significa que x_1 pode crescer infinitamente, pois para todo valor positivo de x_1 é possível aumentar também os valores de x_3 e x_4 para que a PL continue positiva. Isto implica que sempre que todos os coeficientes da coluna correspondente de uma variável candidata forem não-positivos (ou sejam negativos ou zero), a PL é ilimitada.

2.4.1 Como encontrar um certificado de ilimitada

O certificado de ilimitada é, no caso, um vetor $\mathbf{d} = (d_1, d_2, d_3, d_4, d_5)$ que satisfaz três condições: $\mathbf{A}\mathbf{d} = 0$, $\mathbf{d} \geq \mathbf{0}$ e $\mathbf{c}^T \mathbf{d} > 0$. A partir da PL em forma canônica, podemos facilmente encontra-lo. Note que para que $\mathbf{A}\mathbf{d} = 0$, temos que:

$$\begin{aligned} -2d_1 + 4d_2 + d_3 + d_5 &= 0 \\ -3d_1 + 7d_2 + d_4 + d_5 &= 0 \end{aligned}$$

Vamos começar colocando $d_1 = 1$, isto é, na coluna que entraria como variável básica, colocamos o valor 1. As variáveis básicas originais são x_3 e x_4 . Vamos fixar $d_2 = d_5 = 0$ e colocar valores em d_3 e d_4 que garantem as igualdades acima: no caso, $d_3 = 2$ e $d_4 = 3$. Temos que $\mathbf{d} = (1 \ 0 \ 2 \ 3 \ 0)$. Note que este vetor satisfaz as três condições: $\mathbf{A}\mathbf{d} = 0$, $\mathbf{d} \geq \mathbf{0}$ e $\mathbf{c}^T \mathbf{d} = 5 > 0$, sendo um certificado de ilimitada. Como a PL está na forma canônica, apenas $\mathbf{c}^T \mathbf{d} = c_1$ neste caso pois os demais $c_j = 0$ para todas as outras variáveis básicas cujo valor $d_j > 0$.

Encontrar o certificado nestas condições é fácil: estando a PL em forma canônica, e encontrando um c_i positivo cuja coluna $\mathbf{A}_i$ correspondente é toda não-positiva, então para encontrar o certificado $\mathbf{d}$ basta colocar $d_i = 1$, $d_j = 0$ para toda variável j não básica e $d_k = -a_{li}$ para toda variável básica k com valor 1 na restrição l correspondente.

Observação: Note que se toda a coluna correspondente a x_1 fosse 0, com $c_1 > 0$, $\mathbf{d} = (1 \ 0 \ 0 \ 0 \ 0)$ seria um certificado válido.

2.5 Formalização do Simplex

Nesta seção, formalizamos a execução do algoritmo Simplex através de notação matricial. Considere o problema em FPI:

$$\begin{aligned} \max \quad & w = \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{A}\mathbf{x} = \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Se $\mathbf{A}$ possui mais colunas que linhas, o problema possui infinitas soluções (desde que seja viável). Se $\mathbf{A}$ possui mais linhas que colunas, muito provavelmente não possui solução. Vamos assumir, a partir daqui, que $\mathbf{A}$ possui m linhas e n colunas, com $m \leq n$.

Vamos então nos concentrar nas soluções básicas, que, como já sabemos, nos levará à solução ótima caso ela exista. Cada submatriz quadrada $m \times m$ de $\mathbf{A}$ nos fornece, potencialmente, uma solução básica. Sabemos que há $\binom{n}{m}$ possíveis submatrizes quadradas. Seja B o conjunto de colunas escolhido.

Vamos então separar os componentes da PL em uma parte básica B , e uma parte não básica N .

$$\begin{aligned} \mathbf{A} &= (\mathbf{A}_B \mid \mathbf{A}_N) \\ \mathbf{x} &= \begin{pmatrix} \mathbf{x}_B \\ \mathbf{x}_N \end{pmatrix} \\ \mathbf{c}^T &= (\mathbf{c}_B^T \mid \mathbf{c}_N^T) \end{aligned}$$

Vamos assumir que $\mathbf{A}_B$ é não-singular. Podemos reescrever a PL como:

$$\begin{aligned} \max \quad & w = (\mathbf{c}_B^T \mid \mathbf{c}_N^T) \begin{pmatrix} \mathbf{x}_B \\ \mathbf{x}_N \end{pmatrix} \\ \text{sujeito a} \quad & (\mathbf{A}_B \mid \mathbf{A}_N) \begin{pmatrix} \mathbf{x}_B \\ \mathbf{x}_N \end{pmatrix} = \begin{pmatrix} \mathbf{b}_B \\ \mathbf{b}_N \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Ou simplesmente:

$$\begin{aligned} \max \quad & w = \mathbf{c}_B^T \mathbf{x}_B + \mathbf{c}_N^T \mathbf{x}_N \\ \text{sujeito a} \quad & \mathbf{A}_B \mathbf{x}_B + \mathbf{A}_N \mathbf{x}_N = \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0}, \end{aligned}$$

Ao fazer $\mathbf{x}_N = \mathbf{0}$, obtemos uma solução básica ao resolver $\mathbf{A}_B \mathbf{x}_B = \mathbf{b}$. Como $\mathbf{A}_B$ é não-singular, podemos multiplicar a inversa dos dois lados para obter:

$$\mathbf{x}_B = \mathbf{A}_B^{-1} \mathbf{b}$$

Vamos assumir que $\mathbf{x}_B \geq \mathbf{0}$, ou seja, a solução básica é **viável** em relação à PL original.

O próximo passo é descobrir se a solução é ótima. Note que:

$$\begin{aligned} \mathbf{A}_B \mathbf{x}_B + \mathbf{A}_N \mathbf{x}_N &= \mathbf{b} \\ \mathbf{A}_B^{-1} \mathbf{A}_B \mathbf{x}_B + \mathbf{A}_B^{-1} \mathbf{A}_N \mathbf{x}_N &= \mathbf{A}_B^{-1} \mathbf{b} \\ \mathbf{x}_B + \mathbf{A}_B^{-1} \mathbf{A}_N \mathbf{x}_N &= \mathbf{A}_B^{-1} \mathbf{b} \\ \mathbf{x}_B &= \mathbf{A}_B^{-1} \mathbf{b} - \mathbf{A}_B^{-1} \mathbf{A}_N \mathbf{x}_N \end{aligned}$$

A manipulação algébrica acima por enquanto não trouxe nada de novo, já que $\mathbf{x}_N = \mathbf{0}$! Mas vamos ver como as coisas ficam quando substituímos a expressão acima na função objetivo:

$$\begin{aligned} w &= \mathbf{c}_B^T \mathbf{x}_B + \mathbf{c}_N^T \mathbf{x}_N \\ w &= \mathbf{c}_B^T (\mathbf{A}_B^{-1} \mathbf{b} - \mathbf{A}_B^{-1} \mathbf{A}_N \mathbf{x}_N) + \mathbf{c}_N^T \mathbf{x}_N \\ w &= \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{b} - \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A}_N \mathbf{x}_N + \mathbf{c}_N^T \mathbf{x}_N \\ w &= \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{b} + (\mathbf{c}_N - \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A}_N) \mathbf{x}_N \end{aligned}$$

Note que $w = \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{b}$ é o valor da função objetivo.

Vamos agora nos concentrar na expressão $(\mathbf{c}_N - \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A}_N) \mathbf{x}_N$. Considere uma variável não-básica $j \in N$, para a qual temos $(c_j - \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A}_j) x_j$ - nesta expressão, c_j é o coeficiente de j na função objetivo e $\mathbf{A}_j$ é a j -ésima coluna de $\mathbf{A}$. A expressão:

$$z_j = c_j - \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A}_j$$

é chamada de **custo reduzido** de j . Se seu valor é positivo, então poderíamos aumentar o valor de x_j , que atualmente é zero, aumentando consequentemente o valor da função objetivo w . Se os custos reduzidos de todas variáveis não-básicas j são negativos, então não há nada que podemos fazer para melhorar a função objetivo, e encontramos a solução ótima.

Vamos assumir então que o custo reduzido de j é positivo, ou seja, podemos melhorar a solução ao colocá-la na base. A questão é: o quanto podemos colocar em x_j ? Sejam $x_i, i \in B$, as variáveis

básicas, todas ≥ 0 . Ao aumentar x_j , vamos reduzir proporcionalmente todas x_i . Lembre-se que nenhum x_i pode virar negativo, assim temos um limite natural para o quanto x_j pode aumentar. Conforme acima, temos que:

$$\mathbf{x}_B = \mathbf{A}_B^{-1}\mathbf{b} - \mathbf{A}_B^{-1}\mathbf{A}_N\mathbf{x}_N$$

Especificamente para as variáveis i básica e j não-básica, temos que:

$$x_i = \mathbf{A}_B^{-1}b_i - \mathbf{A}_B^{-1}\mathbf{A}_jx_j$$

Como nenhum dos x_i pode ficar negativo, o máximo que podemos aumentar x_j é:

$$x_j = \min_{i \in B} \frac{\mathbf{A}_B^{-1}b_i}{\mathbf{A}_B^{-1}\mathbf{A}_j}$$

Seja B uma base ótima. Ao final, temos que:

w	$= \mathbf{c}_B^T \mathbf{x}_B$	é o valor ótimo da função objetivo
$\mathbf{x}_B$	$= \mathbf{A}_B^{-1}\mathbf{b}$	são os valores ótimos das variáveis básicas
$\mathbf{x}_N$	$= 0$	são os valores das variáveis não-básicas
$\mathbf{z}_N$	$= \mathbf{c}_N - \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A}_N$	são os custos reduzidos, nenhum positivo, das variáveis não-básicas

Mais pra frente, depois que estivermos resolvendo o Simplex em tableaus, voltaremos a esta notação.

2.6 O Simplex via tableaus

Nesta seção mostraremos como aplicar o Simplex de modo mais enxuto.

Considere a PL

$$\begin{aligned} \max \quad & w = (2 \ 3 \ 0 \ 0 \ 0) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 1 & 1 & 0 & 0 \\ 2 & 1 & 0 & 1 & 0 \\ -1 & 1 & 0 & 0 & 1 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 6 \\ 10 \\ 4 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

onde a variável w representa o valor objetivo. Note que esta PL já se encontra em forma canônica para a base viável formada pelas colunas 3, 4 e 5. Vamos reescrever as equações e a função objetivo como um sistema:

$$\begin{pmatrix} 1 & -2 & -3 & 0 & 0 & 0 \\ 0 & 1 & 1 & 1 & 0 & 0 \\ 0 & 2 & 1 & 0 & 1 & 0 \\ 0 & -1 & 1 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} w \\ x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{pmatrix} = \begin{pmatrix} 0 \\ 6 \\ 10 \\ 4 \end{pmatrix}.$$

Note que a primeira linha da matriz corresponde a $w - 2x_1 - 3x_2 = 0$, ou $w = 2x_1 + 3x_2$, que é o valor objetivo. Escrevemos agora a matriz aumentada deste sistema, distinguindo a linha da

variável w , que só está nos ajudando a escrever a função objetivo como uma igualdade envolvendo as outras variáveis:

$$\mathbf{T}_1 = \left(\begin{array}{c|cccccc|c} 1 & -2 & -3 & 0 & 0 & 0 & 0 \\ \hline 0 & 1 & 1 & 1 & 0 & 0 & 6 \\ 0 & 2 & 1 & 0 & 1 & 0 & 10 \\ 0 & -1 & 1 & 0 & 0 & 1 & 4 \end{array} \right)$$

No Simplex, escolhemos uma entrada de $\mathbf{c}$ que seja positiva. Como a matriz $\mathbf{T}_1$ possui $-\mathbf{c}^T$ na primeira linha, faremos agora:

- (1) Escolhemos uma coluna cuja primeira entrada seja negativa. Digamos a 2a coluna.
- (2) Escolhemos agora uma linha da 2a à 4a tal que a razão entre os elementos da última coluna e da 2a coluna seja o menor possível. No caso, 3a linha.
- (3) Transformamos a 2a coluna usando eliminação Gaussiana, de modo que apenas o elemento na 3a linha e 2a coluna seja igual a 1, e o resto seja 0. Isso se chama “pivotar” o elemento (3,2).

$$\mathbf{T}_2 = \left(\begin{array}{c|cccccc|c} 1 & 0 & -2 & 0 & 1 & 0 & 10 \\ \hline 0 & 0 & 1/2 & 1 & -1/2 & 0 & 1 \\ 0 & \boxed{1} & 1/2 & 0 & 1/2 & 0 & 5 \\ 0 & 0 & 3/2 & 0 & 1/2 & 1 & 9 \end{array} \right)$$

Repetimos agora na 3a coluna, pivoteando o elemento (2,3).

$$\mathbf{T}_2 = \left(\begin{array}{c|cccccc|c} 1 & 0 & 0 & 4 & -1 & 0 & 14 \\ \hline 0 & 0 & \boxed{1} & 2 & -1 & 0 & 2 \\ 0 & 1 & 0 & -1 & 1 & 0 & 4 \\ 0 & 0 & 0 & -3 & 2 & 1 & 6 \end{array} \right)$$

Repetimos agora na 5a coluna, pivoteando o elemento (4,5).

$$\mathbf{T}_3 = \left(\begin{array}{c|cccccc|c} 1 & 0 & 0 & 5/2 & 0 & 1/2 & 17 \\ \hline 0 & 0 & 1 & 1/2 & 0 & 1/2 & 5 \\ 0 & 1 & 0 & 1/2 & 0 & -1/2 & 1 \\ 0 & 0 & 0 & -3/2 & \boxed{1} & 1/2 & 3 \end{array} \right)$$

Não há mais elementos negativos na 1a linha, e de fato, a função objetivo agora é

$$w = 17 - \frac{5}{2}x_3 - \frac{1}{2}x_5,$$

cujo valor máximo, igual a 17, ocorre com $x_3 = x_5 = 0$, e corresponde à solução básica viável

$$\mathbf{x} = (1 \ 5 \ 0 \ 3 \ 0)^T,$$

que é facilmente observada em $\mathbf{T}_3$ (basta pensar que cada uma dessas variáveis é um peso multiplicando a coluna correspondente.)

Exercício 29. Considere a PL em FPI com

$$\mathbf{A} = \begin{pmatrix} 1 & 2 & -2 & 0 \\ 0 & 1 & 3 & 1 \end{pmatrix} \quad \mathbf{b} = \begin{pmatrix} 2 \\ 5 \end{pmatrix} \quad \mathbf{c} = \begin{pmatrix} 0 \\ 3 \\ 1 \\ 0 \end{pmatrix}.$$

- (a) Aplique o método Simplex a esta PL iniciando com a base de colunas 1 e 4.
- (b) Ache um certificado de que a PL é ótima ou ilimitada (se for ótima, no olho mesmo, por enquanto).

Exercício 30. Considere a PL em FPI dada por

$$\mathbf{A} = \begin{pmatrix} -2 & 1 & 1 & 1 & 0 & 0 \\ 1 & -1 & 0 & 0 & 1 & 0 \\ 2 & -3 & -1 & 0 & 0 & 1 \end{pmatrix} \quad \mathbf{b} = \begin{pmatrix} 1 \\ 2 \\ 6 \end{pmatrix} \quad \mathbf{c} = \begin{pmatrix} 2 \\ 1 \\ -1 \\ 0 \\ 0 \\ 0 \end{pmatrix}.$$

Resolva a PL usando o Simplex.

2.6.1 Múltiplas soluções ótimas

Considere a PL abaixo:

$$\begin{aligned} \max \quad & x_1 + \frac{1}{2}x_2 \\ \text{sujeito a} \quad & 2x_1 + x_2 \leq 4 \\ & x_1 + 2x_2 \leq 3 \\ & x_1, x_2 \geq 0 \end{aligned}$$

Primeiro escrevemos esta PL em FPI:

$$\begin{aligned} \max \quad & x_1 + \frac{1}{2}x_2 \\ \text{sujeito a} \quad & 2x_1 + x_2 + x_3 = 4 \\ & x_1 + 2x_2 + x_4 = 3 \\ & x_1, x_2, x_3, x_4 \geq 0 \end{aligned}$$

Agora, vamos resolve-la via Simplex. Iniciamos com a base $\mathbf{x}_B = x_3, x_4$:

$$\left(\begin{array}{c|ccc|c} 1 & -1 & -1/2 & 0 & 0 & 0 \\ \hline 0 & 2 & 1 & 1 & 0 & 4 \\ 0 & 1 & 2 & 0 & 1 & 3 \end{array} \right)$$

A solução viável básica no caso é $\mathbf{x} = (0 \ 0 \ 4 \ 3)$ com valor 0 na função objetivo. Escolhemos x_1 para entrar na base, com x_3 saindo. O próximo tableau é dado por:

$$\left(\begin{array}{c|ccc|c} 1 & 0 & 0 & 1/2 & 0 & 2 \\ \hline 0 & 1 & 1/2 & 1/2 & 0 & 2 \\ 0 & 0 & 3/2 & -1/2 & 1 & 1 \end{array} \right)$$

A solução ótima é dada por $\mathbf{x} = (2 \ 0 \ 0 \ 1)$. Como não há elemento negativo na função objetivo, encontramos a solução ótima. Porém, note que $c_2 = 0$, isto é se aumentarmos o valor de x_2 e

reduzirmos apropriadamente os valores de x_1 e x_4 , não alteraremos o valor da função objetivo. Como exemplo, vamos entrar com x_2 na base (no caso, x_4 sai):

$$\left(\begin{array}{c|cccc|c} 1 & 0 & 0 & 1/2 & 0 & 2 \\ \hline 0 & 1 & 0 & 2/3 & -1/3 & 5/3 \\ 0 & 0 & 1 & -1/3 & 2/3 & 2/3 \end{array} \right)$$

A solução $\mathbf{x} = (5/3 \ 2/3 \ 0 \ 0)$ também é ótima. Note que no novo tableau, $c_4 = 0$, o que indica que podemos voltar com x_4 à base no lugar de x_2 e obter a mesma solução anterior.

Em resumo: caso encontremos a solução ótima e no tableau final o coeficiente de uma variável não-básica seja zero, a entrada desta variável na base não pioraria o valor da função objetivo. Porém, pode ser que esta variável não possa entrar na base (não há elemento válido a ser pivotado). Caso possa, a PL possui múltiplas soluções ótimas: não apenas as duas soluções básicas, mas também todos os pontos no segmento que une estas duas soluções.

Exercício 31. Como o problema acima no formato original possui apenas duas variáveis, verifique graficamente a razão de existirem múltiplas soluções.

2.6.2 Soluções degeneradas

Considere agora a seguinte PL:

$$\begin{aligned} \max \quad & 2x_1 + x_2 \\ \text{sujeito a} \quad & 3x_1 + x_2 \leq 6 \\ & x_1 - x_2 \leq 2 \\ & x_2 \leq 3 \\ & x_1, x_2 \geq 0 \end{aligned}$$

Vamos também resolvê-la usando o Simplex. O primeiro tableau com ela já em FPI é dado por:

$$\left(\begin{array}{c|cccccc|c} 1 & -2 & -1 & 0 & 0 & 0 & 0 \\ \hline 0 & 3 & 1 & 1 & 0 & 0 & 6 \\ 0 & 1 & -1 & 0 & 1 & 0 & 2 \\ 0 & 0 & 1 & 0 & 0 & 1 & 3 \end{array} \right) \begin{array}{ll} \text{Base:} & x_3 = 6, x_4 = 2, x_5 = 3 \\ \text{Fora da base:} & x_1 = x_2 = 0 \end{array}$$

Escolhemos x_1 para entrar na base. Há um empate nas variáveis candidatas a sair da base ($x_3 \rightarrow 6/3 = 2$ e $x_4 \rightarrow 2/1 = 2$). Escolhemos arbitrariamente a segunda restrição (terceira linha do tableau). O segundo tableau é dado por:

$$\left(\begin{array}{c|cccccc|c} 1 & 0 & -3 & 0 & 2 & 0 & 4 \\ \hline 0 & 0 & 4 & 1 & -3 & 0 & 0 \\ 0 & 1 & -1 & 0 & 1 & 0 & 2 \\ 0 & 0 & 1 & 0 & 0 & 1 & 3 \end{array} \right) \begin{array}{ll} \text{Base:} & x_1 = 2, x_3 = 0, x_5 = 3 \\ \text{Fora da base:} & x_2 = x_4 = 0 \end{array}$$

Observe que esta solução básica possui uma variável básica igual a zero (x_3). Quando isto ocorre, dizemos que a solução básica é **degenerada**. Isto deve ser motivo de preocupação? Vamos

continuar com o Simplex. A variável x_2 deve entrar na base, e a razão mínima é dada pela primeira restrição (segunda linha da tabela): $0/4 = 0$. Assim x_3 sai da base:

$$\left(\begin{array}{c|cccc|c} 1 & 0 & 0 & 3/4 & -1/4 & 0 & 4 \\ \hline 0 & 0 & 1 & 1/4 & -3/4 & 0 & 0 \\ 0 & 1 & 0 & 1/4 & 1/4 & 0 & 2 \\ 0 & 0 & 0 & -1/4 & 3/4 & 1 & 3 \end{array} \right) \begin{array}{l} \text{Base:} \quad x_1 = 2, x_2 = 0, x_5 = 3 \\ \text{Fora da base:} \quad x_3 = x_4 = 0 \end{array}$$

Obtivemos quase que exatamente a mesma solução, com o mesmo valor e com apenas uma troca em uma variável básica. Ainda há elemento negativo na função objetivo, então continuamos o processo. A variável x_4 entra na base, enquanto que a variável x_5 sai:

$$\left(\begin{array}{c|cccc|c} 1 & 0 & 0 & 2/3 & 0 & 1/3 & 5 \\ \hline 0 & 0 & 1 & 0 & 0 & 1 & 3 \\ 0 & 1 & 0 & 1/3 & 0 & -1/3 & 1 \\ 0 & 0 & 0 & -1/3 & 1 & 4/3 & 4 \end{array} \right) \begin{array}{l} \text{Base:} \quad x_1 = 1, x_2 = 3, x_4 = 4 \\ \text{Fora da base:} \quad x_3 = x_5 = 0 \end{array}$$

A solução acima é ótima. Então, neste caso, a degeneração não impediu que o Simplex encontrasse o ótimo, ela apenas atrasou um pouco até que isto acontecesse. Porém, é possível criar exemplos em que a degeneração leva à **ciclagem**, isto é, uma sequência de pivôs que repete periodicamente os mesmos tableaus e que continua indefinidamente, entrando em *loop infinito*. Esta situação pode ser evitada pela seguinte regra:

Regra de Bland:

- Se para algum $r \in B$, $b_r = 0$, escolha a variável de menor índice dentre aquelas que podem entrar na base (com custo negativo). Na hora de escolher a variável que vai sair da base, em caso de empate escolha também a de menor índice.

Neste link (em inglês), é possível ver um exemplo de uma situação em que a regra de Bland evita a ciclagem.

Esta regra, apesar de garantir a não ocorrência da ciclagem, pode ser por vezes ineficiente. Na prática, por mais que a degeneração seja relativamente comum, em *solvers* comerciais e *open-source* nenhum esforço é dedicado a evitar a ciclagem, pois:

- Apesar da degeneração ser frequente, a ciclagem é extremamente rara.
- A precisão da aritmética computacional acaba cuidando da ciclagem por si só: erros de arredondamento se acumulam e eventualmente o método sai da ciclagem.

Exercício 32. De novo, como o problema acima possui apenas duas variáveis, interprete graficamente a degeneração.

2.7 Simplex 2-fases: o problema de achar soluções viáveis

Exemplo 10. Considere a PL

$$\begin{array}{ll} \max & (1 \ 2 \ -1 \ 3) \mathbf{x} \\ \text{sujeito a} & \begin{pmatrix} 1 & 5 & 2 & 1 \\ -2 & -9 & 0 & 3 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 7 \\ -13 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{array}$$

Queremos apenas decidir por ora se esta PL é viável ou inviável. O primeiro passo é tornar $\mathbf{b} \geq 0$, já que desejamos eventualmente encontrar uma base de colunas na forma da matriz identidade, e que a solução correspondente a esta base seja viável. Fazemos então

$$\begin{aligned} \max \quad & (1 \ 2 \ -1 \ 3) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 5 & 2 & 1 \\ 2 & 9 & 0 & -3 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 7 \\ 13 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Agora, poderíamos testar todas as possíveis $\binom{4}{2}$ escolhas de duas colunas, até acharmos (ou não) uma que corresponda a uma base viável. Mas vamos mostrar abaixo um método mais eficiente! Este método usará uma nova PL para encontrar este par de colunas.

Construímos uma nova PL, chamada de *auxiliar*, em FPI, e que satisfaz a seguintes propriedades:

- (a) Possui uma solução viável óbvia.
- (b) É limitada, e nenhuma solução ótima pode ter valor objetivo maior que 0.
- (c) Uma solução ótima da nova PL de valor objetivo igual a 0 é uma solução viável da PL original, e se o ótimo for menor que 0, a PL original é inviável.

Considere a PL aplicada a vetores $\mathbf{x}$ agora com 6 variáveis, ou seja, criamos duas variáveis novas:

$$\begin{aligned} \max \quad & (0 \ 0 \ 0 \ 0 \ -1 \ -1) \mathbf{x} \\ \text{sujeito a} \quad & \left(\begin{array}{cccc|cc} 1 & 5 & 2 & 1 & 1 & 0 \\ 2 & 9 & 0 & -3 & 0 & 1 \end{array} \right) \mathbf{x} = \begin{pmatrix} 7 \\ 13 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Pare por um momento para entender como esta PL foi obtida da original. Claramente

- (a) $\mathbf{x} = (0 \ 0 \ 0 \ 0 \ 7 \ 13)$ é solução viável para esta PL (note que aqui foi extremamente importante que $\mathbf{b} \geq 0$). Esta solução é básica, mas usa apenas as variáveis novas, e portanto sempre terá valor objetivo negativo (veja como o novo vetor $\mathbf{c}$ foi construído).
- (b) Esta PL é limitada e nenhuma solução desta PL pode ter valor objetivo maior que 0, já que $\mathbf{x} \geq \mathbf{0}$ e o novo $\mathbf{c}$ é ≤ 0 .
- (c) Usando o Simplex (faça como exercício), descobriremos que

$$\mathbf{x} = (2 \ 1 \ 0 \ 0 \ 0 \ 0)$$

é uma **solução ótima para a PL auxiliar**, e, portanto, como $x_5 = x_6 = 0$, esta solução leva à **solução viável da PL original**.

$$\mathbf{x} = (2 \ 1 \ 0 \ 0)^T$$

Exemplo 11. Considere agora a PL

$$\begin{aligned} \max \quad & (6 \ 1 \ -1) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 5 & 1 & 1 \\ -1 & 1 & 2 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 1 \\ 5 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Novamente, fazemos

$$\begin{aligned} \max \quad & (0 \ 0 \ 0 \ -1 \ -1) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 5 & 1 & 1 & 1 & 0 \\ -1 & 1 & 2 & 0 & 1 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 1 \\ 5 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Esta PL é viável e limitada, e seu valor ótimo pode ser no máximo 0. Resolvemos esta PL:

$$\left(\begin{array}{c|ccccc|c} 1 & 0 & 0 & 0 & 1 & 1 & 0 \\ \hline 0 & 5 & 1 & 1 & 1 & 0 & 1 \\ 0 & -1 & 1 & 2 & 0 & 1 & 5 \end{array} \right) \text{ Base: } x_4, x_5$$

Forma canônica:

$$\left(\begin{array}{c|cccc|c} 1 & -4 & -2 & -3 & 0 & 0 & -6 \\ \hline 0 & 5 & 1 & 1 & 1 & 0 & 1 \\ 0 & -1 & 1 & 2 & 0 & 1 & 5 \end{array} \right) \text{ Base: } x_4, x_5$$

Primeira iteração do tableau:

$$\left(\begin{array}{c|cccc|c} 1 & 0 & -1.2 & -2.2 & 0.8 & 0 & -5.2 \\ \hline 0 & 1 & 0.2 & 0.2 & 0.2 & 0 & 0.2 \\ 0 & 0 & 1.2 & 2.2 & 0.2 & 1 & 5.2 \end{array} \right) \text{ Base: } x_1, x_5$$

Segunda iteração do tableau:

$$\left(\begin{array}{c|cccc|c} 1 & 11 & 1 & 0 & 3 & 0 & -3 \\ \hline 0 & 5 & 1 & 1 & 1 & 0 & 1 \\ 0 & -11 & -1 & 0 & -2 & 1 & 3 \end{array} \right) \text{ Base: } x_3, x_5$$

Ao final, obtemos o ótimo

$$\mathbf{x} = (0 \ 0 \ 1 \ 0 \ 3)^T,$$

cujo valor objetivo é -3 . Podemos então concluir que a PL original deste exemplo é inviável, uma vez que qualquer solução viável para a PL original corresponderia a uma solução para a PL auxiliar com valor objetivo 0. Como seu ótimo foi -3 , esta solução não existe. Além disso, a base final de uma PL inviável sempre possuirá pelo menos uma das variáveis artificiais introduzidas na PL auxiliar.

Ademais, um certificado de otimalidade desta PL para uma solução ótima $\mathbf{x}$ é um vetor $\mathbf{y}$ tal que

(a) $\mathbf{c}^T - \mathbf{y}^T \mathbf{A} \leq 0$.

(b) $\mathbf{y}^T \mathbf{b} = \mathbf{c}^T \mathbf{x} = -3$, logo < 0 .

Escolhendo $\mathbf{y} = (2 \ -1)$ teremos um certificado de otimalidade para a PL auxiliar, que é ao mesmo tempo um certificado de inviabilidade para a PL original.

Resumindo: dada uma PL

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{Ax} = \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0}, \end{aligned}$$

onde $\mathbf{A}$ é $m \times n$ e $\mathbf{b} \geq \mathbf{0}$, então construímos a PL auxiliar

$$\begin{aligned} \max \quad & (0 \ \cdots \ 0 \mid -1 \ \cdots \ -1) \mathbf{x} \\ \text{sujeito a} \quad & (\mathbf{A} \mid \mathbf{I}) \mathbf{x} = \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0}, \end{aligned}$$

onde há precisamente m (-1) s na função objetivo, e a matrix identidade ao lado de $\mathbf{A}$ é de tamanho $m \times m$. Esta PL auxiliar é viável, seu ótimo é no máximo 0. A solução básica inicial usa as variáveis recém criadas. Rodamos então o Simplex. Se seu ótimo é menor que 0, a PL original é inviável, e se seu ótimo for igual a 0, então qualquer vetor que atinja esse ótimo corresponde a uma solução básica viável da PL original, e a partir dela, poderemos então iniciar o Simplex na PL original para achar seu ótimo.

Exercício 33. A PL abaixo é viável ou inviável?

$$\begin{aligned} \max \quad & (2 \ -1 \ 2) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} -1 & -2 & 1 \\ 1 & -1 & 1 \end{pmatrix} \mathbf{x} = \begin{pmatrix} -1 \\ 3 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Exercício 34. Suponha que uma dada PL seja inviável. Prove que um certificado de otimalidade para a PL auxiliar é também um certificado de inviabilidade para a PL original.

2.8 Pseudo-código

Apenas para formalizar, segue o SIMPLEX em pseudo-código. Há também, em seguida, alguns comentários sobre sutilezas e nuances do algoritmo.

Método Simplex	
Input:	Uma PL e uma base viável de colunas B .
Output:	Uma solução ótima, ou um certificado de que a PL é ilimitada.
1:	Reescreva a PL para a forma canônica com respeito à base B . Seja $\mathbf{x}$ a solução básica viável associada.
2:	Se $\mathbf{c}_N \leq 0$, então pare. $\mathbf{x}$ é ótima.
3:	Escolha um $k \in N$ tal que $\mathbf{c}_k > 0$.
4:	Se $\mathbf{A}_k \leq 0$, então pare. A PL é ilimitada.
5:	Seja r o índice j tal que o mínimo abaixo ocorre: $t = \min \left\{ \frac{\mathbf{b}_j}{A_{jk}} : A_{jk} > 0 \right\}.$
6:	Troque a r -ésima (na ordem da matriz identidade) coluna de B pela coluna k .
7:	Volte para 1.

Este algoritmo passeia de solução básica em solução básica até encontrar a melhor. Cada solução básica corresponde a precisamente um valor objetivo, e como há um número finito de soluções básicas, se garantirmos que a cada rodada o algoritmo para ou aumenta o valor objetivo, então teremos que este algoritmo sempre termina.

Exercício 35. Dada a PL

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{A}\mathbf{x} \leq \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0}, \end{aligned}$$

e um vetor $\mathbf{y}$ tal que $\mathbf{y} \geq \mathbf{0}$ e $\mathbf{y}^T \mathbf{A} \geq \mathbf{c}^T$, mostre que nenhuma solução da PL pode ter valor objetivo maior que $\mathbf{y}^T \mathbf{b}$.

Exercício 36. Escreva um algoritmo baseado no Simplex que resolve a PL

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{A}\mathbf{x} = \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0} \end{aligned}$$

sem precisar convertê-la para um problema de maximização.

2.9 Versão estendida com registro de operações (VERO™)

Nesta seção, através de exemplos, conheceremos uma versão estendida do tableau que nos permite encontrar, ao final, certificados de otimalidade e inviabilidade. Neste momento, apenas mostraremos que os certificados encontrados são válidos. A demonstração de que este método sempre encontra os certificados está localizada na Seção 3.8.

Exemplo 12. Vamos resolver a PL:

$$\begin{aligned} \max \quad & (-1 \ 3 \ 1 \ 2) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 2 & -2 & 0 \\ 0 & 1 & 3 & 1 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 2 \\ 5 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Olhando para a matriz, vemos que já temos uma base viável de colunas, mas a PL não está em forma canônica. Começaremos escrevendo o tableau em sua nova versão — a versão estendida de registro de operações (VERO™). Esta versão substitui a coluna relativa à variável w , na esquerda do tableau, por uma matriz identidade e um vetor de zeros.

$$\begin{array}{c|ccc|c} 0 & 0 & ||| & 1 & -3 & -1 & -2 & | & 0 \\ 1 & 0 & ||| & 1 & 2 & -2 & 0 & | & 2 \\ 0 & 1 & ||| & 0 & 1 & 3 & 1 & | & 5 \end{array}$$

Começaremos zerando as entradas do vetor $-\mathbf{c}$.

$$\begin{array}{c|cc|ccc|c} -1 & 2 & ||| & 0 & -3 & 7 & 0 & | & 8 \\ 1 & 0 & ||| & 1 & 2 & -2 & 0 & | & 2 \\ 0 & 1 & ||| & 0 & 1 & 3 & 1 & | & 5 \end{array}$$

Note que $(-1 \ 2)$ registra precisamente que somamos ao $-\mathbf{c}$ -1 vezes a 1a linha de $\mathbf{A}$, e 2 vezes a 2a. Prosseguindo com o Simplex, pivotearemos o 2 abaixo do -3 :

$$\begin{array}{c|ccc|ccc|c} -1 & 2 & ||| & 0 & -3 & 7 & 0 & | & 8 \\ 1/2 & 0 & ||| & 1/2 & 1 & -1 & 0 & | & 1 \\ 0 & 1 & ||| & 0 & 1 & 3 & 1 & | & 5 \end{array} \rightarrow \begin{array}{c|ccc|ccc|c} 1/2 & 2 & ||| & 3/2 & 0 & 4 & 0 & | & 11 \\ 1/2 & 0 & ||| & 1/2 & 1 & -1 & 0 & | & 1 \\ -1/2 & 1 & ||| & -1/2 & 0 & 4 & 1 & | & 4 \end{array}$$

Note que ao termos registrado que multiplicamos a 1a linha por $1/2$ quando normalizamos o 2 no primeiro tableau, automaticamente pudemos saber que adicionamos $3 \cdot (1/2)$ da 1a linha original à linha do $\mathbf{c}$. Enfim, chegamos ao ótimo. E agora temos:

$$\mathbf{z} = (0 \ 1 \ 0 \ 4)^T \quad \text{v.o.} = \mathbf{c}^T \mathbf{z} = 11$$

e o certificado de ótimo

$$\mathbf{y} = (1/2 \ 2)^T.$$

De fato:

$$\mathbf{y}^T \mathbf{A} - \mathbf{c}^T = (1/2 \ 3 \ 5 \ 2) - (-1 \ 3 \ 1 \ 2) = (3/20 \ 4 \ 0)$$

que é exatamente o que aparece sobre o tableau, assim como

$$\mathbf{y}^T \mathbf{b} = (1/2 \ 2) \begin{pmatrix} 2 \\ 5 \end{pmatrix} = 11.$$

Vamos ver agora o que aconteceria se tivéssemos registrado as operações ao resolvermos uma PL auxiliar.

Exemplo 13. Vamos resolver a PL:

$$\begin{array}{ll} \max & (6 \ -5 \ 1) \mathbf{x} \\ \text{sujeito a} & \begin{pmatrix} 1 & -3 & 7 \\ -1 & 5 & -10 \end{pmatrix} \mathbf{x} = \begin{pmatrix} -1 \\ 1 \end{pmatrix} \\ & \mathbf{x} \geq \mathbf{0}. \end{array}$$

Não está claro qual seria uma base viável. Logo, vamos para a PL auxiliar. A primeira coisa que faremos é multiplicar a 1a linha por -1 , e portanto já registraremos esta operação. Depois montamos a PL auxiliar.

$$\begin{array}{c|c|c|c|c|c|c|c|c}
 0 & 0 & 0 & 0 & 0 & 1 & 1 & 0 \\
 -1 & 0 & -1 & 3 & -7 & 1 & 0 & 1 \\
 0 & 1 & -1 & 5 & -10 & 0 & 1 & 1
 \end{array} \rightarrow \begin{array}{c|c|c|c|c|c|c|c|c}
 1 & -1 & 2 & -8 & 17 & 0 & 0 & -2 \\
 -1 & 0 & -1 & 3 & -7 & 1 & 0 & 1 \\
 0 & 1 & -1 & 5 & -10 & 0 & 1 & 1
 \end{array}$$

$$\begin{array}{c|c|c|c|c|c|c|c|c}
 1 & -1 & 2 & -8 & 17 & 0 & 0 & -2 \\
 -1 & 0 & -1 & 3 & -7 & 1 & 0 & 1 \\
 0 & 1/5 & -1/5 & 1 & -2 & 0 & 1/5 & 1/5
 \end{array} \rightarrow \begin{array}{c|c|c|c|c|c|c|c|c}
 1 & 3/5 & 2/5 & 0 & 1 & 0 & 8/5 & -2/5 \\
 -1 & -3/5 & -2/5 & 0 & -1 & 1 & -3/5 & 2/5 \\
 0 & 1/5 & -1/5 & 1 & 2 & 0 & 1/5 & 1/5
 \end{array}$$

Como o ótimo da PL auxiliar é negativo, a PL original é inviável. Mais importante que isso neste momento, seja $\mathbf{y}^T = (1 \ 3/5)$, ou seja, o certificado de ótimo da PL auxiliar. Note que

$$\mathbf{y}^T \mathbf{A} = (1 \ 3/5) \begin{pmatrix} 1 & -3 & 7 \\ -1 & 5 & -10 \end{pmatrix} = (2/5 \ 0 \ 1),$$

exatamente o que aparece na linha de cima do tableau, e que é $\geq \mathbf{0}$ já que o tableau está em estado de ótimo. Ademais

$$\mathbf{y}^T \mathbf{b} = (1 \ 3/5) \begin{pmatrix} -1 \\ 1 \end{pmatrix} = -2/5 < 0,$$

portanto $\mathbf{y}$ é um certificado de inviabilidade.

Ou seja, acabamos de ver na prática que o certificado de ótimo de uma PL auxiliar que resultou num ótimo negativo é precisamente igual a um certificado de inviabilidade da PL original!

A partir de agora, tente resolver todas as suas PLs com a VERO™.

Capítulo 3

Dualidade

3.1 Dualidade

Nesta seção, estudaremos um importantíssimo aspecto das programações lineares. Descobriremos que para toda programação linear, poderemos definir uma outra, intimamente relacionada, chamada de programação dual (motivo pelo qual a PL original é costumeiramente chamada de primal).

Considere a PL:

$$\begin{array}{ll}\max & 7x_1 + 5x_2 + 6x_3 \\ \text{sujeito a} & 2x_1 + x_2 + x_3 \leq 2 \\ & x_1 + 2x_2 + 3x_3 \leq 2 \\ & x_1, x_2, x_3 \geq 0.\end{array}$$

Note que ao multiplicarmos a primeira restrição por 3 e somarmos à segunda, obtemos

$$7x_1 + 5x_2 + 6x_3 \leq 8.$$

Ou seja, a função objetivo não pode ser maior do que 8. Sendo assim, caso o sistema abaixo possua alguma solução:

$$\begin{array}{l}2x_1 + x_2 + x_3 = 2 \\ x_1 + 2x_2 + 3x_3 = 2 \\ x_1, x_2, x_3 \geq 0\end{array}$$

encontraremos uma solução ótima. Por exemplo, no caso, $x_1 = x_2 = 2/3$, $x_3 = 0$.

Nem sempre entretanto é possível expressar a função objetivo como combinação das restrições. Por exemplo

$$\begin{array}{ll}\max & 4x_1 + 5x_2 + 6x_3 \\ \text{sujeito a} & 2x_1 + x_2 + x_3 \leq 3 \\ & x_1 + 2x_2 + 3x_3 \leq 2 \\ & x_1, x_2, x_3 \geq 0.\end{array}$$

Não podemos expressar a função objetivo como uma combinação das inequações (por que?), mas suponha que existam $y_1, y_2 \geq 0$ que, quando multiplicados às restrições do problema:

$$\begin{aligned} \max \quad & 4x_1 + 5x_2 + 6x_3 \\ \text{sujeito a} \quad & (2x_1 + x_2 + x_3)y_1 \leq 3y_1 \\ & (x_1 + 2x_2 + 3x_3)y_2 \leq 2y_2 \\ & x_1, x_2, x_3 \geq 0. \end{aligned}$$

nos garanta que:

$$4x_1 + 5x_2 + 6x_3 \leq y_1(2x_1 + x_2 + x_3) + y_2(x_1 + 2x_2 + 3x_3).$$

Então saberemos que $4x_1 + 5x_2 + 6x_3 \leq 3y_1 + 2y_2$.

Por exemplo, para $y_1 = 6$ e $y_2 = 0$, teremos

$$4x_1 + 5x_2 + 6x_3 \leq 12x_1 + 6x_2 + 6x_3 \leq 18,$$

já que $x_1, x_2, x_3 \geq 0$ e os coeficientes são não-negativos.

Com $y_1 = 0$ e $y_2 = 4$, temos

$$4x_1 + 5x_2 + 6x_3 \leq 4x_1 + 8x_2 + 12x_3 \leq 8.$$

Com $y_1 = 1$ e $y_2 = 2$, temos

$$4x_1 + 5x_2 + 6x_3 \leq 4x_1 + 5x_2 + 7x_3 \leq 7.$$

Uma boa escolha de y_1 e y_2 nos fornece um **limite superior** ao valor que a solução ótima do problema pode obter. Naturalmente, gostaríamos de encontrar o menor limite superior possível. É mais valioso dizer que a solução ótima do problema é ≤ 7 que ≤ 18 , por exemplo.

Procuramos então y_1 e y_2 , não-negativos, tais que $3y_1 + 2y_2$ seja o menor possível, e ainda assim tenhamos $2y_1 + y_2 \geq 4$, $y_1 + 2y_2 \geq 5$, e $y_1 + 3y_2 \geq 6$. Parece familiar?

Exercício 37. Escreva uma programação linear cuja otimização busca limitar os valores objetivos da PL

$$\begin{aligned} \max \quad & \begin{pmatrix} 1 & 1 & 1 \end{pmatrix} \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 1 & 2 \\ 2 & 1 & 1 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 4 \\ 4 \end{pmatrix} \\ & \mathbf{x} \geq 0. \end{aligned}$$

Otimize ambas.

3.2 A PL dual

Considere uma PL, que chamamos de **primal**, dada por

$$(P) \quad \begin{array}{ll} \max & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} & \mathbf{Ax} \leq \mathbf{b} \\ & \mathbf{x} \geq 0. \end{array}$$

Como vimos na seção anterior, é possível escrever uma PL, doravante chamada de **dual**, em que **cada restrição da primal corresponde a uma variável da dual**.

Será um problema de minimização. O valor objetivo será calculado em termos de $\mathbf{b}$. O vetor $\mathbf{c}$ é o limite inferior das restrições. E tudo ainda precisa ser não-negativo. Ou seja

$$(D) \quad \begin{array}{ll} \min & \mathbf{b}^T \mathbf{y} \\ \text{sujeito a} & \mathbf{y}^T \mathbf{A} \geq \mathbf{c}^T \quad (\text{ou equivalentemente } \mathbf{A}^T \mathbf{y} \geq \mathbf{c}) \\ & \mathbf{y} \geq 0. \end{array}$$

Note que este formato é específico para uma PL que esteja exatamente no formato de (P) acima. Como fazer por exemplo se a PL (P) estiver em FPI?

Originalmente, no exemplo acima, tínhamos $2x_1 + x_2 + x_3 \leq 3$. Ao multiplicarmos ambos os lados por y_1 , precisamos que $y_1 \geq 0$ para que o sinal da desigualdade não se invertesse. Se contudo tivéssemos $2x_1 + x_2 + x_3 = 3$, então y_1 poderia ter sido qualquer número e a igualdade não se alteraria. Temos portanto a seguinte formulação de **dualidade para uma PL em FPI**:

$$(P) \quad \begin{array}{ll} \max & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} & \mathbf{Ax} = \mathbf{b} \\ & \mathbf{x} \geq 0 \end{array} \quad \left| \quad \begin{array}{ll} \min & \mathbf{b}^T \mathbf{y} \\ \text{sujeito a} & \mathbf{A}^T \mathbf{y} \geq \mathbf{c} \\ & \mathbf{y} \text{ livre.} \end{array} \quad (D)$$

Mais geralmente, temos a seguinte tabela que nos ensina como construir a dual de uma PL qualquer:

Primal			Dual		
$\max \quad \mathbf{c}^T \mathbf{x}$ sujeita a $\mathbf{Ax} ? \mathbf{b}$ $\mathbf{x} ? 0$	restrição	$\leq$	variável	≥ 0	$\min \quad \mathbf{b}^T \mathbf{y}$ sujeita a $\mathbf{A}^T \mathbf{y} ? \mathbf{c}$ $\mathbf{y} ? 0$
	restrição	$=$	variável	livre	
	restrição	$\geq$	variável	≤ 0	
	variável	≥ 0	restrição	$\geq$	
	variável	livre	restrição	$=$	
	variável	≤ 0	restrição	$\leq$	

Esta tabela é um bom guia, mas é mais eficiente que você...

- (i) entenda a lógica da dualidade,
- (ii) converta a primal para a FPI ou para o formato de (P) acima,
- (iii) memorize a dual desses formatos.

Exercício 38. Considere a programação linear

$$(P) \quad \begin{array}{ll} \max & \begin{pmatrix} 3 & 2 \end{pmatrix} \mathbf{x} \\ \text{sujeito a} & \begin{pmatrix} 2 & 1 \\ 1 & 2 \\ 1 & 1 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 8 \\ 8 \\ 5 \end{pmatrix} \\ & \mathbf{x} \geq 0. \end{array}$$

- (i) Escreva em FPI.
- (ii) Escreva a dual.
- (iii) Escreva a dual em FPI.
- (iv) Escreva a dual da dual, e a coloque em FPI. O que aconteceu?
- (v) Ache soluções viáveis para a primal (P) e a sua dual (D).
- (vi) Verifique que o valor objetivo da solução viável da primal é menor ou igual que o valor objetivo da solução viável da dual.
- (vii) Calcule o valor ótimo de cada PL.

Faça o mesmo para a PL

$$(P) \quad \begin{array}{ll} \max & (2 \ 3) \mathbf{x} \\ \text{sujeito a} & \begin{pmatrix} 1 & 1 \\ 2 & 1 \\ -1 & 1 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 6 \\ 10 \\ 4 \end{pmatrix} \\ & \mathbf{x} \geq 0. \end{array}$$

Exercício 39. Usando a tabela acima, mostre que a dual da dual é sempre igual a primal.

3.3 Teorema fraco da Dualidade

Como vimos, a dual é construída de modo que seu valor objetivo seja sempre um limitante superior para o valor objetivo da primal. Formalizamos isso no teorema abaixo, onde assumimos que a primal está escrita em FPI.

Teorema 5 (Teorema fraco da dualidade). *Sejam (P) e (D) um par primal-dual de programações lineares, (P) em formato FPI, e seja $\mathbf{x}$ e $\mathbf{y}$ soluções viáveis para (P) e (D), respectivamente. Então:*

- (i) $\mathbf{c}^T \mathbf{x} \leq \mathbf{b}^T \mathbf{y}$.
- (ii) Se $\mathbf{c}^T \mathbf{x} = \mathbf{b}^T \mathbf{y}$, então $\mathbf{x}$ é solução ótima para (P), e $\mathbf{y}$ é solução ótima para (D).

Demonstração.

- (i) Já que $\mathbf{x}$ é viável para (P), segue que

$$\mathbf{y}^T \mathbf{A} \mathbf{x} = \mathbf{y}^T \mathbf{b}.$$

Já que $\mathbf{y}$ é viável em (D), ou seja, $\mathbf{y}^T \mathbf{A} \geq \mathbf{c}$, segue que, para todo $\mathbf{x} \geq 0$,

$$\mathbf{y}^T \mathbf{A} \mathbf{x} \geq \mathbf{c}^T \mathbf{x}.$$

Temos portanto

$$\mathbf{b}^T \mathbf{y} = \mathbf{x}^T \mathbf{A} \mathbf{y} \geq \mathbf{c}^T \mathbf{x}.$$

(ii) É uma consequência imediata do item (i).

□

Note que este teorema **ainda não está dizendo que se ambas as PLs tem ótimos, então estes ótimos são iguais**. Isso de fato é verdade, e veremos logo mais, reforçando ainda mais o motivo pelo qual definimos duais como tal. Contudo, por enquanto, a única coisa que sabemos é que se a primal e a dual possuírem soluções viáveis de mesmo valor objetivo, então essas soluções são respectivos ótimos de cada PL. Note aqui que uma solução da dual com mesmo valor objetivo que uma solução da primal é exatamente o que estávamos chamando de certificado de otimalidade.

Corolário 6. *Seja (P) e (D) um par primal-dual de PLs.*

- (i) *Se (P) é ilimitada, então (D) é inviável.*
- (ii) *Se (D) é ilimitada, então (P) é inviável.*
- (iii) *Se (P) e (D) são viáveis, então ambas são limitadas.*

□

Exercício 40. Considere a PL

$$\begin{aligned} \max \quad & (3 \ 2 \ 4) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 1 & 2 \\ 2 & 0 & 3 \\ 2 & 1 & 3 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 5 \\ 4 \\ 7 \end{pmatrix} \\ & \mathbf{x} \geq 0. \end{aligned}$$

- (i) Ache o ótimo.
- (ii) Ache um certificado de otimalidade (ou seja, um vetor $\mathbf{y}$ tal que $\mathbf{c}^T \leq \mathbf{y}^T \mathbf{A}$ e $\mathbf{y}^T \mathbf{b} = \mathbf{c}^T \mathbf{z}$, onde $\mathbf{z}$ é ótimo).
- (iii) Escreva a dual.
- (iv) Ache o ótimo da dual sem realizar o simplex novamente.

Exercício 41. Escreva a dual da PL abaixo

$$\begin{aligned} \max \quad & (1 \ 3 \ -1) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 2 & 2 & -1 \\ 3 & -2 & 1 \\ 1 & -3 & 1 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 10 \\ 10 \\ 10 \end{pmatrix} \\ & \mathbf{x} \geq 0. \end{aligned}$$

Mostre que a dual é inviável de duas formas diferentes:

- (i) Mostrando que a primal é ilimitada.
- (ii) Usando uma PL auxiliar.

3.4 Interpretação do tableau estendido

Considere novamente a PL primal:

$$(P) \quad \begin{array}{ll} \max & (3 \ 2) \mathbf{x} \\ \text{sujeito a} & \begin{pmatrix} 2 & 1 \\ 1 & 2 \\ 1 & 1 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 8 \\ 8 \\ 5 \end{pmatrix} \\ & \mathbf{x} \geq 0. \end{array}$$

Ao resolvê-la com o Simplex a partir da base inicial x_3, x_4 e x_5 e pivoteando inicialmente na primeira coluna, obtemos a seguinte sequência de tableaus:

$$\begin{pmatrix} 0 & 0 & 0 & \parallel & -3 & -2 & 0 & 0 & 0 & | & 0 \\ 1 & 0 & 0 & \parallel & \boxed{2} & 1 & 1 & 0 & 0 & | & 8 \\ 0 & 1 & 0 & \parallel & 1 & 2 & 0 & 1 & 0 & | & 8 \\ 0 & 0 & 1 & \parallel & 1 & 1 & 0 & 0 & 1 & | & 5 \end{pmatrix}$$

$$\left(\begin{array}{cccc|cccc|c} 3/2 & 0 & 0 & 0 & 0 & -1/2 & 3/2 & 0 & 0 & 12 \\ 1/2 & 0 & 0 & 0 & 1 & 1/2 & 1/2 & 0 & 0 & 4 \\ -1/2 & 1 & 0 & 0 & 0 & 3/2 & -1/2 & 1 & 0 & 4 \\ -1/2 & 0 & 1 & 0 & 0 & \boxed{1/2} & -1/2 & 0 & 1 & 1 \end{array} \right)$$

$$\left(\begin{array}{cccc|cccc|c} 1 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 1 & 13 \\ 1 & 0 & -1 & 0 & 1 & 0 & 1 & 0 & -1 & 3 \\ 1 & 1 & -3 & 0 & 0 & 1 & 1 & -3 & 1 & 1 \\ -1 & 0 & 2 & 0 & 1 & -1 & 0 & 2 & 2 & 2 \end{array} \right)$$

O valor objetivo ótimo da primal é 13 e a solução ótima $\mathbf{x} = (3 \ 2 \ 0 \ 1 \ 0)$. Desta forma, a base viável ótima é formada pelas colunas 1, 4 e 2. A ordem x_1, x_4, x_2 indica quais variáveis são definidas pelas primeira, segunda e terceira restrições respectivamente.

Agora suponha que alguém lhe dissesse de antemão que esta base inicial (x_1, x_4 e x_2) era válida e viável, e que te recomendasse começar o tableau a partir dela. Partimos do tableau inicial:

$$\left(\begin{array}{cccc|cccc|c} 0 & 0 & 0 & 0 & -3 & -2 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 2 & 1 & 1 & 0 & 0 & 8 \\ 0 & 1 & 0 & 0 & 1 & 2 & 0 & 1 & 0 & 8 \\ 0 & 0 & 1 & 0 & 1 & 1 & 0 & 0 & 1 & 5 \end{array} \right)$$

A quarta coluna (a segunda da base) já está em forma canônica. Faremos o processo na 1a coluna, pivoteando o elemento relativo à primeira restrição, e na 2a coluna, pivoteando o elemento relativo à 3a restrição:

$$\left(\begin{array}{cccc|cccc|c} 3/2 & 0 & 0 & 0 & 0 & -1/2 & 3/2 & 0 & 0 & 12 \\ 1/2 & 0 & 0 & 0 & 1 & 1/2 & 1/2 & 0 & 0 & 4 \\ -1/2 & 1 & 0 & 0 & 0 & 3/2 & -1/2 & 1 & 0 & 4 \\ -1/2 & 0 & 1 & 0 & 0 & 1/2 & -1/2 & 0 & 1 & 1 \end{array} \right)$$

$$\left(\begin{array}{ccc|ccc|c} 1 & 0 & 1 & 0 & 0 & 1 & 0 & 1 & 13 \\ 1 & 0 & -1 & 1 & 0 & 1 & 0 & -1 & 3 \\ 1 & 1 & -3 & 0 & 0 & 1 & 1 & -3 & 1 \\ -1 & 0 & 2 & 0 & 1 & -1 & 0 & 2 & 2 \end{array} \right)$$

Obtivemos o mesmo tableau final que quando começamos o simplex a partir da base (x_3, x_4, x_5) . Isto não é coincidência, pois não importa a ordem das operações, ao final só haverá um tableau possível para uma certa base. Suponha sem perda de generalidade que tivéssemos reorganizado as colunas da matriz $\mathbf{A}$ na ordem $(1, 4, 2, 3, 5)$, reorganizando também acima o vetor $\mathbf{c}^T$. Neste caso, podemos dividir a matriz $\mathbf{A}$ em $\mathbf{A}_B$ representando a base e $\mathbf{A}_N$ com as colunas das variáveis que não são parte da base. O tableau inicial ficaria da seguinte forma:

$$\begin{array}{c|ccc} \mathbf{0} & & & \\ \hline & & & \\ \hline \mathbf{I} & & & \\ \hline & & & \end{array} \begin{array}{c|c|c} -\mathbf{c}_B^T & -\mathbf{c}_N^T & 0 \\ \hline \mathbf{A}_B & \mathbf{A}_N & \mathbf{b} \end{array}$$

Ao fazer esta reorganização no exemplo numérico acima, o tableau ficaria assim:

$$\left(\begin{array}{ccc|ccc|c} 0 & 0 & 0 & -3 & 0 & -2 & 0 & 0 & 0 \\ 1 & 0 & 0 & 2 & 0 & 1 & 1 & 0 & 8 \\ 0 & 1 & 0 & 1 & 1 & 2 & 0 & 0 & 8 \\ 0 & 0 & 1 & 1 & 0 & 1 & 0 & 1 & 5 \end{array} \right)$$

Ao colocar o tableau na forma canônica, estamos obtendo uma matriz identidade no lugar de $\mathbf{A}_B$, o que é equivalente a fazer $\mathbf{A}_B^{-1}\mathbf{A}_B = \mathbf{I}$. Isto implica também que na matriz original identidade à esquerda, obteremos $\mathbf{A}_B^{-1}$. Fazendo as mesmas operações nas demais colunas, obtemos o tableau temporário, ainda não totalmente na forma canônica:

$$\begin{array}{c|ccc} \mathbf{0} & & & \\ \hline & & & \\ \hline \mathbf{A}_B^{-1} & & & \\ \hline & & & \end{array} \begin{array}{c|c|c} -\mathbf{c}_B^T & -\mathbf{c}_N^T & 0 \\ \hline \mathbf{A}_B^{-1}\mathbf{A}_B = \mathbf{I} & \mathbf{A}_B^{-1}\mathbf{A}_N & \mathbf{A}_B^{-1}\mathbf{b} \end{array}$$

No exemplo numérico, o tableau após esta operação ficaria assim:

$$\left(\begin{array}{ccc|ccc|c} 0 & 0 & 0 & -3 & 0 & -2 & 0 & 0 & 0 \\ 1 & 0 & -1 & 1 & 0 & 0 & 1 & -1 & 3 \\ 1 & 1 & -3 & 0 & 1 & 0 & 1 & -3 & 1 \\ -1 & 0 & 2 & 0 & 0 & 1 & -1 & 2 & 2 \end{array} \right)$$

Para completar a forma canônica, precisamos zerar $\mathbf{c}_B^T$. Para isso, multiplicamos $\mathbf{A}_B^{-1}\mathbf{A}_B$ por $\mathbf{c}_B^T$ e somamos em $-\mathbf{c}_B^T$. Claro, repetimos as operações nas outras partes do tableau:

$$\begin{array}{c|ccc} \mathbf{c}_B^T\mathbf{A}_B^{-1} & & & \\ \hline & & & \\ \hline \mathbf{A}_B^{-1} & & & \\ \hline & & & \end{array} \begin{array}{c|c|c} \mathbf{c}_B^T\mathbf{A}_B^{-1}\mathbf{A}_B - \mathbf{c}_B^T = \mathbf{0} & \mathbf{c}_B^T\mathbf{A}_B^{-1}\mathbf{A}_N - \mathbf{c}_N^T & \mathbf{c}_B^T\mathbf{A}_B^{-1}\mathbf{b} \\ \hline \mathbf{A}_B^{-1}\mathbf{A}_B = \mathbf{I} & \mathbf{A}_B^{-1}\mathbf{A}_N & \mathbf{A}_B^{-1}\mathbf{b} \end{array}$$

$$\left(\begin{array}{ccc|ccc|cc|c} 1 & 0 & 1 & 0 & 0 & 0 & 1 & 1 & 13 \\ 1 & 0 & -1 & 1 & 0 & 0 & 1 & -1 & 3 \\ 1 & 1 & -3 & 0 & 1 & 0 & 1 & -3 & 1 \\ -1 & 0 & 2 & 0 & 0 & 1 & -1 & 2 & 2 \end{array} \right)$$

Juntando novamente as matrizes $\mathbf{A}_B$ e $\mathbf{A}_N$ em uma matriz única $\mathbf{A}$:

$$\begin{array}{c|c|c} \mathbf{c}_B^T \mathbf{A}_B^{-1} & \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A} - \mathbf{c}^T & \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{b} \\ \hline \mathbf{A}_B^{-1} & \mathbf{A}_B^{-1} \mathbf{A} & \mathbf{A}_B^{-1} \mathbf{b} \end{array}$$

Se a base escolhida é a base ótima, teremos que (como o tableau é invertido) que $\mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A} - \mathbf{c}^T \geq 0$, onde os termos relativos à base são precisamente iguais a zero. O valor ótimo do problema é dado por $\mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{b}$. Na próxima seção, veremos que $\mathbf{c}_B^T \mathbf{A}_B^{-1}$ é o vetor $\mathbf{y}^*$ que resolve o problema dual.

3.5 Teorema Forte da Dualidade

Como já vimos em exemplos acima, quando as PLs em um par primal-dual são viáveis e limitadas, os valores ótimos podem ser, de fato iguais. Os exemplos não foram uma coincidência. Este fato é particularmente relevante, tanto de um ponto de vista prático como teórico.

Teorema 7. *Sejam (P) e (D) um par primal-dual de PLs, e suponha que (P) está em FPI. Se existe uma solução ótima para (P) , então existe uma solução ótima para (D) , e, ademais, o valor objetivo ótimo de (P) e (D) é igual.*

Demonstração. Temos

$$\begin{array}{l|l} \begin{array}{ll} \max & \mathbf{c}^T \mathbf{x} \\ \text{(P)} \text{ sujeito a } & \mathbf{A} \mathbf{x} = \mathbf{b} \\ & \mathbf{x} \geq 0 \end{array} & \begin{array}{ll} \min & \mathbf{b}^T \mathbf{y} \\ \text{(D)} \text{ sujeito a } & \mathbf{A}^T \mathbf{y} \geq \mathbf{c} \end{array} \end{array}$$

Sabemos que existe uma solução ótima para (P) que é básica. Seja $\mathbf{z}$ uma solução ótima básica de (P) para uma base B . Aplicamos uma rodada do simplex, e obteremos uma PL em forma canônica. Como vimos anteriormente, esta PL é obtida multiplicando $\mathbf{A} \mathbf{x} = \mathbf{b}$ por $\mathbf{A}_B^{-1}$, e usando os coeficientes de $\mathbf{c}_B$ para somar as linhas da nova matriz de modo que $\mathbf{c}_B$ se torne $\mathbf{0}$ e $\mathbf{c}_N$ se torne não-positivo (agora, sem o tableau invertido). Ou seja

$$\mathbf{c}^T - \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A} \leq 0,$$

Como $\mathbf{c}_B^T - \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A}_B = 0$ e as variáveis não básicas de $\mathbf{z}$ também são iguais a zero, temos que:

$$\begin{aligned} (\mathbf{c}^T - \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A}) \mathbf{z} &= 0 \\ \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A} \mathbf{z} &= \mathbf{c}^T \mathbf{z} \end{aligned}$$

Ou seja, $\mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A} \mathbf{z}$ é o valor ótimo da PL. Como $\mathbf{A} \mathbf{z} = \mathbf{b}$, segue que o valor ótimo é precisamente

$$\mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A} \mathbf{z} = \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{b}.$$

Considere $\mathbf{y}^T = \mathbf{c}_B^T \mathbf{A}_B^{-1}$. Vamos mostrar que $\mathbf{y}$ é solução viável para (D) com mesmo valor objetivo que $\mathbf{z}$ em (P) .

(i) Como $\mathbf{c}^T - \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A} \leq 0$, segue que $\mathbf{c}^T - \mathbf{y}^T \mathbf{A} \leq 0$, logo $\mathbf{A}^T \mathbf{y} \geq \mathbf{c}$. Logo $\mathbf{y}$ é viável.

(ii) Como $\mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{b} = \mathbf{y}^T \mathbf{b}$, segue que o valor objetivo de $\mathbf{y}$ em (D) é igual ao valor objetivo de $\mathbf{z}$ em (P) .

Pelo teorema fraco da dualidade, segue que o ótimo de (D) não pode ser menor que o ótimo de (P) , e portanto eles tem que ser iguais. $\square$

Exercício 42. Considere o par a seguir de PLs:

$$(P) \quad \begin{array}{ll} \max & (-3 \quad \alpha \quad 13) \mathbf{x} \\ \text{sujeito a} & \begin{pmatrix} 4 & 2 & 2 \\ 1 & 2 & -1 \\ -1 & 3 & 3 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} \beta \\ 5 \\ 5 \end{pmatrix} \\ & \mathbf{x} \geq 0 \end{array}$$

$$(D) \quad \begin{array}{ll} \min & (\beta \quad 5 \quad 5) \mathbf{y} \\ \text{sujeito a} & \begin{pmatrix} 4 & 1 & -1 \\ 2 & 2 & 3 \\ 2 & -1 & 3 \end{pmatrix} \mathbf{y} \geq \begin{pmatrix} -3 \\ \alpha \\ 13 \end{pmatrix} \\ & y_1, y_2 \geq 0 \end{array}$$

Existe α e β tais que $\mathbf{x} = (1 \quad 2 \quad 0)$ e $\mathbf{y} = (0 \quad 2 \quad 5)$ são respectivos ótimos? Se sim, ache. Se não, explique.

Exercício 43. Considere a PL

$$\begin{array}{ll} \min & (1 \quad \alpha \quad 10 \quad 25/2) \mathbf{x} \\ \text{sujeito a} & \begin{pmatrix} 1 & 0 & 5 & 6 \\ 2 & 6 & 0 & 1 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 1 \\ 2 \end{pmatrix} \\ & x_1 \geq 0, x_2 \leq 0, x_3 \text{ livre}, x_4 \geq 0. \end{array}$$

Escreva a dual, e determine para quais valores de α a solução $(1 \quad 0 \quad 0 \quad 0)$ é ótima para a PL acima.

3.6 PLs inviáveis ou ilimitadas

Nós sabemos que toda PL satisfaz uma das três possibilidades abaixo:

(i) É inviável.

(ii) É viável e ilimitada.

(iii) É viável e limitada, e possui uma solução ótima.

Nós agora podemos relacionar essas possibilidades para um par primal-dual de PLs.

Corolário 8. *Sejam (P) e (D) um par primal-dual de PLs. Há precisamente quatro casos:*

- (i) *Ambas são inviáveis.*
- (ii) *(P) é viável e ilimitada, e então (D) é inviável.*
- (iii) *(D) é viável e ilimitada, e então (P) é inviável.*
- (iv) *Ambas são viáveis, e então ambas possuem soluções ótimas.*

Demonstração. Consequência direta do fato que toda solução da primal é um limitante para a dual e vice-versa, e que se uma PL possui ótimo, então sua dual também possui. $\square$

Exercício 44. Considere as quatro PLs primais abaixo, e as quatro PLs duais em seguida. Associe os pares corretamente, e em seguida decida qual caso do corolário acima se aplica a cada par. Apresente certificados.

$\begin{array}{ll} \max & 2x_1 + x_2 \\ \text{sujeito a} & x_1 + x_2 \leq 4 \\ & x_1 - x_2 \leq 2 \\ & x_1, x_2 \geq 0 \end{array}$	$\begin{array}{ll} \max & 2x_1 + x_2 \\ \text{sujeito a} & x_1 - x_2 \leq 4 \\ & x_1 - x_2 \leq 2 \\ & x_1, x_2 \geq 0 \end{array}$
$\begin{array}{ll} \max & 2x_1 + x_2 \\ \text{sujeito a} & x_1 + x_2 \geq 4 \\ & x_1 + x_2 \leq 2 \\ & x_1, x_2 \geq 0 \end{array}$	$\begin{array}{ll} \max & 2x_1 + x_2 \\ \text{sujeito a} & x_1 - x_2 \geq 4 \\ & x_1 - x_2 \leq 2 \\ & x_1, x_2 \geq 0 \end{array}$
$\begin{array}{ll} \min & -4y_1 + 2y_2 \\ \text{sujeito a} & y_1 - y_2 \leq -2 \\ & y_1 - y_2 \leq -1 \\ & y_1, y_2 \geq 0 \end{array}$	$\begin{array}{ll} \min & 4y_1 + 2y_2 \\ \text{sujeito a} & y_1 + y_2 \geq 2 \\ & y_1 - y_2 \geq 1 \\ & y_1, y_2 \geq 0 \end{array}$
$\begin{array}{ll} \min & -4y_1 + 2y_2 \\ \text{sujeito a} & -y_1 + y_2 \geq 2 \\ & y_1 - y_2 \geq 1 \\ & y_1, y_2 \geq 0 \end{array}$	$\begin{array}{ll} \min & 4y_1 + 2y_2 \\ \text{sujeito a} & y_1 + y_2 \geq 2 \\ & -y_1 - y_2 \geq -1 \\ & y_1, y_2 \geq 0 \end{array}$

Exercício 45. Considere a PL

$$\begin{array}{ll} \max & a_1x_1 + a_2x_2 \\ \text{sujeito a} & \begin{pmatrix} 1 & -3 \\ -1 & 3 \end{pmatrix} \mathbf{x} \geq \begin{pmatrix} -2 \\ 3 \end{pmatrix} \\ & \mathbf{x} \text{ livre.} \end{array}$$

- (i) Mostre que é inviável.
- (ii) Escreva sua dual.
- (iii) Ache todos os valores de a_1 e a_2 tais que a dual seja (1) viável (2) inviável (3) viável e ilimitada.
- (iv) A dual pode ser viável e limitada?

3.7 Folgas complementares

Considere a programação linear

$$(P) \quad \begin{array}{ll} \max & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} & \mathbf{Ax} \leq \mathbf{b} \\ & \mathbf{x} \geq 0. \end{array}$$

cuja dual é

$$(D) \quad \begin{array}{ll} \min & \mathbf{b}^T \mathbf{y} \\ \text{sujeito a} & \mathbf{A}^T \mathbf{y} \geq \mathbf{c} \\ & \mathbf{y} \geq 0. \end{array}$$

Suponha que adicionemos a (P) variáveis que representem as diferenças de $\mathbf{Ax}$ para $\mathbf{b}$. Ou seja, as **folgas**. Seja $\mathbf{u}$ o vetor que contém tais variáveis. Teremos então

$$(P) \quad \begin{array}{ll} \max & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} & \mathbf{Ax} + \mathbf{u} = \mathbf{b} \\ & \mathbf{x}, \mathbf{u} \geq 0. \end{array}$$

Sejam agora $\mathbf{x}$ e $\mathbf{y}$ soluções viáveis para o par primal-dual, e $\mathbf{u}$ as variáveis de folga correspondentes a $\mathbf{x}$. Segue que

$$\begin{aligned} \mathbf{y}^T \mathbf{b} &= \mathbf{y}^T (\mathbf{Ax} + \mathbf{u}) \\ &= (\mathbf{y}^T \mathbf{A}) \mathbf{x} + \mathbf{y}^T \mathbf{u} \\ &\geq \mathbf{c}^T \mathbf{x} + \mathbf{y}^T \mathbf{u}. \end{aligned}$$

Esta última desigualdade segue do fato que $\mathbf{x} \geq 0$ e $\mathbf{y}^T \mathbf{A} \geq \mathbf{c}^T$.

Suponha agora que $\mathbf{x}$ e $\mathbf{y}$ fossem soluções ótimas. Então pelo Teorema Forte da Dualidade, temos $\mathbf{y}^T \mathbf{b} = \mathbf{c}^T \mathbf{x}$. Logo

$$\mathbf{y}^T \mathbf{u} \leq 0.$$

Como ambos os vetores são não-negativos, isso só é possível se, para cada índice i , ou $\mathbf{y}_i = 0$ ou $\mathbf{u}_i = 0$. Toda essa análise serve também para o dual, e independe da forma em que a PL é apresentada.

Soluções viáveis $\mathbf{x}$ e $\mathbf{y}$ para um par primal-dual de PLs (P) e (D) satisfazem as **condições das folgas complementares** se

- Ou $\mathbf{x}_j = 0$, ou a j -ésima restrição de (D) é satisfeita com igualdade.

- Ou $y_i = 0$, ou a i -ésima restrição de (P) é satisfeita com igualdade.

Vimos que se $\mathbf{x}$ e $\mathbf{y}$ são ótimas, essas condições são satisfeitas. O converso também é verdadeiro, ou seja...

Teorema 9 (Teorema das Folgas Complementares). *Dado um par primal-dual (P) e (D) de PLs, e soluções viáveis $\mathbf{x}$ e $\mathbf{y}$, então $\mathbf{x}$ e $\mathbf{y}$ são ótimas se, e somente se, as condições de folgas complementares são satisfeitas.*

Exercício 46. Considere o seguinte par primal-dual

$$(P) \quad \begin{array}{ll} \max & (5 \ 3 \ 5) \mathbf{x} \\ \text{sujeito a} & \begin{pmatrix} 1 & 2 & -1 \\ 3 & 1 & 2 \\ -1 & 1 & 1 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 2 \\ 4 \\ -1 \end{pmatrix} \end{array} \quad \left| \quad \begin{array}{ll} \min & (2 \ 4 \ -1) \mathbf{y} \\ \text{sujeito a} & \begin{pmatrix} 1 & 3 & -1 \\ 2 & 1 & 1 \\ -1 & 2 & 1 \end{pmatrix} \mathbf{y} = \begin{pmatrix} 5 \\ 3 \\ 5 \end{pmatrix} \\ & \mathbf{y} \geq 0 \end{array}$$

Prove que $\mathbf{x} = (1 \ -1 \ 1)$ e $\mathbf{y} = (0 \ 2 \ 1)$ são soluções ótimas de duas maneiras diferentes. Uma usando o Teorema Fraco da Dualidade, e a outra usando o Teorema das Folgas Complementares.

Faça o mesmo para o par

$$(P) \quad \begin{array}{ll} \max & (12 \ 26 \ 20) \mathbf{x} \\ \text{sujeito a} & \begin{pmatrix} 1 & 2 & 1 \\ 4 & 6 & 5 \\ 2 & -1 & -3 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} -1 \\ 2 \\ 13 \end{pmatrix} \\ & x_1, x_3 \geq 0 \end{array} \quad \left| \quad \begin{array}{ll} \min & (-1 \ 2 \ 13) \mathbf{y} \\ \text{sujeito a} & \begin{pmatrix} 1 & 4 & 2 \\ 2 & 6 & -1 \\ 1 & 5 & -3 \end{pmatrix} \mathbf{y} \geq \begin{pmatrix} 12 \\ 26 \\ 20 \end{pmatrix} \\ & y_1, y_2 \geq 0, \end{array}$$

com as soluções $\mathbf{x} = (5 \ -3 \ 0)$ e $\mathbf{y} = (0 \ 4 \ -2)$.

Exercício 47. Suponha que a PL abaixo possua solução viável:

$$\begin{array}{ll} \max & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} & \mathbf{A} \mathbf{x} = \mathbf{b} \end{array}$$

Prove que esta mesma PL possui solução ótima se, e somente se, existe uma combinação linear das linhas de $\mathbf{A}$ que é igual a $\mathbf{c}$.

3.8 Certificados de otimalidade e inviabilidade

Considere o par primal-dual (com a primal em FPI):

$$\begin{array}{ll|ll} \max & \mathbf{c}^T \mathbf{x} & & \min & \mathbf{b}^T \mathbf{y} \\ \text{(P)} \text{ sujeito a} & \mathbf{A}\mathbf{x} = \mathbf{b} & & \text{(D)} \text{ sujeito a} & \mathbf{A}^T \mathbf{y} \geq \mathbf{c} \\ & \mathbf{x} \geq 0 & & & \mathbf{y} \geq 0 \end{array}$$

E relembre o tableau final ótimo:

$$\begin{array}{c|c|c} \mathbf{c}_B^T \mathbf{A}_B^{-1} & \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A} - \mathbf{c}^T & \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{b} \\ \hline \mathbf{A}_B^{-1} & \mathbf{A}_B^{-1} \mathbf{A} & \mathbf{A}_B^{-1} \mathbf{b} \end{array}$$

3.8.1 Certificado de otimalidade

Dada uma solução ótima e viável $\mathbf{z}$, um certificado de otimalidade é um vetor $\mathbf{y}$ tal que

$$\mathbf{y}^T \mathbf{A} \geq \mathbf{c}^T \quad \text{e} \quad \mathbf{y}^T \mathbf{b} = \mathbf{c}^T \mathbf{z}.$$

Seja $\mathbf{y}^T = \mathbf{c}_B^T \mathbf{A}_B^{-1}$, ou seja, a solução dual, ou o vetor definido no canto superior esquerdo do tableau estendido ótimo. No canto superior direito, o valor ótimo da função objetivo $\mathbf{c}^T \mathbf{z} = \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{b} = \mathbf{y}^T \mathbf{b}$, garantindo a segunda condição acima. Também temos que, pelo dual:

$$\begin{aligned} \mathbf{y}^T \mathbf{A} &\geq \mathbf{c}^T \\ \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A} &\geq \mathbf{c}^T \\ \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A} - \mathbf{c}^T &\geq 0 \end{aligned}$$

... que é justamente a condição no tableau ótimo que nos permitiu provar a otimalidade do problema. Temos que $\mathbf{y}^T = \mathbf{c}_B^T \mathbf{A}_B^{-1}$ é tanto a solução ótima do dual quanto um certificado de otimalidade.

3.8.2 Certificado de inviabilidade

Uma PL em FPI é inviável se existir um vetor $\mathbf{y}$ tal que

$$\mathbf{y}^T \mathbf{A} \geq 0 \quad \text{e} \quad \mathbf{y}^T \mathbf{b} < 0.$$

Suponha uma PL inviável em FPI:

$$\begin{array}{ll} \max & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} & \mathbf{A}\mathbf{x} = \mathbf{b} \\ & \mathbf{x} \geq 0 \end{array}$$

Definimos a PL auxiliar como:

$$\begin{array}{ll} \max & (\mathbf{0} \quad -\mathbf{1}) \mathbf{x} \\ \text{sujeito a} & (\mathbf{A} \quad \mathbf{I}) \mathbf{x} = \mathbf{b} \\ & \mathbf{x} \geq 0 \end{array}$$

Ao resolvê-la, obtemos um valor ótimo negativo, indicando inviabilidade. A parte central o tableau ótimo final da PL auxiliar pode ser dividida em duas:

$$\begin{array}{c|c|c|c} \mathbf{c}_B^T \mathbf{A}_B^{-1} & \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A} - (\mathbf{0})^T & \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{I} - (-\mathbf{1})^T & \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{b} \\ \hline \mathbf{A}_B^{-1} & \mathbf{A}_B^{-1} \mathbf{A} & \mathbf{A}_B^{-1} \mathbf{I} & \mathbf{A}_B^{-1} \mathbf{b} \end{array}$$

Temos, no tableau, o valor objetivo $\mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{b} < 0$, ou seja, inviável em relação à PL original. Seja novamente $\mathbf{y}^T = \mathbf{c}_B^T \mathbf{A}_B^{-1}$, o que satisfaz diretamente a condição $\mathbf{y}^T \mathbf{b} < 0$. Como o tableau é ótimo, temos que

$$\begin{array}{l} \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A} - (\mathbf{0})^T \geq 0 \\ \mathbf{y}^T \mathbf{A} \geq 0 \end{array}$$

Assim, temos que a solução ótima da dual da PL auxiliar é um certificado de inviabilidade da PL original.

3.9 Método Simplex Dual

Suponha que você queira resolver a seguinte PL:

$$(P) \quad \begin{array}{ll} \max & (-4 \ -8 \ -9) \mathbf{x} \\ \text{sujeito a} & \begin{pmatrix} 2 & -1 & 5 \\ 3 & -4 & 1 \\ -1 & 0 & -2 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 1 \\ 3 \\ -8 \end{pmatrix} \\ & \mathbf{x} \geq 0. \end{array}$$

cujas dual é:

$$(D) \quad \begin{array}{ll} \min & (1 \ 3 \ -8) \mathbf{y} \\ \text{sujeito a} & \begin{pmatrix} 2 & 3 & -1 \\ -1 & -4 & 0 \\ 5 & 1 & -2 \end{pmatrix} \mathbf{y} \geq \begin{pmatrix} -4 \\ -8 \\ -9 \end{pmatrix} \\ & \mathbf{y} \geq 0. \end{array}$$

Ao escrever a primal em FPI, notaremos um fato inconveniente. A base de variáveis de folga não será viável, pois a última entrada do vetor $\mathbf{b}$ é negativa. Isso significa que primeiro precisaremos escrever a PL auxiliar para decidir se (P) é viável, e então eventualmente achar uma base viável para então colocarmos (P) em forma canônica.

Vamos fazer diferente: vamos montar o tableau original mesmo assim, ainda que a base de variáveis de folga seja inviável:

$$\left(\begin{array}{ccc|ccc|c} 0 & 0 & 0 & 4 & 8 & 9 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 2 & -1 & 5 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 3 & -4 & 1 & 0 & 1 & 0 & 3 \\ 0 & 0 & 1 & -1 & 0 & -2 & 0 & 0 & 1 & -8 \end{array} \right)$$

O tableau está na forma canônica, e nele possuímos uma solução básica $\mathbf{x} = (0 \ 0 \ 0 \ 1 \ 3 \ -8)$ que é inviável, pois $x_6 < 0$. Note porém que o vetor $\mathbf{y} = (0 \ 0 \ 0)$ (encontrado no canto superior esquerdo do tableau estendido) é uma solução viável para o problema dual (o dual original, sem ser em FPI).

Este fato possui uma implicação interessante: o valor da função objetivo para esta solução viável no dual é 0, informação também presente no canto superior direito do tableau. Porém, pelo teorema fraco de dualidade sabemos que toda solução viável para o dual é um limitante superior à toda solução viável do primal, então a solução ótima do primal é menor ou igual a zero neste caso.

Vamos então explorar essa nova informação: será que conseguimos caminhar entre soluções básicas do dual, mantendo a viabilidade no dual, e reduzindo o valor até chegar no ótimo deste problema? Ou seja, aplicar o simplex no dual ao invés do primal?

Conseguimos fazer isso ao modificar a forma como fazemos o pivoteamento: gostaríamos que $\mathbf{c}$ permaneça ≥ 0 (assim as variáveis duais são não negativas), e gostaríamos de mudar o sinal das entradas problemáticas de $\mathbf{b}$. Olhamos então a última linha, onde $\mathbf{b}$ é negativo, e selecionamos a entrada negativa que minimiza

$$\frac{c_i}{-A_{3,i}}.$$

Teremos $i = 1$. Daí fazemos pivoteamento:

$$\left(\begin{array}{ccc|cccc|c} 0 & 0 & 0 & 4 & 8 & 9 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 2 & -1 & 5 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 3 & -4 & 1 & 0 & 1 & 0 & 3 \\ 0 & 0 & 1 & \boxed{-1} & 0 & -2 & 0 & 0 & 1 & -8 \end{array} \right) \rightarrow \left(\begin{array}{ccc|cccc|c} 0 & 0 & 4 & 0 & 8 & 1 & 0 & 0 & 4 & -32 \\ 1 & 0 & 2 & 0 & -1 & 1 & 1 & 0 & 2 & -15 \\ 0 & 1 & 3 & 0 & -4 & -5 & 0 & 1 & 3 & -21 \\ 0 & 0 & -1 & \boxed{1} & 0 & 2 & 0 & 0 & -1 & 8 \end{array} \right)$$

Obtivemos outra solução básica inviável para o primal: $\mathbf{x} = (8 \ 0 \ 0 \ -15 \ -21 \ 0)$. Porém, no registro das operações à esquerda, temos a solução dual viável $\mathbf{y} = (0 \ 0 \ 4)$, e note que o valor desta solução viável é -32, como dado no tableau (confira).

Vamos continuar o processo. Agora duas entradas de $\mathbf{b}$ são negativas. Escolhemos a primeira, e na sua linha, há uma única entrada negativa, no caso será na coluna $i = 3$. Teremos

$$\left(\begin{array}{ccc|cccc|c} 0 & 0 & 4 & 0 & 8 & 1 & 0 & 0 & 4 & -32 \\ 1 & 0 & 2 & 0 & \boxed{-1} & 1 & 1 & 0 & 2 & -15 \\ 0 & 1 & 3 & 0 & -4 & -5 & 0 & 1 & 3 & -21 \\ 0 & 0 & -1 & 1 & 0 & 2 & 0 & 0 & -1 & 8 \end{array} \right) \rightarrow \left(\begin{array}{ccc|cccc|c} 8 & 0 & 20 & 0 & 0 & 9 & 8 & 0 & 20 & -152 \\ -1 & 0 & -2 & 0 & \boxed{1} & -1 & -1 & 0 & -2 & 15 \\ -4 & 1 & -5 & 0 & 0 & -9 & -4 & 1 & -5 & 39 \\ 0 & 0 & -1 & 1 & 0 & 2 & 0 & 0 & -1 & 8 \end{array} \right)$$

Note que agora $\mathbf{b} \geq 0$ e $\mathbf{c}^T \leq 0$, o que faz com que a base das colunas 1, 2 e 5 seja não apenas viável, mas também ótima! Em particular

$$\mathbf{x} = (8 \ 15 \ 0)$$

é ótimo para a primal, e note que no registro de operações realizadas à esquerda, obtivemos um vetor que é também a solução ótima do problema dual:

$$\mathbf{y} = (8 \ 0 \ 20)$$

Observe que o valor da solução ótima do primal é igual ao valor da solução ótima do dual: -152.

Como a PL original estava em forma canônica para a base das últimas três colunas (variáveis de folga), as operações realizadas ao vetor $\mathbf{c}$ também registraram os mesmos valores (poderíamos ter economizado nas contas).

Resumindo, sabemos que B é uma base viável e ótima para uma PL se

(1) $\mathbf{c} \leq 0$ e $\mathbf{c}_B = 0$.

(2) $\mathbf{b} \geq 0$.


A filosofia do simplex (versão primal) é a seguinte:

- (i) Comece com uma base viável, ou seja, satisfazendo (2) acima.
- (ii) Busque uma solução melhor utilizando alguma variável não-básica com custo reduzido positivo.
- (iii) Ao caminhar, mantenha a viabilidade (condição (2)) até que consiga chegar à condição (1), onde não há custo reduzido positivo e consequentemente alcançamos o ótimo.

A filosofia do simplex (versão dual) é a seguinte:

- (i) Comece com uma base “ótima”, mas que não necessariamente seja viável. Uma base ótima é uma em que não há variável não-básica com custo reduzido positivo e que, consequentemente, poderia melhorar a solução primal (em outras palavras, satisfaz a condição (1)). Note que nesta definição não estamos dizendo que ela precisa ser viável!
- (ii) Ele então busca uma solução “mais viável”, ou seja, mais próxima da viabilidade no primal, mantendo a otimalidade da base atual. Em termos duais, isto se traduz em melhorar a solução do dual mantendo-a viável (custos reduzidos todos não positivos).
- (iii) Ao encontrar uma solução viável no dual que satisfaça a condição (2), encontramos também uma solução do primal, e (pelo teorema forte da dualidade) as duas são ótimas dos seus respectivos problemas.

A figura abaixo ilustra a potencial vantagem do Simplex dual sobre o primal: às vezes, é mais fácil “consertar” uma solução inviável, perto da ótima, do que partir do zero no primal. Na figura, as linhas sólidas representam os passos do Simplex primal, e as linhas pontilhadas os passos do Simplex dual. Os círculos em verde representam as bases viáveis e os círculos em laranja representam as bases inviáveis. A seta amarela representa o gradiente da função objetivo (melhor direção a caminhar). Você pode notar que os passos do primal ficam dentro do polígono, e os passos do dual caminham por fora. No exemplo particular dessa figura, apenas um passo no dual foi necessário para atingir a otimalidade (no dual, foram três).



Exercício 48. Resolva a PL

$$\begin{aligned}
 &\min \quad (2 \ 3 \ 4 \ 5) \mathbf{x} \\
 &\text{sujeito a} \quad \begin{pmatrix} 1 & -1 & 1 & -1 \\ 1 & -2 & 3 & -4 \\ 3 & -4 & 5 & -6 \end{pmatrix} \mathbf{x} \geq \begin{pmatrix} 10 \\ 6 \\ 15 \end{pmatrix} \\
 &\mathbf{x} \geq 0.
 \end{aligned}$$

Note que ao colocá-la em FPI, teremos uma situação perfeita para aplicar o método simplex dual.

Exercício 49. Resolva a PL

$$\begin{aligned} \max \quad & (5 \ 4 \ 3) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 2 & 3 & 1 \\ 4 & 1 & 2 \\ 3 & 4 & 2 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 5 \\ 11 \\ 8 \end{pmatrix} \\ & \mathbf{x} \geq 0, \end{aligned}$$

usando o método simplex primal.

Uma vez que sua solução esteja pronta, suponha que você receba uma nova restrição adicional:

$$(1 \ 1 \ 1) \mathbf{x} \leq 1.$$

Qual a maneira mais eficiente de aproveitar a sua solução antiga para achar uma solução para a nova PL?

Exercício 50. Faça o mesmo no exercício 48. Suponha que após resolver a PL, o cliente chega e lhe diz que esqueceu a restrição mais importante, que é

$$x_1 + 2x_2 + 3x_3 - 4x_4 \leq 8.$$

Resolva a nova PL.

3.10 Análise de sensibilidade

Com tudo o que já vimos até agora, podemos compreender como alterações realizadas *a posteriori* na formulação da PL afetam a solução ótima encontrada para o problema original. Para isso, será sempre útil ter a matriz que codifica as operações realizadas pelo simplex para achar a base viável ótima. Como referência, vimos antes que, dada uma base B qualquer, o tableau estendido final obtido para aquela base é dado por:

$$\begin{array}{c|c|c} \mathbf{c}_B^T \mathbf{A}_B^{-1} & \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A} - \mathbf{c}^T & \mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{b} \\ \hline \mathbf{A}_B^{-1} & \mathbf{A}_B^{-1} \mathbf{A} & \mathbf{A}_B^{-1} \mathbf{b} \end{array}$$

Vamos agora estudar como alterações *a posteriori* alteram a solução ótima de uma PL. Observe o seguinte exemplo.

$$\begin{aligned} \max \quad & (1 \ 1) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 0 \\ 2 & 3 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 3 \\ 24 \end{pmatrix} \\ & \mathbf{x} \geq 0. \end{aligned}$$

que possui o seguinte tableau inicial:

$$\left(\begin{array}{cc|ccc|c} 0 & 0 & -1 & -1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 & 3 \\ 0 & 1 & 2 & 3 & 0 & 1 & 24 \end{array} \right)$$

Este caso está apropriado para o método simplex primal. Procedemos:

$$\left(\begin{array}{cc|ccc|c} 1 & 0 & 0 & -1 & 1 & 0 & 3 \\ 1 & 0 & \boxed{1} & 0 & 1 & 0 & 3 \\ -2 & 1 & 0 & 3 & -2 & 1 & 18 \end{array} \right)$$

$$\left(\begin{array}{cc|ccc|c} 1/3 & 1/3 & 0 & 0 & 1/3 & 1/3 & 9 \\ 1 & 0 & 1 & 0 & 1 & 0 & 3 \\ -2/3 & 1/3 & 0 & \boxed{1} & -2/3 & 1/3 & 6 \end{array} \right)$$

O que aprendemos com isso? Várias coisas:

- (i) A base viável ótima é formada por colunas 1 e 2. Isolando essas colunas, podemos calcular....
- (ii) ... a solução ótima, que é tal que

$$\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 3 \\ 6 \end{pmatrix},$$

ou seja, $\mathbf{x}^T = (3 \ 6)$.

- (iii) O valor objetivo é 9.
- (iv) Também calculamos a solução ótima da dual, que está em cima, ao lado esquerdo da barra tripla. De fato, note que $\mathbf{y}^T = (1/3 \ 1/3)$ é uma solução viável para a PL dual

$$(D) \quad \begin{array}{ll} \min & (3 \ 24) \mathbf{y} \\ \text{sujeito a} & \begin{pmatrix} 1 & 2 \\ 0 & 3 \end{pmatrix} \mathbf{y} \geq (1 \ 1) \\ & \mathbf{y} \geq 0, \end{array}$$

com valor objetivo igual a 9.

- (v) Note que as condições de folga complementares são satisfeitas (e não poderia ser diferente). Ambas as soluções não possuem entradas iguais a 0, mas ambas satisfazem suas restrições com igualdade.
- (vi) A matriz 2×2 ao lado esquerdo da barra tripla codifica as operações realizadas na PL. Como vimos anteriormente, ela nada mais é do que a inversa da matriz formada pelas colunas 1 e 2 originais. De fato, note que:

$$\begin{pmatrix} 1 & 0 \\ -2/3 & 1/3 \end{pmatrix} \begin{pmatrix} 1 & 0 & 1 & 0 \\ 2 & 3 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & -2/3 & 1/3 \end{pmatrix},$$

e que

$$\begin{pmatrix} 1 & 0 \\ -2/3 & 1/3 \end{pmatrix} \begin{pmatrix} 3 \\ 24 \end{pmatrix} = \begin{pmatrix} 3 \\ 6 \end{pmatrix}.$$

Este último ponto é extremamente relevante. Suponha que ao término desta resolução, seu cliente lhe informe que na verdade houve um erro, e que as restrições deveriam ter sido

$$x_1 \leq 3 \quad \text{e} \quad 2x_1 + 3x_2 \leq 18.$$

Você então pensa da seguinte forma. “Se eu tivesse realizado as mesmas operações com este vetor, eu teria obtido”

$$\begin{pmatrix} 1 & 0 \\ -2/3 & 1/3 \end{pmatrix} \begin{pmatrix} 3 \\ 18 \end{pmatrix} = \begin{pmatrix} 3 \\ 4 \end{pmatrix}.$$

Ou seja, o tableau final seria

$$\left(\begin{array}{cc|cc|c} 1/3 & 1/3 & 0 & 0 & 1/3 & 1/3 & ? \\ 1 & 0 & 1 & 0 & 1 & 0 & 3 \\ -2/3 & 1/3 & 0 & 1 & -2/3 & 1/3 & 4 \end{array} \right).$$

Este tableau corresponde a uma solução básica e viável, já que $\mathbf{b} \geq 0$, e ótima, já que está na forma canônica com $\mathbf{c} \leq 0$. Ou seja, $\mathbf{x}^T = (3 \ 4)$ é ótima, com valor objetivo $\mathbf{c}^T \mathbf{x} = 7$.

Note que o ótimo do dual não se alterou.

Exercício 51. Determine o menor valor w para que, se $\mathbf{b}^T = (3 \ w)$, a base de colunas 1 e 2 permaneça viável e ótima.

Exercício 52. Como resolver agora se $\mathbf{b}^T = (2 \ 3)$? Dica: use o simplex dual.

Exercício 53. Resolva a PL

$$\begin{array}{ll} \max & (3 \ 2) \mathbf{x} \\ \text{sujeito a} & \begin{pmatrix} 1 & 0 \\ 2 & 1 \\ 1 & 1 \\ 4 & 1 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 4 \\ 11 \\ 9 \\ 17 \end{pmatrix}. \end{array}$$

Após sua resolução, encontre 2 restrições que podem ser eliminadas sem alterar a solução ótima.

Dica: use a dual.

Este último exercício nos mostra que restrições cuja variável dual correspondente na solução ótima é igual a zero podem ser eliminadas sem alteração na solução ótima de PL primal. Dualmente, variáveis que são iguais a zero na solução ótima da PL primal podem ser eliminadas da sua programação sem alteração no valor ótimo.

Note que também podemos olhar isso ao notar quais restrições estão folgadas no problema primal: uma restrição folgada na solução ótima poderia ser descartada do modelo. Porém, note que a solução dual **é mais informativa**: pode ser que tanto a folga quanto a dual correspondente sejam zero, o que continua satisfazendo o teorema das folgas complementares. Se a restrição não for folgada, não podemos afirmar que ela pode ser retirada, mas **se a dual for zero**, então pode ser removida.

Por fim, incluímos mais dois exemplos.

Exemplo 14. Considere a PL dual do exercício anterior (mas agora não pense nela como dual, e sim como uma PL primal):

$$\begin{aligned} \min \quad & (4 \ 11 \ 9 \ 17) \mathbf{y} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 2 & 1 & 4 \\ 0 & 1 & 1 & 1 \end{pmatrix} \mathbf{y} \geq \begin{pmatrix} 3 \\ 2 \end{pmatrix} \\ & \mathbf{y} \geq 0. \end{aligned}$$

Você aplica o simplex nesta PL (de fato: aplique, pratique!), e após sua solução você encontra o tableau

$$\left(\begin{array}{c|cccc|c} & 2 & 0 & 0 & 2 & 2 & 7 & -20 \\ \hline & 1 & 1 & 0 & 3 & -1 & 1 & 1 \\ & -1 & 0 & 1 & -2 & 1 & -2 & 1 \end{array} \right)$$

Note que temos -20 porque estávamos fazendo $\max(-\mathbf{c}^T)\mathbf{y}$ ao invés de $\min \mathbf{c}^T\mathbf{y}$. Tudo funciona igual, mas o valor objetivo fica multiplicado por -1 .

Continuando.... Suponha agora que seu cliente lhe diz: “esqueça a variável y_2 ”. Você fica chateado porque a variável y_2 era básica, mas mesmo assim você a apaga do seu tableau, obtendo:

$$\left(\begin{array}{c|cccc|c} & 2 & 0 & 2 & 2 & 7 & -20 \\ \hline & 1 & 0 & 3 & -1 & 1 & 1 \\ & -1 & 1 & -2 & 1 & -2 & 1 \end{array} \right)$$

Como ajustar agora para acharmos o ótimo?

O problema perdeu uma variável básica. Isto indica também que o dual deste problema (que seria o primal do exemplo anterior!) perdeu uma restrição apertada. Ou seja, o problema dual continua viável, mas não é mais necessariamente ótimo. Vamos então reotimizar o problema através do simplex dual. Para facilitar, vamos começar multiplicando a primeira linha, que perdeu sua variável básica, por -1 :

$$\left(\begin{array}{c|cccc|c} & 2 & 0 & 2 & 2 & 7 & -20 \\ \hline & -1 & 0 & -3 & 1 & -1 & -1 \\ & -1 & 1 & -2 & 1 & -2 & 1 \end{array} \right)$$

Podemos aplicar (como visto anteriormente) o simplex dual escolhendo o mínimo:

$$\frac{\mathbf{c}_i}{-A_{1,i}}.$$

A idéia é sempre fazer a operação de pivoteamento correta que (1) não torna a solução inviável (2) não leva $\mathbf{c}$ a ficar ≤ 0 . No caso, $i = 3$. Teremos então

$$\left(\begin{array}{c|cccc|c} & 4/3 & 0 & 0 & 8/3 & 19/3 & -62/3 \\ \hline & 1/3 & 0 & 1 & -1/3 & 1/3 & 1/3 \\ & -1/3 & 1 & 0 & 1/3 & -8/3 & 5/3 \end{array} \right)$$

Note que este novo tableau é ótimo para a base viável de colunas 2 e 3!

Por último, estudamos o que fazer quando uma variável é adicionada:

Exemplo 15.

$$\begin{aligned} \max \quad & (1 \ 2 \ 7) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 0 & 2 \\ 0 & 1 & 3 \\ -1 & 1 & 0 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 4 \\ 5 \\ 0 \end{pmatrix} \\ & \mathbf{x} \geq 0. \end{aligned}$$

Seu tableau estendido, que registra as operações realizadas, é:

$$\left(\begin{array}{ccc|ccc|c} 0 & 0 & 0 & -1 & -2 & -7 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 2 & 1 & 0 & 0 & 4 \\ 0 & 1 & 0 & 0 & 1 & 3 & 0 & 1 & 0 & 5 \\ 0 & 0 & 1 & -1 & 1 & 0 & 0 & 0 & 1 & 0 \end{array} \right)$$

Que, após sua solução, leva a

$$\left(\begin{array}{ccc|ccc|c} 2 & 1 & 1 & 0 & 0 & 0 & 2 & 1 & 1 & 13 \\ 3 & -2 & 2 & 1 & 0 & 0 & 3 & -2 & 2 & 2 \\ -1 & 1 & -1 & 0 & 0 & 1 & -1 & 1 & -1 & 1 \\ 3 & -2 & 3 & 0 & 1 & 0 & 3 & -2 & 3 & 2 \end{array} \right)$$

Suponha agora que somos informados que uma variável foi omitida da formulação incorretamente. Na verdade, o problema original deveria ter sido:

$$\begin{aligned} \max \quad & (1 \ 2 \ 7 \ 4) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 0 & 2 & 0 \\ 0 & 1 & 3 & 1 \\ -1 & 1 & 0 & 2 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 4 \\ 5 \\ 0 \end{pmatrix} \\ & \mathbf{x} \geq 0. \end{aligned}$$

Como proceder?

Ora, sabemos que após as mesmas operações realizadas originalmente, a coluna correspondente à nova variável será

$$\begin{pmatrix} 3 & -2 & 2 \\ -1 & 1 & -1 \\ 3 & -2 & 3 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 2 \\ -1 \\ 4 \end{pmatrix},$$

e que seu valor no vetor $\mathbf{c}$, dado por $\mathbf{c}_B^T \mathbf{A}_B^{-1} \mathbf{A}_4 - \mathbf{c}^T$ (onde $\mathbf{A}_4$ é a coluna da nova variável x_4), será

$$(2 \ 1 \ 1) \begin{pmatrix} 0 \\ 1 \\ 2 \end{pmatrix} - 4 = -1.$$

Note o -4 devido ao tableau inverter o valor do c_4 original. O tableau então será

$$\left(\begin{array}{ccc|ccc|c} 2 & 1 & 1 & 0 & 0 & 0 & -1 & 2 & 1 & 1 & 13 \\ 3 & -2 & 2 & 1 & 0 & 0 & 2 & 3 & -2 & 2 & 2 \\ -1 & 1 & -1 & 0 & 0 & 1 & -1 & -1 & 1 & -1 & 1 \\ 3 & -2 & 3 & 0 & 1 & 0 & 4 & 3 & -2 & 3 & 2 \end{array} \right)$$

Então neste caso, basta aplicarmos o pivoteamento do simplex primal:

$$\left(\begin{array}{ccc|ccc|ccc|c} 2 & 1 & 1 & 0 & 0 & 0 & -1 & 2 & 1 & 1 & 13 \\ 3 & -2 & 2 & 1 & 0 & 0 & 2 & 3 & -2 & 2 & 2 \\ -1 & 1 & -1 & 0 & 0 & 1 & -1 & -1 & 1 & -1 & 1 \\ 3 & -2 & 3 & 0 & 1 & 0 & \boxed{4} & 3 & -2 & 3 & 2 \end{array} \right)$$

levando a

$$\left(\begin{array}{ccc|ccc|ccc|c} 11/4 & 1/2 & 7/4 & 0 & 1/4 & 0 & 0 & 11/4 & 1/2 & 7/4 & 27/2 \\ 3/2 & -1 & 1/2 & 1 & -1/2 & 0 & 0 & 3/2 & -1 & 1/2 & 1 \\ -1/4 & 1/2 & -1/4 & 0 & 1/4 & 1 & 0 & -1/4 & 1/2 & -1/4 & 3/2 \\ 3/4 & -1/2 & 3/4 & 0 & 1/4 & 0 & 1 & 3/4 & -1/2 & 3/4 & 1/2 \end{array} \right)$$

Resumindo: esteja confortável com o método simplex primal e dual. E então....

- (i) Ao adicionarmos uma restrição após a solução: (1) eliminação Gaussiana para que a nova PL permaneça na base antiga (2) aplicar o simplex dual para achar uma nova base viável.
- (ii) Variação no vetor **b**: aplica a matriz de operações ao novo vetor **b**. Se viável, maravilha. Se não, simplex dual.
- (iii) Para remover restrições, cheque as entradas iguais a 0 na solução dual ótima.
- (iv) Para remover variáveis: se for não-básica, nada muda, apenas remove. Se for básica, remove, e aplica uma espécie de simplex dual na linha correspondente com o sinal invertido.
- (v) Para adicionar variáveis: aplica no vetor correspondente a matriz de operações da solução, incluindo as mudanças na entrada de **c**. Se não estiver ótima, aplica-se o simplex primal.

Exercício 54. Explique como adaptar a solução de uma PL se houver uma mudança na função objetivo.

3.11 Teoria de jogos

Nesta aula vamos dar um gostinho de teoria de jogos, e mostrar uma aplicação clássica do Teorema Forte da Dualidade.

Aqui vamos tentar formalizar a definição de um jogo. Vamos começar com pedra-papel-tesoura. Em cada rodada, dois jogadores fazem escolhas independentes, e a comparação das estratégias escolhidas define o resultado. Pedra-papel-tesoura é um jogo de soma zero: se jogador *A* ganha, jogador *B* perde, ou vice-versa. Não há como ambos ganharem ou ambos perderem. Um jogo como este pode ser formalizado como uma matriz:

	Pedra	Papel	Tesoura
Pedra	0	-1	1
Papel	1	0	-1
Tesoura	-1	1	0

Esta matriz $\mathbf{M}$ representa a pontuação recebida pelo jogador A , onde sua escolha é a linha, e a escolha de B é a coluna. Como este é um jogo de soma 0, a matriz que indica a pontuação de B é exatamente -1 vezes a transposta da matriz acima: se A ganha -1 em a_{12} , então B ganha 1 em a_{12} , etc.

Suponha que A e B fazem suas escolhas seguindo uma certa probabilidade. Por exemplo, A pode escolher $\mathbf{x} = (1/2, 1/4, 1/4)$, indicando que em 50% dos casos ele escolhe pedra, e os outros 50% ele divide igualmente entre papel e tesoura. Já B pode fazer $\mathbf{y} = (1/3, 1/3, 1/3)$, ou seja, mesma chance pra todos. Com essas escolhas feitas, podemos calcular o valor esperado do jogo para A :

$$\sum_{i=1}^3 \sum_{j=1}^3 \mathbf{x}_i \mathbf{y}_j m_{ij} \quad , \text{ que é igual a } \mathbf{x}^T \mathbf{M} \mathbf{y}.$$

O negativo deste valor é o valor esperado para B . Ou seja, A ganha

$$\mathbf{x}^T \mathbf{M} \mathbf{y} = 0.$$

E portanto B também ganharia 0. Por outro lado, se as escolhas tivessem sido $\mathbf{x} = (1, 0, 0)$ e $\mathbf{y} = (0, 0, 1)$, então

$$\mathbf{x}^T \mathbf{M} \mathbf{y} = 1,$$

indicando que A ganharia sempre $+1$, e B ganharia sempre -1 (o que é de se esperar, já que A estaria garantindo que escolheria sempre pedra, e B escolheria sempre tesoura).

3.11.1 Estratégias

Imagine agora a situação em que A e B jogam, mas A anuncia sua estratégia probabilística antes do jogo para B . Será que isso dá alguma vantagem a B ?

- A resposta é que depende da estratégia. Por exemplo, se A anuncia $\mathbf{x} = (1, 0, 0)$, então B sabiamente escolheria $\mathbf{y} = (0, 1, 0)$ para ganhar. Mas note que se A escolher $\mathbf{x} = (1/3, 1/3, 1/3)$, então não importa o que B faça, A vai acabar sorteando independentemente a sua escolha. Ou seja, há uma escolha de probabilidades para A que, mesmo que B tenha acesso a ela de antemão, ele não ganha qualquer vantagem.

Imagine agora outro jogo, chamado “Exemplo da Wikipedia”. Neste jogo, A tem duas escolhas, e B tem três. A matriz que quantifica o pagamento para A a partir das combinações é a seguinte:

	1	2	3
1	30	-10	20
2	-10	20	-20

Aí A pensa assim: “se eu escolher 2, eu posso até ganhar 20, mas aí eu perco 10 ou 20, nas outras possibilidades. Por outro lado, escolher 1 me dá chance de ganhar 30 ou 20, e eu só perderia 10. Então vou escolher 1.” Mas aí B se liga nisso e escolheria 2. Então A se toca que B pensaria assim, e na verdade escolhe 2 pra surpreender B . B que não é besta imagina que A pensaria nisso, e aí pega 3 pra ganhar 20 de A . E assim sucessivamente.... Qual a melhor estratégia?

- B decide então tomar uma atitude drástica: ele vai deixar que a sorte escolha. Mas não totalmente. Ele escolhe as probabilidades. Após muito refletir, B decide que $\mathbf{y} = (0, 1/2, 1/2)$ parece razoável. E se sentindo confiante, decide avisar a A de antemão que é assim que ele

vai agir. O que A deveria fazer? Ora, A agora vai escolher sua probabilidade, ou seja, A escolhe $\mathbf{x} = (x_1, x_2)$, com $x_1 + x_2 = 1$, e o ganho final do jogo para A será

$$(x_1 \ x_2) \begin{pmatrix} 30 & -10 & 20 \\ -10 & 20 & -20 \end{pmatrix} \begin{pmatrix} 0 \\ 1/2 \\ 1/2 \end{pmatrix} = (x_1 \ x_2) \begin{pmatrix} 5 \\ 0 \end{pmatrix} = 5x_1.$$

Ou seja, sabendo das probabilidades de B , A vai sempre escolher 1, e maximizará assim sua esperança de ganho. B , se sentindo injustiçado, decide jogar de novo. Mas dessa vez, ele quer forçar A a escolher suas probabilidades antes e anunciá-las. O que acontece?

- A , que não é besta manda pra B a seguinte escolha de probabilidades: $\mathbf{x} = (4/7, 3/7)$. B vai lá fazer suas continhas, pra achar $\mathbf{y} = (y_1, y_2, y_3)$, com $y_1 + y_2 + y_3 = 1$. Daí temos

$$(4/7 \ 3/7) \begin{pmatrix} 30 & -10 & 20 \\ -10 & 20 & -20 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix} = (90/7 \ 20/7 \ 20/7) \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix} = \frac{90}{7}y_1 + \frac{20}{7}y_2 + \frac{20}{7}y_3.$$

Ou seja, não importa o que B fizer, a esperança de ganho para A será pelo menos $20/7$!

Exercício 55. Suponha que em um dado jogo, a melhor estratégia probabilística para Alice é o vetor $\mathbf{x}$, e que

$$\mathbf{x}^T \mathbf{M} = (-1 \ 2 \ 3 \ -2 \ 0).$$

Qual a estratégia ótima para Bob?

3.11.2 Teorema Minimax

Não foi surpresa alguma que no jogo anterior A foi capaz de ganhar *mesmo* tendo que anunciar sua estratégia probabilística de antemão. A verdade é que: *não importa!!!*

Seja $\mathbf{M}$ a matriz do problema que dá os ganhos de A . Vamos formular o problema supondo que A vai mandar sua distribuição para B . O jogador A sabe que B calculará $\mathbf{x}^T \mathbf{M}$ e escolherá a menor entrada deste vetor para concentrar suas probabilidades. No exemplo acima, A ganhou porque a menor entrada deste vetor era positiva, igual a $20/7$. Portanto A deseja maximizar a menor entrada de $\mathbf{x}^T \mathbf{M}$. Formulamos este problema como uma PL usando uma variável extra $\ell \in \mathbb{R}$, da seguinte forma:

$$\begin{aligned} \max \quad & \ell \\ \text{sujeito a} \quad & \ell \leq 30x_1 - 10x_2 \\ & \ell \leq -10x_1 + 20x_2 \\ & \ell \leq 20x_1 - 20x_2 \\ & x_1 + x_2 = 1 \\ & \mathbf{x} \geq 0. \end{aligned}$$

Utilizando notação matricial e reordenando os termos, temos a PL:

$$\begin{aligned}
& \max \quad \ell \\
& \text{sujeito a} \quad \mathbf{M}^T \mathbf{x} - \ell \mathbf{1} \geq 0 \\
& \quad \mathbf{1}^T \mathbf{x} = 1 \\
& \quad \mathbf{x} \geq 0.
\end{aligned}$$

onde $\mathbf{1}$ é um vetor de 1's de dimensão apropriada.

Equivalentemente, se for B o primeiro a escolher as probabilidades, B estará resolvendo a PL

$$\begin{aligned}
& \min \quad \omega \\
& \text{sujeito a} \quad \omega \geq 30y_1 - 10y_2 + 20y_3 \\
& \quad \omega \geq -10y_1 + 20y_2 - 20y_3 \\
& \quad y_1 + y_2 + y_3 = 1 \\
& \quad \mathbf{y} \geq 0.
\end{aligned}$$

que em notação matricial pode ser escrita como:

$$\begin{aligned}
& \min \quad \omega \\
& \text{sujeito a} \quad \mathbf{M}\mathbf{y} - \omega \mathbf{1} \leq 0 \\
& \quad \mathbf{1}^T \mathbf{y} = 1 \\
& \quad \mathbf{y} \geq 0.
\end{aligned}$$

Não coincidentemente, as duas PLs acima são duais uma da outra! De fato, seja $\mathbf{x}'^T = (\mathbf{x}^T \ \ell)$, $\mathbf{y}'^T = (\mathbf{y}^T \ \omega)$, e seja

$$\mathbf{N} = \begin{pmatrix} \mathbf{M}^T & -\mathbf{1} \\ \mathbf{1}^T & 0 \end{pmatrix}.$$

Então a primeira PL é

$$\begin{aligned}
& \max \quad (0 \ 0 \ \dots \ 0 \ 1) \begin{pmatrix} \mathbf{x} \\ \ell \end{pmatrix} \\
& \text{sujeito a} \quad \begin{pmatrix} \mathbf{M}^T & -\mathbf{1} \\ \mathbf{1}^T & 0 \end{pmatrix} \begin{pmatrix} \mathbf{x} \\ \ell \end{pmatrix} \begin{matrix} \geq \\ \geq \\ \geq \\ \vdots \\ \geq \\ \geq \\ = \end{matrix} \begin{pmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 0 \\ 0 \\ 1 \end{pmatrix} \\
& \quad \mathbf{x} \geq 0.
\end{aligned}$$

Sua dual será

$$\begin{aligned} \min \quad & (0 \ 0 \ \dots \ 0 \ 1) \begin{pmatrix} \mathbf{y} \\ \omega \end{pmatrix} \\ \text{sujeito a} \quad & \begin{pmatrix} \mathbf{M} & \mathbf{1} \\ -\mathbf{1}^T & 0 \end{pmatrix} \begin{pmatrix} \mathbf{y} \\ \omega \end{pmatrix} \begin{matrix} \geq \\ \geq \\ \vdots \\ \geq \\ = \end{matrix} \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ 1 \end{pmatrix} \\ & \mathbf{y} \leq 0. \end{aligned}$$

Trocando $\mathbf{y}$ por $-\mathbf{z}$, teremos exatamente a formulação

$$\begin{aligned} \min \quad & (0 \ 0 \ \dots \ 0 \ 1) \begin{pmatrix} -\mathbf{z} \\ \omega \end{pmatrix} \\ \text{sujeito a} \quad & \begin{pmatrix} \mathbf{M} & -\mathbf{1} \\ \mathbf{1}^T & 0 \end{pmatrix} \begin{pmatrix} \mathbf{z} \\ \omega \end{pmatrix} \begin{matrix} \leq \\ \leq \\ \vdots \\ \leq \\ = \end{matrix} \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ 1 \end{pmatrix} \\ & \mathbf{z} \geq 0. \end{aligned}$$

Conclusão?

Teorema 10 (von Neumann). *Em um jogo de soma zero entre duas pessoas, o valor máximo do ganho esperado mínimo de um jogador é IGUAL ao valor mínimo da perda esperada máxima do outro jogador. Ademais, cada jogador possui uma estratégia probabilística que satisfaz esta igualdade. Ou seja*

$$\max_{\mathbf{x}} \left(\min_{\mathbf{y}} \mathbf{x}^T A \mathbf{y} \right) = \min_{\mathbf{y}} \left(\max_{\mathbf{x}} \mathbf{x}^T A \mathbf{y} \right).$$

O valor descrito no teorema acima é o famoso equilíbrio de Nash do jogo. John Nash publicou este teorema em sua tese de doutorado, e este trabalho lhe rendeu o Prêmio Nobel de Economia em 1994.

Exercício 56. Considere o seguinte jogo. Alice e Bob decidem que a cor azul vale 10 reais, e que a cor verde vale 6 reais. Cada um deles escolhe uma cor. Se derem iguais, Bob paga a Alice o valor somado das duas cores (16). Se der diferente, Alice paga a Bob duas vezes o valor da cor que ela escolheu (20 ou 12).

- (i) Este jogo é melhor pra quem? Calcule o equilíbrio de Nash.
- (ii) Há alguma escolha de valores para as cores em que este jogo se torna justo?

3.12 Interpretação econômica

Considere a seguinte situação. Uma indústria X produz n produtos, e cada produto i dá um lucro de $\mathbf{c}_i$. Para produzir estes produtos, a empresa usa m recursos, e há um máximo de $\mathbf{b}_j$ para cada recurso j . Finalmente, se usa A_{ji} quantidades do recurso j para produzir o produto i .

A pergunta, naturalmente, é quanto produzir de cada produto para maximizar o lucro total? Agrupando esses dados em vetores e matrizes, temos naturalmente a programação linear:

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{A}\mathbf{x} \leq \mathbf{b} \\ & \mathbf{x} \geq 0. \end{aligned}$$

Vamos agora ver um exemplo do significado do dual. Suponha que até então esta empresa era um monopólio, e adquiria os recursos a um preço muito baixo do único produtor Z .

Uma segunda indústria Y , mais poderosa talvez, deseja entrar no mercado. Após sucessivas tentativas frustradas de comprar a indústria X , ela decide eliminá-la secando a fonte dela, ou seja, comprando todos os recursos disponíveis de Z . Como estabelecer uma proposta de preços para cada recurso de modo a minimizar o custo total, porém de modo que a oferta a Z seja irrecusável?

A empresa Y pensa assim. Para cada recurso j , com j de 1 a m , vamos propor o preço de $\mathbf{y}_m$. Queremos minimizar o custo da compra de todos os recursos, ou seja

$$\min \mathbf{b}^T \mathbf{y}.$$

Para que nossa oferta a Z seja irrecusável, vamos oferecer um preço que cubra o que o X jamais conseguiria ganhar com a venda de seus produtos. Dessa forma, Z pensará que mesmo que X reformule sua produção, nossa oferta ainda será superior. Note que, com a produção de uma unidade do produto i , X gasta

$$\sum_{j=1}^m A_{ji}$$

recursos. Cada uma dessas unidades rende a X um lucro de $\mathbf{c}_i$. Então vamos colocar preços de modo que ao comprar a mesma quantidade de recursos, Z receba pelo menos o que X receberia na venda do produto, ou seja

$$\sum_{j=1}^m A_{ji} \mathbf{y}_j \geq \mathbf{c}_i.$$

Juntando todas elas para cada produto, temos exatamente

$$\mathbf{A}^T \mathbf{y} \geq \mathbf{c}.$$

Obviamente, os preços, devem ser não-negativos, e então aparece a formulação:

$$\begin{aligned} \min \quad & \mathbf{b}^T \mathbf{y} \\ \text{sujeito a} \quad & \mathbf{A}^T \mathbf{y} \geq \mathbf{c} \\ & \mathbf{y} \geq 0. \end{aligned}$$

Esta é precisamente a PL dual. O mais impressionante, talvez, é que por conta do Teorema da Dualidade, a solução ótima para Y é exatamente o máximo que X conseguiria vender. Nem mais, nem menos.

A idéia aqui, obviamente, é limitada no sentido em que preços no mundo real não são determinados de modo tão simples. Este modelo ignora a existência de outros fatores, como demais concorrentes ou outros fornecedores de recursos. Mas ele estabelece uma idéia importante: a de que dado um certo processo de produção, os recursos usados possuem um preço inerente somente ao processo, também chamado de preço interno ou “shadow price”.

E as condições de folga complementares, o que diriam? Nesta lógica, se um determinado recurso não é completamente usado por X , então Y pode oferecer qualquer valor a Z pelo excedente. Em certo sentido, Z estaria disposta a até mesmo dar de graça para poder fechar o negócio. Nessa lógica, a variável correspondente em y é 0.

Note também que uma pequena variação na quantidade disponível de cada recurso provavelmente não alterará o preço deste recurso. De fato, como vimos, alterações no vetor b podem, muitas vezes, não alterar o processo de solução no simplex. Ou seja, a solução dual permanece a mesma!

Considere agora o seguinte problema.

Exercício 57. Um estudante está decidindo o que comprar de uma padaria para um lanche. Há duas opções: brownies e cheesecakes, ao preço de 5 ou 8 reais, respectivamente (é possível comprar frações do lanche). A padaria usa 100 gramas de chocolate no cheesecake, 60g de açúcar no brownie e 120g no cheesecake, e 60g de creme no brownie e 150g no cheesecake. O estudante, seguindo a dieta do nutricionista, quer no mínimo 180g de chocolate, 300g de açúcar e 240g de creme. O objetivo, naturalmente, é gastar o mínimo possível.

- (a) Formule a PL correspondente.
- (b) Imagine agora que você é o distribuidor que vende à padaria chocolate, açúcar e creme. A padaria te informa precisamente o mínimo de cada ingrediente que ela precisa comprar para satisfazer o estudante, assim como quanto é gasto em cada lanche. Explique a interpretação econômica de dualidade, ou seja, qual a lógica do distribuidor para realizar essa venda, e como a PL dual captura isso?
- (c) Usando as condições de folga complementares, explique qual seria a lógica se uma das variáveis na solução ótima da dual for zero, ou seja, o que explicaria o distribuidor vender algo de graça a padaria?

Capítulo 4

Geometria e teorema de alternativas

4.1 Geometria de poliedros

Dado um vetor $\mathbf{a} \in \mathbb{R}^n$, o conjunto de vetores $\mathbf{x}$ que satisfaz

$$\mathbf{a}^T \mathbf{x} = 0$$

é um hiperplano, ou seja, um subespaço de $\mathbb{R}^n$ de dimensão $n - 1$. O vetor $\mathbf{a}$ é o vetor diretor do hiperplano, ortogonal a todos os vetores que lá se encontram. Ao trocarmos $=$ por $\leq$ ou $\geq$, passamos a considerar a metade do $\mathbb{R}^n$ que se encontra de um lado ou de outro do hiperplano. Por exemplo, o conjunto dos $\mathbf{x}$ tais que

$$\mathbf{a}^T \mathbf{x} \geq 0$$

é o conjunto de todos os vetores $\mathbf{x}$ tais que o ângulo entre $\mathbf{x}$ e $\mathbf{a}$ está entre 0 e $\pi/2$. Tais conjuntos são chamados de hiperespaços. Ao adicionarmos uma constante, por exemplo

$$\mathbf{a}^T \mathbf{x} \geq \beta,$$

estamos apenas transladando o hiperplano que serve de fronteira entre o hiperespaço e o seu complemento.

As restrições lineares de uma PL sempre são da forma

$$\mathbf{a}^T \mathbf{x} \leq \beta \quad \text{ou} \quad \mathbf{a}^T \mathbf{x} = \beta \quad \text{ou} \quad \mathbf{a}^T \mathbf{x} \geq \beta.$$

Note que $\mathbf{a}^T \mathbf{x} \geq \beta$ é equivalente a $(-\mathbf{a}^T) \mathbf{x} \leq -\beta$, e que $\mathbf{a}^T \mathbf{x} = \beta$ é equivalente a simultaneamente termos $\mathbf{a}^T \mathbf{x} \leq \beta$ e $(-\mathbf{a}^T) \mathbf{x} \leq -\beta$. Portanto as restrições de uma PL sempre podem ser expressas usando $\leq$, e ao juntarmos todas elas, teremos

$$\mathbf{A} \mathbf{x} \leq \mathbf{b} \tag{*}$$

para uma certa matriz $\mathbf{A}$ e um vetor $\mathbf{b}$. Conjuntos de vetores $\mathbf{x}$ satisfazendo (*) são chamados de poliedros. Todo poliedro é uma interseção finita de hiperespaços.

Toda PL consiste em otimizar uma função afim (linear adicionada de uma possível constante) em um poliedro.

Dados dois pontos $\mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^n$, o segmento de reta entre eles pode ser expresso como

$$\mathbf{x} \in \mathbb{R}^n : \mathbf{x} = \lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2 \text{ com } 0 \leq \lambda \leq 1.$$

Um conjunto C de pontos é chamado de convexo se para quaisquer dois pontos no conjunto, o segmento de reta entre eles também pertence ao conjunto.

Teorema 11. *Poliedros são convexos.*

Demonstração. Sejam $\mathbf{x}_1$ e $\mathbf{x}_2$ pontos satisfazendo $\mathbf{Ax} \leq \mathbf{b}$. Daí teremos que, para todo λ tal que $0 \leq \lambda \leq 1$,

$$\mathbf{A}(\lambda\mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2) \leq \lambda\mathbf{b} + (1 - \lambda)\mathbf{b} = \mathbf{b}.$$

□

Exercício 58. A reta entre dois pontos $\mathbf{x}_1$ e $\mathbf{x}_2$ é definida como

$$\mathbf{x} \in \mathbb{R}^n : \mathbf{x} = \lambda\mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2 \text{ com } \lambda \in \mathbb{R}.$$

Por que não podemos usar a demonstração acima para mostrar que a reta entre dois pontos de um poliedro está sempre contida no poliedro?

Um ponto $\mathbf{x}$ em um poliedro P é chamado de ponto extremo se não há qualquer segmento em P que tenha $\mathbf{x}$ como um ponto em seu interior. É interessante notar que se um ponto $\mathbf{x}$ não é extremo, então ele não pode ser a única solução ótima de uma PL.

Exercício 59. Suponha que estamos maximizando $\mathbf{c}^T \mathbf{x}$, com $\mathbf{Ax} \leq \mathbf{b}$. Assuma que $\mathbf{z}_1$ e $\mathbf{z}_2$ são soluções viáveis. Seja $\mathbf{z} = \lambda\mathbf{z}_1 + (1 - \lambda)\mathbf{z}_2$, com λ entre 0 e 1. Mostre que o valor objetivo de $\mathbf{z}$ não pode ser estritamente maior que ambos os valores objetivos de $\mathbf{z}_1$ e $\mathbf{z}_2$, e que se $\mathbf{z}_1$ e $\mathbf{z}_2$ são soluções ótimas, então $\mathbf{z}$ também é.

Nosso objetivo agora é entender como podemos identificar os pontos extremos de um poliedro olhando apenas para o conjunto de desigualdades $\mathbf{Ax} \leq \mathbf{b}$ que o define. Se $\mathbf{x}_1$ é um ponto específico que satisfaz essas desigualdades, definimos como $\mathbf{A}^=$ a matriz associada a $\mathbf{x}_1$ que contempla todas as linhas em que a inequação é uma igualdade, e analogamente $\mathbf{b}^=$. Ou seja, $\mathbf{A}^=\mathbf{x}_1 = \mathbf{b}^=$.


Teorema 12. *Seja $P = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{Ax} \leq \mathbf{b}\}$ um poliedro, e suponha que $\mathbf{x}_1 \in P$. Seja $\mathbf{A}^=\mathbf{x}_1 = \mathbf{b}^=$ o conjunto de restrições com igualdade para $\mathbf{x}_1$. Então $\mathbf{x}_1$ é um ponto extremo de P se, e somente se, o posto de $\mathbf{A}^=$ é igual a n .*

Antes da demonstração, vamos ver um exemplo.

Exemplo 16. Considere o poliedro definido por

$$\begin{pmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \\ -1 & 0 \\ 0 & -1 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 3 \\ 2 \\ 2 \\ 0 \\ 0 \end{pmatrix},$$

cujas região correspondente no $\mathbb{R}^2$ é dada por



Pegamos por exemplo o ponto $\mathbf{x} = (1 \ 1)$. Segue que

$$\mathbf{Ax} = \begin{pmatrix} 2 \\ 1 \\ 1 \\ -1 \\ -1 \end{pmatrix} \leq \begin{pmatrix} 3 \\ 2 \\ 2 \\ 0 \\ 0 \end{pmatrix},$$

e portanto nenhuma das linhas corresponde a uma restrição com igualdade. Segue que $\mathbf{A}^=$ é a matriz vazia, de posto 0, e $\mathbf{x}$ não é ponto extremo.

Considere agora $\mathbf{x} = (1 \ 0)$. Teremos

$$\mathbf{Ax} = \begin{pmatrix} 1 \\ 1 \\ 0 \\ -1 \\ 0 \end{pmatrix} \leq \begin{pmatrix} 3 \\ 2 \\ 2 \\ 0 \\ 0 \end{pmatrix},$$

portanto a última linha é uma restrição com igualdade, e $\mathbf{A}^= = (0 \ -1)$ e $\mathbf{b}^= = (0)$. Como o posto de $\mathbf{A}^=$ é igual a 1, e não 2, este ponto $\mathbf{x}$ não é um ponto extremo.

Considere agora $\mathbf{x} = (2 \ 1)$. Segue que

$$\mathbf{Ax} = \begin{pmatrix} 3 \\ 2 \\ 1 \\ -2 \\ -1 \end{pmatrix} \leq \begin{pmatrix} 3 \\ 2 \\ 2 \\ 0 \\ 0 \end{pmatrix},$$

portanto as duas primeiras linhas são restrições com igualdade, e daí teremos

$$\mathbf{A}^= = \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix} \text{ e } \mathbf{b}^= = \begin{pmatrix} 3 \\ 2 \end{pmatrix}.$$

Como o posto de $\mathbf{A}^=$ é 2, este ponto $\mathbf{x}$ é um ponto extremo.

Apresentamos a demonstração do teorema.

Demonstração. Suponha que o posto de $\mathbf{A}^=$ é n , e suponha por contradição que $\mathbf{x}$ não é ponto extremo, logo existem $\mathbf{x}_1$ e $\mathbf{x}_2$ distintos, e um λ entre 0 e 1, tais que $\mathbf{x} = \lambda\mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2$. Segue que

$$\mathbf{b}^= = \mathbf{A}^=\mathbf{x} = \mathbf{A}^=(\lambda\mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2) \leq \lambda\mathbf{b}^= + (1 - \lambda)\mathbf{b}^= = \mathbf{b}^=.$$

Portanto o sinal de desigualdade é uma igualdade, e daí segue que

$$\mathbf{A}^=\mathbf{x}_1 = \mathbf{A}^=\mathbf{x}_2 = \mathbf{b}^=,$$

logo $\mathbf{A}^=(\mathbf{x}_1 - \mathbf{x}_2) = \mathbf{0}$, uma contradição ao fato de que $\mathbf{A}^=$ tem posto n .

Suponha agora que o posto de $\mathbf{A}^=$ seja menor que n , e portanto existe um vetor $\mathbf{d} \neq \mathbf{0}$ tal que $\mathbf{A}^=\mathbf{d} = \mathbf{0}$. Para todo $\epsilon > 0$, segue que $\mathbf{x}$ é ponto médio entre $\mathbf{x}_1 = \mathbf{x} + \epsilon\mathbf{d}$ e $\mathbf{x}_2 = \mathbf{x} - \epsilon\mathbf{d}$. Vamos mostrar agora que tanto $\mathbf{x}_1$ como $\mathbf{x}_2$ estão em P . Note primeiro que $\mathbf{A}^=\mathbf{x}_1 = \mathbf{A}^=\mathbf{x}_2 = \mathbf{b}^=$, já que $\mathbf{A}^=\mathbf{d} = \mathbf{0}$.

As únicas desigualdades em $\mathbf{A}\mathbf{x}_1 \leq \mathbf{b}$ e $\mathbf{A}\mathbf{x}_2 \leq \mathbf{b}$ que faltam ser testadas são aquelas em que $\mathbf{A}\mathbf{x} \leq \mathbf{b}$ ocorria como desigualdade estrita - nestes casos, pode haver uma desigualdade tal que $\mathbf{a}^T(\mathbf{x}_1 + \epsilon\mathbf{d}) > b$ ou $\mathbf{a}^T(\mathbf{x}_1 - \epsilon\mathbf{d}) > b$. Porém, neste caso, basta escolhermos ϵ pequeno o suficiente para que nenhuma desigualdade estrita seja violada, isto é, para que a influência de $\mathbf{A}\mathbf{d}$ nestas desigualdades não seja relevante. Assim, $\mathbf{x}$ pode ser escrito como uma combinação linear de dois pontos distintos $\mathbf{x}_1$ e $\mathbf{x}_2$ e, portanto, não é ponto extremo. $\square$

Neste momento, é bem conveniente interpretar os resultados acima no âmbito de PLs em FPI. Primeiro, o exercício abaixo.

Exercício 60. Considere o poliedro

$$P = \left\{ \mathbf{x} \in \mathbb{R}^4 : \begin{pmatrix} 1 & 3 & 1 & 0 \\ 2 & 2 & 0 & 1 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \mathbf{x} \geq 0 \right\}.$$

Note que $\mathbf{z} = (0 \ 0 \ 2 \ 1)^T$ é uma solução básica viável.

- (i) Reescreva as restrições que definem P para que apareçam apenas restrições com $\leq$.
- (ii) Use o Teorema (12) para mostrar que $\mathbf{z}$ é um ponto extremo do poliedro.

Exercício 61. O objetivo deste exercício é compreender melhor a geometria da região viável de uma PL em FPI. Considere

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{A}\mathbf{x} = \mathbf{b} \\ & \mathbf{x} \geq 0, \end{aligned}$$

e suponha que seja viável e limitada. Suponha que $\mathbf{A}$ é uma matriz $m \times n$, $n \geq m$, e seu posto é igual a m .

- (a) Suponha que $\mathbf{z}_1$ e $\mathbf{z}_2$ são soluções viáveis. Verifique diretamente que o segmento de reta entre elas é composto de soluções viáveis.

Lembre-se que para uma PL em FPI, uma solução viável $\mathbf{x}$ é chamada de básica se o suporte das entradas não nulas de $\mathbf{x}$ corresponde a um subconjunto de colunas de $\mathbf{A}$ contidas em uma base. Para a próxima letra, converta a expressão da PL para algo da forma $\mathbf{M}\mathbf{x} \leq \mathbf{d}$, e use o teorema anterior.

(b) Mostre que $\mathbf{x}$ é solução viável básica se e somente se $\mathbf{x}$ é um ponto extremo.

Também é possível demonstrar a letra acima diretamente. As letras abaixo são um passo-a-passo. É um excelente exercício fazer as letras abaixo sem olhar para a demonstração do teorema acima.

- (c) Assuma que $\mathbf{z}_1$ e $\mathbf{z}_2$ são soluções viáveis distintas, e $\mathbf{z} = \lambda\mathbf{z}_1 + (1 - \lambda)\mathbf{z}_2$. Mostre que se $0 < \lambda < 1$, $\mathbf{z}$ não pode ser uma solução básica viável da PL.
- (d) Mostre que se $\mathbf{w} > 0$ (ou seja, um vetor em que todas as entradas são positivas) e $\mathbf{w}$ é viável, então existem $\mathbf{w}_1 \neq \mathbf{w}_2$ soluções viáveis tais que $\mathbf{w} = 1/2(\mathbf{w}_1 + \mathbf{w}_2)$, a não ser possivelmente no caso em que $n = m$.
- (e) Mostre que todo ponto extremo do poliedro (ou seja, os pontos que não pertencem a um segmento viável não-trivial) são exatamente as soluções básicas viáveis.

Por fim, seja $\mathbf{x}_1, \dots, \mathbf{x}_m$ um conjunto de pontos no $\mathbb{R}^n$. Uma combinação convexa desses pontos é um ponto $\mathbf{x}$ que satisfaz

$$\mathbf{x} = \lambda_1\mathbf{x}_1 + \dots + \lambda_m\mathbf{x}_m,$$

onde $0 \leq \lambda_i \leq 1$ para todo i , e $\lambda_1 + \dots + \lambda_m = 1$.

Exercício 62.

- (i) Considere três pontos não-colineares. Geometricamente, o que é o conjunto de todas as combinações convexas desses pontos?
- (ii) Mostre que se três pontos pertencem a conjunto convexo, então todas as combinações convexas também pertencem.
- (iii) Se convença, mas tente me convencer também, que um poliedro que não contenha uma semi-reta (ou se você preferir, um poliedro limitado, também chamado de politopo) é precisamente o conjunto de combinações convexas dos seus pontos extremos.

4.2 Teorema de alternativas e dualidade

Dados $\mathbf{A}$ e $\mathbf{b}$, um grande e importante problema é decidir se o poliedro determinado pelas desigualdades $\mathbf{A}\mathbf{x} \leq \mathbf{b}$ é vazio ou não. Para tanto, introduzimos o Teorema das Alternativas, em cuja demonstração apresentamos o esquema de eliminação de Fourier-Motzkin.

Teorema 13. *Dados $\mathbf{A}$ e $\mathbf{b}$, exatamente uma das seguintes sentenças é verdadeira.*

- (1) O sistema $\mathbf{A}\mathbf{x} \leq \mathbf{b}$ tem solução.
- (2) Existe $\mathbf{z}$ com $\mathbf{z} \geq \mathbf{0}$, $\mathbf{z}^T\mathbf{A} = \mathbf{0}$, e $\mathbf{b}^T\mathbf{z} < 0$.

Demonstração. Claramente, ambos não podem ser verdadeiros ao mesmo tempo. Portanto, devemos mostrar que ambos não podem ser falsos ao mesmo tempo. A prova é por indução no número de colunas de $\mathbf{A}$. Dentro da indução existe um algoritmo implícito conhecido como procedimento de eliminação de Fourier-Motzkin.

Para o caso base, note que se $\mathbf{A}$ tem zero colunas, então (1) simplesmente declara que $\mathbf{b} \geq \mathbf{0}$. Se isso falhar, uma coordenada é negativa, digamos i -ésima, então simplesmente escolha $\mathbf{z} = \mathbf{e}_i$.

Suponha que o teorema seja válido para qualquer matriz com $n - 1$ colunas. Considere agora $\mathbf{A}$ uma matriz $m \times n$. Suponha sem perda de generalidade que as desigualdades foram escalonadas de modo que a magnitude dos coeficientes diferentes de zero de x_n seja 1. Sejam I_+ os índices de linha correspondentes aos coeficientes positivos de x_n , I_- aos negativos e I_0 aos coeficientes 0. Portanto, o sistema se escreve como

$$\begin{aligned} \sum_{k=1}^{n-1} A_{ik}x_k + x_n &\leq b_i, & \text{para todo } i \in I_+, \\ \sum_{k=1}^{n-1} A_{ik}x_k - x_n &\leq b_i, & \text{para todo } i \in I_-, \\ \sum_{k=1}^{n-1} A_{ik}x_k &\leq b_i, & \text{para todo } i \in I_0. \end{aligned}$$

Isso implica que

$$\max_{i \in I_-} \left(\sum_{k=1}^{n-1} A_{ik} - b_i \right) \leq \min_{i \in I_+} \left(b_i - \sum_{k=1}^{n-1} A_{ik} \right),$$

então o sistema original tem solução se e somente se o seguinte sistema também tem

$$\begin{aligned} \sum_{k=1}^{n-1} (A_{ik} + A_{jk})x_k &\leq b_i + b_j, & \text{para } i \in I_- \text{ e } j \in I_+, \\ \sum_{k=1}^{n-1} A_{ik}x_k &\leq b_i, & \text{para } i \in I_0. \end{aligned}$$

Note que o número de variáveis diminuiu, mas o número de inequações aumentou terrivelmente. Isso contudo não é um problema para a nossa indução (mas seria um problema se estivéssemos usando este método para resolver PLs).

Se o sistema original não tem solução, o anterior também não tem, e, por indução, existem coeficientes w_{ij} , para $i \in I_-$ e $j \in I_+$, e coeficientes v_i , para $i \in I_0$, de modo que, para todos os índices, $w_{ij} \geq 0$, $v_i \geq 0$, e

$$\sum_{i \in I_-, j \in I_+} (A_{ik} + A_{jk})w_{ij} + \sum_{i \in I_0} A_{ik}v_i = 0, \quad \text{para todo } k,$$

e

$$\sum_{i \in I_-, j \in I_+} (b_i + b_j)w_{ij} + \sum_{i \in I_0} b_i v_i < 0.$$

Assim, simplesmente definimos $\mathbf{z}$ por

$$\begin{aligned} z_i &= \sum_{j \in I_+} w_{ij}, & \text{para } i \in I_-, \\ z_j &= \sum_{i \in I_-} w_{ij}, & \text{para } j \in I_+, \\ z_i &= v_i, & \text{para } i \in I_0. \end{aligned}$$

Satisfaz $\mathbf{z} \geq \mathbf{0}$, $\mathbf{z}^T \mathbf{A} = \mathbf{0}$, e $\mathbf{b}^T \mathbf{z} < 0$.

Exercício 63. O lema de Farkas diz que $\mathbf{Ax} = \mathbf{b}$ e $\mathbf{x} \geq \mathbf{0}$ não tem solução se e somente se houver $\mathbf{y}$ de modo que $\mathbf{y}^T \mathbf{A} \geq \mathbf{0}$ e $\mathbf{b}^T \mathbf{y} < 0$. Prove isso (usando o Teorema das Alternativas).

Lembre-se que vimos que o certificado de inviabilidade nada mais é do que o ótimo da dual da PL auxiliar. Não é difícil verificar que sua existência implica que o ótimo de PLs duais coincide.

Teorema 14 (Teorema Forte da Dualidade). *Considere o seguinte par primal-dual de programações lineares*

$$(P) \quad \begin{array}{ll} \max & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} & \mathbf{Ax} \leq \mathbf{b} \end{array} \quad \left| \quad (D) \quad \begin{array}{ll} \min & \mathbf{b}^T \mathbf{y} \\ \text{sujeito a} & \mathbf{A}^T \mathbf{y} = \mathbf{c} \\ & \mathbf{y} \geq \mathbf{0}. \end{array}$$

Se o problema dual (D) é viável e limitado, então (P) também é, e os ótimos coincidem.

Demonstração. Já sabemos por dualidade fraca que $\mathbf{c}^T \mathbf{x} \leq \mathbf{b}^T \mathbf{y}$. Seja $\mathbf{w}$ solução ótima para (D). Considere o sistema de inequações lineares

$$\begin{pmatrix} \mathbf{A} \\ -\mathbf{c}^T \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} \mathbf{b} \\ -\mathbf{b}^T \mathbf{w} \end{pmatrix}.$$

Note que se ele for viável, então existe $\mathbf{x}$ viável para (P) tal que $\mathbf{c}^T \mathbf{x} \geq \mathbf{b}^T \mathbf{w}$, e portanto $\mathbf{c}^T \mathbf{x} = \mathbf{b}^T \mathbf{w}$. Suponha então, para efeito de contradição, que o sistema é inviável. Pelo Lema de Farkas, existe $(\mathbf{z}, z_0) \geq \mathbf{0}$ tal que

$$(\mathbf{z}^T \ z_0) \begin{pmatrix} \mathbf{A} \\ -\mathbf{c}^T \end{pmatrix} = \mathbf{0} \quad \text{e} \quad (\mathbf{z}^T \ z_0) \begin{pmatrix} \mathbf{b} \\ -\mathbf{b}^T \mathbf{w} \end{pmatrix} < 0.$$

Se $z_0 = 0$, note então que $\mathbf{z}$ seria um certificado de ilimitada para (D), uma contradição.

Se $z_0 > 0$, então note que

$$\frac{1}{z_0} \mathbf{z}^T \mathbf{A} = \mathbf{c}^T, \quad \text{e} \quad \frac{1}{z_0} \mathbf{z}^T \mathbf{b} < \mathbf{b}^T \mathbf{w},$$

contrariando o fato que $\mathbf{w}$ era ótimo para (D).

Assim, concluímos que (P) é viável, e seu ótimo é igual ao de (D). $\square$

É um exercício interessante verificar que (algumas das) demais formulações equivalentes de dualidade também satisfazem o teorema forte acima.

4.3 Geometria de otimização poliédrica

O cone gerado por um conjunto de vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$ é o conjunto

$$C = \left\{ \sum_{i=1}^k \lambda_i \mathbf{v}_i : \lambda_i \geq 0 \right\}.$$

Dado um poliedro $P = \{\mathbf{x} : \mathbf{Ax} \leq \mathbf{b}\}$, e $\mathbf{x}_1 \in P$, lembre da definição de $\mathbf{A}^=$ e $\mathbf{b}^=$. O cone das restrições de igualdade é o cone gerado pelas linhas de $\mathbf{A}^=$.

Exercício 64. Volte ao Exemplo 16 e calcule o cone de restrições de igualdade para os três pontos apresentados.

Apresentamos então uma caracterização de otimalidade.

Teorema 15. *Seja $\mathbf{x}$ uma solução viável de $\max\{\mathbf{c}^T \mathbf{x} : \mathbf{Ax} \leq \mathbf{b}\}$. Então $\mathbf{x}$ é ótima se e somente se $\mathbf{c}$ pertence ao cone de restrições de igualdade de $\mathbf{x}$.*

Demonstração. Vamos começar escrevendo o problema com variáveis de folga, o problema dual, e relembrando as condições de folga complementares. No caso, temos

$$\begin{array}{ll|ll} \max & \mathbf{c}^T \mathbf{x} & & \min & \mathbf{b}^T \mathbf{y} \\ \text{(P)} & \text{sujeito a} & \mathbf{Ax} + \mathbf{u} = \mathbf{b} & \text{(D)} & \text{sujeito a} & \mathbf{A}^T \mathbf{y} = \mathbf{c} \\ & & \mathbf{u} \geq \mathbf{0} & & & \mathbf{y} \geq \mathbf{0}, \end{array}$$

e, sem dificuldades, temos dualidade fraca:

$$\mathbf{c}^T \mathbf{x} = \mathbf{y}^T \mathbf{Ax} = \mathbf{y}^T (\mathbf{b} - \mathbf{u}) \leq \mathbf{y}^T \mathbf{b},$$

com igualdade se e somente se $\mathbf{y}^T \mathbf{u} = 0$, caso em que $\mathbf{x}$ e $\mathbf{y}$ formam um par primal dual de soluções ótimas.

Suponha que $\mathbf{c}$ pertence ao cone de restrições de igualdade de $\mathbf{x}$. Ou seja, existe $\mathbf{y} \geq \mathbf{0}$ tal que $\mathbf{y}^T \mathbf{A}^= = \mathbf{c}$. Estendendo $\mathbf{y}$ com variáveis iguais a 0 para as demais linhas de $\mathbf{A}$, temos (abusando a notação) que $\mathbf{y}^T \mathbf{A} = \mathbf{c}$, ou seja, $\mathbf{y}$ é viável para (D), e, sem muitas dificuldades, segue que $\mathbf{y}$ é diferente de 0 precisamente onde $\mathbf{Ax} \leq \mathbf{b}$ não tem folga, ou seja, onde a entrada de $\mathbf{u}$ é 0, e daí temos que $\mathbf{y}^T \mathbf{u} = 0$.

Se $\mathbf{x}$ (e folgas $\mathbf{u}$) são ótimas para (P), o teorema forte da dualidade garante a existência de $\mathbf{y}$ viável para (D) e com $\mathbf{y}^T \mathbf{u} = 0$. É imediato verificar que $\mathbf{y}^T \mathbf{A}$ é portanto uma combinação dos coeficientes positivos de $\mathbf{y}$ vezes as linhas de $\mathbf{A}^=$, e portanto $\mathbf{c}$ pertence ao cone de restrições de igualdade de $\mathbf{x}$. $\square$

Capítulo 5


Programações inteiras

5.1 Programações inteiras

Considere o problema de otimização abaixo:


$$\begin{array}{ll}\max & 12x_1 + 2x_2 \\ \text{sujeito a} & x_2 \leq 4 \\ & 3x_1 - 2x_2 \leq 3 \\ & 10x_1 + 2x_2 \leq 23 \\ & x_1, x_2 \geq 0 \\ & x_1, x_2 \in \mathbb{Z}.\end{array}$$

Se ignorarmos a última restrição (que diz que as variáveis devem ser inteiras), a PL correspondente pode ser representada graficamente pela figura abaixo:



Os vértices do poliedro que define a área viável são $(0,0)$, $(1,0)$, $(2, \frac{3}{2})$, $(\frac{3}{2}, 4)$, $(0,4)$. A figura também inclui, em vermelho, os pontos dentro da área viável que são inteiros.

O ótimo (da PL) está no ponto $(2, \frac{3}{2})$. O problema é que ele é fracionário, isto é, a solução não satisfaz a condição de integralidade imposta. Observe a figura abaixo:



Os pontos inteiros viáveis mais próximos da solução ótima da PL são $(1,1)$ e $(1,2)$. Porém, como podemos ver na figura, o ótimo inteiro é o ponto $(1,4)$. As linhas verdes pontilhadas representam a função objetivo passando pelo ponto ótimo da PL (com valor 27) e pelo ponto ótimo do problema inteiro (com valor 20).

Este exemplo dá uma ideia da dificuldade que é lidar com problemas de programação inteira: a solução ótima não é necessariamente próxima da solução ótima da PL obtida quando ignoramos a restrição de integralidade. Quando consideramos mais variáveis (mais dimensões), o problema se torna ainda mais crítico. Apontamos alguns fatos relevantes:

- (i) O ótimo de uma programação inteira não está necessariamente na fronteira do poliedro.
- (ii) Se a programação é um problema de maximização, o ótimo da PL é sempre maior ou igual que o ótimo da PI. No exemplo acima, o ótimo da PL era 27, e da PI 20.
- (iii) O que acontece com dualidade?
- (iv) Se todos os vértices do poliedro são pontos de coordenadas inteiras, então esses ótimos irão coincidir.

Em relação ao ponto (iv) acima, veremos mais pra frente que algumas PIs com um tipo de estrutura específica podem ser resolvidas facilmente. Porém, a grande maioria das PIs não possui tal estrutura, e é um problema em aberto se é possível resolvê-las com algoritmos polinomiais ou não.

Veremos em breve dois algoritmos que resolvem PIs. Ambos os algoritmos possuem complexidade exponencial, porém funcionam rapidamente na prática em diversos casos (mas não todos!). Porém, inicialmente, vamos apresentar alguns exemplos de problemas que podem ser modelados como PIs.

5.2 Modelagem

Vimos nas aulas anteriores várias PLs onde faria sentido se, na verdade, tivessem sido modeladas como PIs. Por exemplo, ao planejar a produção de uma empresa, permitimos que a solução final sugerisse produzir uma quantidade fracionária de um certo produto ao invés de unidades inteiras. Outro exemplo é o problema da dieta, onde a solução pode indicar a compra de “5.3 ovos” ou “10.2 porções de carne”. Na prática, faria sentido impor que as porções devem ser inteiras para diversos alimentos (com exceção daqueles que compramos a granel, por exemplo).

Nesta seção, veremos exemplos de problemas onde somente faz sentido utilizar programação inteira.

Exemplo 17. Uma empresa possui N projetos nos quais pode investir. Cada projeto $i \in N$ possui retorno esperado positivo c_i (em reais). Porém, devido a restrições orçamentárias, não é possível investir em todos. No caso, cada projeto i requer que a empresa faça aportes financeiros a_{it} nos tempos $t = 1, \dots, T$. O orçamento disponível para estes aportes no tempo t é b_t (previamente conhecido ou estimado). Formule este problema como um problema de programação inteira.

Variáveis de decisão: Devemos decidir em quais projetos a empresa irá investir. Não faz sentido “investir em meio projeto”, ou “investir duas vezes no mesmo projeto”. Ou seja, a decisão é binária: para cada projeto i , ou investe, ou não investe. Assim, vamos propor variáveis x_i que terão o valor 1 se optarmos por investir no projeto i , ou o valor 0, caso contrário.

Este tipo de variável é geralmente chamado de variável binária. É uma variável inteira limitada pelos valores $0 \leq x_i \leq 1$. É bastante utilizada em situações onde devemos tomar decisões binárias, sim ou não. A grande maioria dos problemas mais interessantes de PI requer variáveis binárias.

Função objetivo: Tendo decidido as variáveis, a empresa busca maximizar o retorno esperado dos investimentos:

$$\max \sum_{i=1}^N c_i x_i$$

Note que o retorno esperado do projeto i , c_i , será positivo na função objetivo apenas caso x_i seja 1.

Restrições: Para cada período de tempo $t = 1, \dots, T$ possuímos um orçamento limitado que não pode ser ultrapassado:

$$\sum_{i=1}^N a_{it} x_i \leq b_t \quad t = 1, \dots, T$$

Observe que a formulação possui T restrições, uma para cada período de tempo. O modelo completo é dado abaixo:

$$\begin{aligned}
& \max \quad \sum_{i=1}^N c_i x_i \\
& \text{sujeito a} \quad \sum_{i=1}^N a_{it} x_i \leq b_t \quad t = 1, \dots, T \\
& \quad \quad \quad 0 \leq x_i \leq 1, x_i \text{ inteiro}, \quad i = 1, \dots, N
\end{aligned}$$

É comum também utilizarmos a notação $x_i \in \mathbb{B}$ para dizer que uma variável pode ter apenas os valores 0 ou 1.

No problema acima, assumimos que c_i é conhecido. Na prática, o retorno esperado é uma estimativa cuja incerteza pode ser alta (alto risco). Existem diversos modelos de otimização que buscam gerenciar o risco ao controlar a incerteza enquanto busca-se maximizar o retorno esperado.

Exercício 65. Suponha que a empresa possua três condições adicionais:

- (a) Os projetos 3 e 4 são concorrentes, não é possível investir em ambos ao mesmo tempo.
- (b) Se a empresa investir no projeto 2, então deve obrigatoriamente investir no projeto 5.
- (c) Se a empresa investir nos projeto 1 e 4, então deve obrigatoriamente investir no projeto 6.

Acrescente restrições à formulação acima de forma a garantir que estas condições sejam respeitadas.

Exemplo 18. Uma empresa possui N tarefas urgentes que devem ser cumpridas. Cada tarefa exige um funcionário (há também N funcionários disponíveis). Todo funcionário pode fazer toda tarefa, mas como cada funcionário tem um nível de capacitação diferente, o tempo gasto varia. Já sabemos de antemão que o funcionário i precisa de c_{ij} horas para executar a tarefa j . A empresa busca minimizar o tempo total gasto nas tarefas e quer que todos os funcionários fiquem ocupados (ninguém deve ficar a toa). Formule este problema como uma PI.

Variáveis de decisão: Temos $x_{ij} = 1$ se o funcionário i executa a tarefa j , $x_{ij} = 0$ caso contrário.

Formulação: O problema é formulado da seguinte forma:

$$\begin{aligned}
& \min \quad \sum_{i=1}^N \sum_{j=1}^N c_{ij} x_{ij} \\
& \text{sujeito a} \quad \sum_{j=1}^N x_{ij} = 1 \quad i = 1, \dots, N \\
& \quad \quad \quad \sum_{i=1}^N x_{ij} = 1 \quad j = 1, \dots, N \\
& \quad \quad \quad x_{ij} \in \mathbb{B} \quad i = 1, \dots, N, j = 1, \dots, N
\end{aligned}$$

O primeiro conjunto de restrições garante que todo funcionário será alocado a uma tarefa, e o segundo conjunto garante que toda tarefa será executada por um funcionário.

Este problema é conhecido como o **problema da atribuição** (*assignment*). Veremos mais pra frente que esta é uma PI “fácil” de ser resolvida.

Exercício 66. Altere a formulação acima de acordo com os detalhes abaixo:

- (a) As tarefas 3, 4, e 5 serão executadas na mesma sala. O funcionário 3 recentemente descobriu que o funcionário 2 é amante de sua esposa, o que fez com que chegassem às vias de fato em pleno ambiente de trabalho. A empresa obviamente não quer que os dois fiquem na mesma sala. Adicione esta restrição à formulação acima.
- (b) Os funcionários 4 e 5 trabalham bem em conjunto, e seria interessante que ou eles fizessem as tarefas 1 e 2 (pois são relacionadas), ou fizessem as tarefas 6 e 7 (que também são relacionadas). Altere a formulação para garantir que um dos casos acima será verdadeiro. Dica: utilize uma variável binária extra.
- (c) Ao invés de minimizar o tempo total das tarefas, a empresa quer finalizar os trabalhos o mais cedo possível, ou seja, ela quer que a última tarefa a ser finalizada termine o quanto antes. Altere a formulação acima para atender este caso.

Exercício 67. O governo de Minas deve decidir onde construir novos quartéis do corpo de bombeiros. Há uma região com 6 cidades no norte do Estado que atualmente que não é atendida por nenhum quartel em menos de 45 minutos. O governo gostaria de garantir que há um corpo de bombeiros a no máximo 15 minutos de distância de cada uma destas 6 cidades. Abaixo, uma tabela com o tempo necessário para dirigir da cidade i até a cidade j (a tabela não é necessariamente simétrica):

De/para	1	2	3	4	5	6
1	0	10	20	30	30	20
2	10	0	25	35	20	10
3	20	25	0	15	30	20
4	30	35	15	0	15	25
5	20	20	30	15	0	14
6	20	10	20	25	14	0

Devido ao orçamento apertado, o governo gostaria de construir o menor número possível de quartéis. Formule este problema como uma PI.

Exercício 68. Você quer resolver um problema de *machine learning* e possui N *features* disponíveis. Você acha que N *features* são demais e gostaria de reduzir este conjunto para $K < N$ *features*, sendo K um valor fixo previamente decidido. O ideal é que as *features* selecionadas sejam pouco correlacionadas, ou seja, queremos minimizar a soma das correlações entre todas as K *features* selecionadas. O valor c_{ij} representa a correlação entre as *features* i e j . Formule este problema utilizando Programação Inteira Linear Mista (neste caso, podem haver variáveis inteiras e variáveis não inteiras).

Exercício 69. Uma empresa produz mapas do mundo que são vendidos em bancas de jornal. Cada um dos N países do mapa deve ser colorido com uma cor, porém países vizinhos não podem ter cores iguais. Devido aos altos custos dos cartuchos de tinta, a empresa gostaria de utilizar o menor número possível de cores no mapa. Considere que há C cores disponíveis e que já sabemos

de antemão quais países são vizinhos, isto é, temos uma matriz $B_{ij} = 1$ se os países i e j são vizinhos, 0 caso contrário.

Formule o problema de encontrar o menor número possível de cores a serem utilizadas em um mapa como um problema de programação inteira.

Exercício 70. Desafio O Brasileirão possui 20 equipes e é disputado utilizando-se uma fórmula de pontos corridos, onde todas as equipes se enfrentam duas vezes (uma em casa, uma fora), totalizando 38 jogos por equipe. Idealmente, as equipes devem alternar entre jogar uma partida em casa, uma fora de casa, e assim vai. Não é interessante para o torcedor que uma equipe jogue 3 partidas seguidas em casa, por exemplo, ou que jogue 5 partidas seguidas fora de casa. Por isto, estas situações nunca devem ocorrer. Matematicamente, porém, não sabemos se existe uma solução onde nenhuma equipe jogue duas partidas seguidas em casa ou duas seguidas fora (quando isto ocorre, temos uma **quebra**).

- Considere inicialmente que cada equipe jogará apenas uma vez contra as demais (19 jogos cada). Formule este problema como uma PI que minimiza o número de quebras.
- Adicione uma restrição que impõe que se na primeira rodada uma equipe jogou em casa, então deve jogar fora de casa na última rodada.
- O que você deve fazer para resolver agora o problema com 38 rodadas, onde se a equipe i enfrentou j em casa na rodada t , deve então enfrenta-la fora de casa na rodada $t + 19$ (tabela com dois turnos simétricos)?

5.3 Escrevendo uma PI como uma PL

Até agora tratamos PIs da seguinte forma. Apresentamos uma PL do tipo

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{Ax} = \mathbf{b} \\ & \mathbf{x} \geq 0, \end{aligned}$$

e adicionamos uma restrição


$$\mathbf{x} \in \mathbb{Z}^n.$$

Nosso objetivo agora é ser capaz de formular uma PI sem precisar codificar a restrição de integralidade da maneira acima. Aprenderemos como, ao sermos apresentados a uma matriz $\mathbf{A}$ qualquer, fazer pequenas modificações de modo que o ótimo da PL seja um ótimo da PI correspondente.

Exemplo 19. Considere

$$\begin{aligned} \max \quad & (1 \ 1) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 2 & 1 \\ 1 & 2 \\ -1 & -4 \\ -1 & 0 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 7 \\ 7 \\ -4 \\ -1/2 \end{pmatrix} \\ & \mathbf{x} \text{ inteiro.} \end{aligned}$$

Cada uma das restrições corresponde às retas (1), (2), (3) e (4) abaixo, e a região verde é portanto a região de viabilidade da relaxação linear.



O ótimo da PL é o ponto $\mathbf{x} = (7/3 \ 7/3)$. Suponha que agora foi adicionada a restrição abaixo, que corresponde à reta (c) da figura.

$$(1 \ 1) \mathbf{x} \leq 4.$$

Originalmente, havia 6 pontos inteiros que eram viáveis. Eram eles

$$(1 \ 1), \ (1 \ 2), \ (1 \ 3), \ (2 \ 1), \ (2 \ 2), \ (3 \ 1)$$

Note que todos eles permanecem satisfazendo $(1 \ 1) \mathbf{x} \leq 4$, mas que o ponto $\mathbf{x} = (7/3 \ 7/3)$ não satisfaz. Consideramos a PI que adiciona esta restrição:

$$\begin{aligned} \max \quad & (1 \ 1) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 2 & 1 \\ 1 & 2 \\ -1 & -4 \\ -1 & 0 \\ 1 & 1 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 7 \\ 7 \\ -4 \\ -1/2 \\ 4 \end{pmatrix} \\ & \mathbf{x} \text{ inteiro.} \end{aligned}$$

O ótimo desta PI ainda será o mesmo que o da PI original, já que não retiramos qualquer ponto inteiro da região de viabilidade. Porém ao olharmos para a relaxação linear, saberemos que o seu ótimo será diferente. Basicamente: cortamos $\mathbf{x} = (7/3 \ 7/3)$ fora, sem mudar os pontos inteiros.

- De fato, a relaxação linear da nova PI tem 3 soluções ótimas inteiras.

Esta será nossa estratégia. Acrescentar desigualdades à formulação, chamadas de *planos de corte*, de modo que eventualmente o ótimo da relaxação linear se torne inteiro. Corte, no caso, costuma ser utilizado como sinônimo de restrição.

Observe na figura anterior os cortes (a), (b) e (c). Eles foram adicionados de forma que todos os pontos extremos do poliedro sejam inteiros. Ao resolver a PL correspondente (cuja área viável é a área vermelha na figura), obteremos a solução ótima da PI original. A PL que não corta nenhuma

solução inteira da PI original e cujos pontos extremos são todos inteiros é chamada de **envoltória convexa** (*convex hull*) da PI. No caso geral, um número exponencial (em relação ao número de variáveis do problema) de cortes é necessário para representar totalmente a envoltória convexa de uma PI.

5.4 Planos de corte

Considere o seguinte exemplo.

$$\begin{aligned} \max \quad & (2 \ 5) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 4 \\ 1 & 1 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 8 \\ 4 \end{pmatrix} \\ & \mathbf{x} \geq 0, \mathbf{x} \text{ inteiro.} \end{aligned}$$


A relaxação linear da PI acima pode ser resolvida normalmente, e encontramos a solução ótima

$$\mathbf{x} = (8/3 \ 4/3).$$

Claramente esta solução não é uma solução da PI. Portanto nosso objetivo agora é encontrar uma desigualdade do tipo

$$a_1x_1 + a_2x_2 \leq b$$

que seja satisfeita por qualquer solução inteira do problema, mas que não seja satisfeita por $x_1 = 8/3$ e $x_2 = 4/3$. Uma desigualdade deste tipo será chamada de *plano de corte*.



No caso, a desigualdade aqui será $x_1 + 3x_2 \leq 6$, correspondente à reta (*) acima. Como achá-la em geral? Ao resolvermos o simplex na relaxação linear do problema original, teremos

$$\left[\begin{array}{c|cccc|c} 1 & -2 & -5 & 0 & 0 & 0 \\ 0 & 1 & 4 & 1 & 0 & 8 \\ 0 & 1 & 1 & 0 & 1 & 4 \end{array} \right] \Rightarrow \left[\begin{array}{c|cccc|c} 1 & 0 & 0 & 1 & 1 & 12 \\ 0 & 1 & 0 & -1/3 & 4/3 & 8/3 \\ 0 & 0 & 1 & 1/3 & -1/3 & 4/3 \end{array} \right]$$

A segunda linha do tableau significa que

$$x_1 - \frac{1}{3}x_3 + \frac{4}{3}x_4 = \frac{8}{3}.$$

Qualquer solução satisfaz essa igualdade, uma vez que ela foi obtida a partir de operações elementares aplicadas a uma igualdade original da PL em FPI. Vamos então reduzir o valor do lado esquerdo desta expressão ao reduzir coeficientes: isto é válido pois as variáveis são não negativas. Transformamos a igualdade em desigualdade:

$$x_1 + \left\lfloor \frac{-1}{3} \right\rfloor x_3 + \left\lfloor \frac{4}{3} \right\rfloor x_4 \leq \frac{8}{3}.$$

Ou seja

$$x_1 - x_3 + x_4 \leq \frac{8}{3}.$$

Contudo, estamos preocupado apenas com soluções inteiras. Uma soma de número inteiros menor ou igual que $8/3$ será também menor ou igual a 2. Teremos finalmente a inequação abaixo, que necessariamente será satisfeita por qualquer solução viável inteira do problema original:

$$x_1 - x_3 + x_4 \leq 2.$$

Observe que esta desigualdade é violada pela solução ótima da PL, $\mathbf{x} = (8/3 \ 4/3)$. De fato, um corte obtido desta forma sempre será violado pela solução atual da PL (por que?).

Acrescentamos esta inequação e resolvemos de novo. Ou seja, o novo tableau será:

$$\left[\begin{array}{c|cccc|c} 1 & 0 & 0 & 1 & 1 & 0 & 12 \\ \hline 0 & 1 & 0 & -1/3 & 4/3 & 0 & 8/3 \\ 0 & 0 & 1 & 1/3 & -1/3 & 0 & 4/3 \\ 0 & 1 & 0 & -1 & 1 & 1 & 2 \end{array} \right] \Rightarrow \left[\begin{array}{c|cccc|c} 1 & 0 & 0 & 1 & 1 & 0 & 12 \\ \hline 0 & 1 & 0 & -1/3 & 4/3 & 0 & 8/3 \\ 0 & 0 & 1 & 1/3 & -1/3 & 0 & 4/3 \\ 0 & 0 & 0 & -2/3 & -1/3 & 1 & -2/3 \end{array} \right],$$

que resolveremos usando o método dual do simplex!

Resumindo...

- (i) Resolvemos a relaxação linear original.
- (ii) Escolhemos uma das equações que indique uma solução fracionária para uma das variáveis do problema - necessariamente será uma linha onde o $\mathbf{b}$ foi uma fração.
- (iii) Trocamos todos os coeficientes desta inequação por $\lfloor \cdot \rfloor$ (cuidado com os negativos!!).
- (iv) Acrescentamos a nova equação, e resolvemos o simplex novamente (método dual será sempre a melhor estratégia).
- (v) Se a solução for inteira, acaba. Se não for, repete o passo (ii).

Este algoritmo foi proposto por Ralph Gomory nos anos 50 e estes cortes possuem hoje o nome de cortes de Gomory. De início, porém, não era considerado muito prático (até pelo próprio Gomory) devido a instabilidades numéricas e devido ao enorme número de cortes que eram necessários no geral para resolver uma PI. A partir dos anos 90, o método foi revisitado e combinado com o próximo algoritmo que veremos, o **Branch-and-bound**, para formar o que chamamos de algoritmos **Branch-and-cut**, bastante efetivos para diversos problemas. Hoje em dia, todos os *solvers* implementam e aplicam cortes de Gomory de uma forma ou outra.

Exercício 71. Suponha que ao resolver a relaxação linear de uma PI, chegamos no seguinte tableau:

$$\left[\begin{array}{c|ccccccc} 1 & 0 & 0 & 0 & 17/12 & 1/12 & 5/12 & 140 \\ \hline 0 & 1 & 0 & 0 & 111/60 & -13/12 & -1/60 & 9/2 \\ 0 & 0 & 1 & 0 & 1/10 & 1/2 & -1/10 & 1 \\ 0 & 0 & 0 & 1 & 2 & 11/2 & -1/12 & 11/10 \end{array} \right]$$

Quais inequações podem ser usadas para acharmos planos de corte? Para cada uma delas, qual o plano de corte correspondente?

Exercício 72. Resolva a PI abaixo pelo método dos planos de corte.

$$\begin{aligned} \max \quad & (3 \ 2 \ 4) \mathbf{x} \\ \text{sujeito a} \quad & \begin{pmatrix} 1 & 1 & 2 \\ 2 & 0 & 3 \\ 2 & 1 & 3 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 4 \\ 5 \\ 7 \end{pmatrix} \\ & \mathbf{x} \geq 0, \mathbf{x} \text{ inteiro.} \end{aligned}$$

5.5 Branch and bound

Nesta seção, vamos ver outra estratégia para resolver PIs. Suponha que tenhamos o problema abaixo, a qual nos referiremos como **Problema 1**.

$$\begin{aligned} \max \quad & 60x_1 + 50x_2 \\ \text{sujeito a} \quad & \begin{pmatrix} 3/2 & 1 \\ 9 & 11 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 6 \\ 45 \end{pmatrix} \\ & \mathbf{x} \geq 0, \mathbf{x} \text{ inteiro.} \end{aligned}$$

O ótimo da relaxação linear deste problema é


$$\mathbf{x} = (14/5 \ 9/5), \quad \text{valor objetivo } 258.$$

Imaginamos então que o ótimo inteiro tenha valores próximos desses. Vimos que isso nem sempre é verdade, mas pode ser verdade em alguns casos. Pegamos então uma variável cujo resultado tenha sido fracionário, e dividimos em dois casos. Por exemplo, a variável x_1 . Claramente $x_1 \leq 2$ ou $x_1 \geq 3$. Desta forma, criamos dois subproblemas:

Subproblema 2: Problema 1 + restrição $x_1 \geq 3$.

Subproblema 3: Problema 1 + restrição $x_1 \leq 2$.

Temos agora mais duas PLs para resolver, os subproblemas 2 e 3. Sabemos que a solução inteira ótima é parte de algum destes dois problemas. Podemos visualizar os problemas como uma árvore, de acordo com a figura abaixo:




Devemos então escolher um dos dois para começar. Vamos escolher o Subproblema 2. Como já relembramos nesta semana, resolver uma PL após adicionar uma única restrição não é muito custoso, podemos continuar ao executar o simples dual a partir do tableau do problema original. Ao resolver, descobrimos que o ótimo do Subproblema 2 é $\mathbf{x} = (3 \ 3/2)$ com valor objetivo 255. A variável x_1 agora é inteira, mas a variável x_2 continua fracionária. Podemos então criar mais dois problemas:

Subproblema 4: Subproblema 2 + restrição $x_2 \leq 1$.

Subproblema 5: Subproblema 2 + restrição $x_2 \geq 2$.

A árvore abaixo indica o estágio atual:




Agora possuímos três subproblemas na fila para serem resolvidos, 3, 4 e 5. Vamos seguir onde estávamos e resolver agora o Subproblema 4. Obtemos como solução $\mathbf{x} = (10/3 \ 1)$ com valor objetivo 250. A variável x_2 passou a ser inteira, mas x_1 voltou a ser fracionária. Podemos criar então mais dois subproblemas ao ramificar a árvore em x_1 :

Subproblema 6: Problema 4 + restrição $x_1 \leq 3$.

Subproblema 7: Problema 4 + restrição $x_1 \geq 4$.

Novamente, a árvore abaixo mostra a situação atual:




Note que o Subproblema 6 é formado pelo problema original mais as restrições $x_1 \geq 3, x_2 \leq 1$ e $x_1 \leq 3$ (ou seja, $x_1 = 3$). Vamos resolver este subproblema.

Ao resolve-lo, encontramos a solução ótima $\mathbf{x} = (3 \ 1)$ com valor objetivo 230. Esta solução é inteira e torna-se nossa primeira candidata a solução inteira ótima. Neste momento, sabemos que a solução ótima não é menor que 230, mas também sabemos que ela não é maior que 258. Para tal, verificamos todos os nós da árvore cujos filhos ainda não foram totalmente resolvidos. O máximo dentre estes valores é o melhor limite superior que possuímos no momento em relação à solução ótima. Neste momento, sabemos que o **gap de otimalidade** é $\frac{258-230}{258} = 10.85\%$.

Não é mais necessário ramificar a árvore abaixo do Subproblema 6 pois a solução da relaxação linear já é inteira. Qualquer restrição adicional no caso só poderia piorar a solução da relaxação ou, na melhor das hipóteses, mante-la no mesmo valor.

Passamos então ao Subproblema 7. Ao resolve-lo, obtemos a solução ótima $\mathbf{x} = (4 \ 0)$ com valor 240. Ela também é inteira e melhor que a solução anterior. Por isso, atualizamos nossa melhor solução e sabemos agora que o novo gap de otimalidade é $\frac{258-240}{258} = 7.5\%$.

Neste lado da árvore, não é necessário descer mais. Voltamos ao problema 5 e, ao resolve-lo, notamos que ele é inviável (não há solução onde $x_1 \geq 3$ e $x_2 \geq 2$). Não precisamos mais ramificar a árvore neste nó. No momento, a árvore está da seguinte forma:



Só nos resta agora expandir a árvore no Subproblema 3. O ótimo deste subproblema é $\mathbf{x} = (2 \ 2.45)$ com valor objetivo 242.73. Observe que devemos ramificar a árvore neste nó, porém note que estamos mais perto da solução ótima: sabemos que o valor ótimo não pode ser maior que 242.73, o que nos dá um gap de otimalidade de 1.1% apenas. Ramificando no nó, criamos mais dois problemas:


Subproblema 8: Problema 3 + restrição $x_2 \leq 2$.

Subproblema 9: Problema 3 + restrição $x_2 \geq 3$.

Ao resolver o Subproblema 8 obtemos a solução ótima $\mathbf{x} = (2 \ 2)$ com valor objetivo 220. A solução é inteira, não precisa ser ramificada e é pior que a melhor que temos (cujo valor é 240). Podemos descartá-lo e passar para o próximo nó.

Resolvemos o Subproblema 9 e obtemos a solução $\mathbf{x} = (4/3 \ 3)$ com valor objetivo 230. Esta solução é fracionária e em teoria deveríamos ramificar a árvore aqui. Porém, será mesmo necessário? Se já possuímos uma solução inteira com valor 240 e sabemos que a inclusão de novas restrições no Subproblema 9 não melhora a solução, então podemos descartar este nó pois dali nunca virá uma solução inteira com valor > 240 . Este processo é conhecido em Inglês como **pruning the tree**, ou “podar a árvore”.

Assim, encontramos a solução ótima para o problema. A árvore final pode ser vista abaixo:




Alguns comentários:

- (i) Várias escolhas no processo acima foram arbitrárias. Preferimos fazer uma busca em profundidade antes, sempre descendo na árvore quando possível. Também escolhemos começar ramificando em x_1 ao invés de x_2 . Podemos implementar a mesma idéia com variações, e estas decisões podem influenciar fortemente na performance do algoritmo. A busca em profundidade costuma encontrar soluções inteiras mais rapidamente, mas demora mais para reduzir limite superior e, conseqüentemente, o gap de otimalidade. A busca em largura é o oposto.
- (ii) O passo em que decidimos não seguir no subproblema 9 é o grande diferencial desse algoritmo, em comparação a uma simples busca em todos os pontos inteiros. Ele usa o fato de que o ótimo da PI nunca é melhor que o da sua relaxação linear para eliminar a necessidade de testar vários casos. Pode fazer uma diferença enorme na prática.
- (iii) Muitos dos melhores algoritmos comerciais para resolver PIs usam métodos mistos que combinam branch-and-bound e planos de corte. São os chamados branch-and-cut, cutting-and-bound, etc. Para grande parte dos problemas inteiros, esta combinação é hoje a técnica de maior sucesso na resolução destes problemas. A maior instância já resolvida para o caixeiro viajante possui 85900 cidades e a solução ótima foi obtida com um branch-and-cut.
- (iv) Ainda assim, muitos problemas são desafiadores do ponto de vista computacional. O branch-and-bound é um algoritmo de enumeração com complexidade exponencial no pior caso. Uma grande área de pesquisa é o desenvolvimento de algoritmos especializados para resolver PIs específicas. Estes algoritmos podem explorar novas formulações, novos tipos de cortes, novas regras de ramificação, etc. Podem também utilizar informação do dual da relaxação linear, decompor o problema em problemas menores. Podem também explorar heurísticas para prover uma solução inicial ao branch-and-bound, o que pode facilitar as podas da árvore.


- (v) Em ambos algoritmos (planos de corte e branch-and-bound), precisamos resolver um grande número de PLs. Em ambos os casos, usar o método simplex dual é mais eficiente que o primal - portanto o ganho final de usar este método é enorme.

Exercício 73. Suponha que a árvore abaixo mostra o atual estado na solução de uma PI via branch and bound. Já é possível determinar a solução final do problema?



Exercício 74. Suponha que se deseja resolver a PI abaixo, cuja região de viabilidade está desenhada ao lado, em um quadriculado onde cada quadrado tem lado $1/2$. Lembre-se que o ótimo de uma PL sempre se encontra em um vértice da região de viabilidade.

$$\begin{aligned} \max \quad & \begin{pmatrix} 8 & 10 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \\ \text{sujeita a} \quad & x_1 + 2x_2 \leq 6 \\ & 2x_1 + 2x_2 \leq 7 \\ & 2x_1 + x_2 \leq 6 \\ & x_1, x_2 \geq 0, \quad x_1, x_2 \in \mathbb{Z}. \end{aligned}$$



Resolva a PI efetuando “branch and bound”.

Exercício 75. Usando branch and bound, resolva a PI abaixo:

$$\begin{array}{ll}\max & (18 \ 10 \ 6 \ 4) \mathbf{x} \\ \text{sujeito a} & (12 \ 10 \ 8 \ 6) \mathbf{x} \leq 18 \\ & 0 \leq \mathbf{x} \leq 1, \ \mathbf{x} \text{ inteiro.}\end{array}$$

Use o fato que

$$18/12 > 10/10 > 6/8 > 4/6.$$

Exercício 76 (Desafio). Considere a PI abaixo, onde n é um inteiro positivo e ímpar.

$$\begin{array}{ll}\min & x_{n+1} \\ \text{sujeito a} & 2(x_1 + x_2 + \dots + x_n) + x_{n+1} = n \\ & 0 \leq \mathbf{x} \leq 1, \ \mathbf{x} \text{ inteiro.}\end{array}$$

Mostre que o método de branch and bound precisa examinar, no caso de piores escolhas possíveis, pelo menos $2^{\lfloor n/2 \rfloor}$ subproblemas antes de resolver o problema.

Capítulo 6

Formulando programações inteiras

6.1 Problema do caixeiro viajante

Considere o seguinte problema:

- Um caixeiro viajante precisa visitar as cidades $1, 2, \dots, n$ em alguma ordem, e voltar para a cidade de início. O custo para ir da cidade i para a cidade j é dada por c_{ij} . Qual volta pelas n cidades possui custo mínimo?

Este é o problema do caixeiro viajante, ou TSP (*travelling salesman problem*). É um dos problemas mais estudados da Ciência da Computação e foi formulado pela primeira vez pelo matemático irlandês W. R. Hamilton nos anos 1800s. Em homenagem a ele, uma solução para o problema que parte da cidade de origem, visita cada uma das $n - 1$ cidades restantes uma vez e que volta à cidade de origem é chamada de **ciclo Hamiltoniano**.

O problema foi formalizado nos anos 1930 (recebendo o nome que tem hoje) e em 1954 Dantzig (o mesmo do Simplex), Fulkerson (do algoritmo de Ford-Fulkerson) e Johnson (deve ter feito outras coisas boas) publicaram um artigo resolvendo “na mão” uma instância com 49 cidades. Eles formularam o problema como uma PI com diversas restrições específicas para esta instância em particular e provaram a otimalidade da solução encontrada. Basicamente, eles adicionaram alguns cortes e fizeram um processo de fixação de valor de algumas variáveis inteiras em 0 ou 1. Este artigo não descreveu um algoritmo genérico para o TSP, apenas resolveu esta instância em particular, mas foi um embrião para algoritmos de planos de corte e provavelmente a primeira vez que um algoritmo semelhante ao branch-and-bound foi executado. Foi um enorme feito para a época, visto que o número de possíveis soluções para o TSP com 49 cidades é $48! \approx 1.24 \times 10^{61}$.

6.1.1 Formulação matemática

Considere que o mapa das cidades que devem ser visitadas pelo caixeiro viajante é modelado como um grafo direcionado $G(V, A)$ onde V é o conjunto de cidades e A o conjunto de arcos. Assuma um grafo completo onde para todo par de cidades i, j existam arcos (i, j) e (j, i) conectando as cidades nas duas direções. A cada arco é associado um custo c_{ij} e não há necessariamente simetria nos custos - isto é, pode ser que $c_{ij} \neq c_{ji}$.

Caso o grafo real do problema não seja completo (por exemplo, não existe rota direta entre Rio e Brasília sem passar por BH), podemos criar um arco artificial nas duas direções onde o custo entre Rio e Brasília é dada pelo menor custo de um caminho entre as duas cidades. Seja $|V|$ o

número de vértices do grafo (esta notação é geralmente utilizada para representar a cardinalidade de um conjunto).

Esta versão do problema é chamada de TSP assimétrico. Vamos agora formula-lo como uma PI:

Variáveis de decisão: Considerando um grafo completo, podemos definir variáveis $x_{ij}, i, j \in V, i \neq j$ onde $x_{ij} = 1$ se o caixeiro segue de i direto para j , e $x_{ij} = 0$ caso contrário.

Formulação: Gostaríamos de minimizar o custo total, e garantir que toda cidade será visitada. Veja o modelo abaixo:

$$\begin{aligned} \min \quad & \sum_{i \in V} \sum_{j \in V, j \neq i} c_{ij} x_{ij} \\ \text{sujeito a} \quad & \sum_{j \in V, j \neq i} x_{ij} = 1, & \forall i \in V \\ & \sum_{i \in V, i \neq j} x_{ij} = 1, & \forall j \in V \\ & x_{ij} \in \{0, 1\}. \end{aligned}$$

As restrições do problema indicam que a partir de toda cidade i o caixeiro viajante deve seguir viagem para alguma cidade j . Igualmente, se o caixeiro chegou em j , ele tem que ter vindo de alguma cidade i . Ou seja, em toda cidade, o caixeiro vem de algum lugar e vai para algum lugar. A formulação está completa?

Infelizmente ainda não! Por exemplo, considere $|V| = 6$ e assumamos a solução $x_{12} = x_{23} = x_{31} = 1$, $x_{45} = x_{56} = x_{64} = 1$ e todos os demais $x_{ij} = 0$. Esta representa uma solução viável de acordo com o modelo acima, porém não representa um ciclo Hamiltoniano. Diz-se que a solução acima possui **subciclos**. Como podemos garantir que o caso acima não aconteça?

Uma possível ideia é adicionar a seguinte restrição ao problema:

$$x_{14} + x_{15} + x_{16} + x_{24} + x_{25} + x_{26} + x_{34} + x_{35} + x_{36} \geq 1$$

A restrição acima diz que o caixeiro deve ir de alguma cidade do lado 1, 2, 3 para outra cidade do lado 4, 5, 6. Assim, evitaríamos o subciclo mostrado no exemplo. Claro, precisamos também garantir que o caixeiro volte de 4, 5, 6 para 1, 2, 3. Porém, ao adicionar apenas a restrição acima ao modelo, garantimos também que a volta irá acontecer (por que?).

De forma geral, podem haver subciclos envolvendo qualquer subconjunto de V . O subciclo poderia ocorrer entre 1, 2 e 3, 4, 5, 6, ou poderia ocorrer entre 1, 3, 5 e 2, 4, 6. Temos então que garantir que para todo subconjunto de vértices, pelo menos um arco saia dele em direção ao complemento desse subconjunto. Podemos adicionar o seguinte conjunto de restrições:

$$\sum_{i \in W, j \notin W} x_{ij} \geq 1, \quad \forall W \subseteq V, 1 < |W| < |V| - 1 \quad (6.1)$$

O modelo completo fica assim:

$$\begin{aligned}
& \min \sum_{i \in V} \sum_{j \in V, j \neq i} c_{ij} x_{ij} \\
& \text{sujeito a} \quad \sum_{j \in V, j \neq i} x_{ij} = 1, & \forall i \in V \\
& \quad \sum_{i \in V, i \neq j} x_{ij} = 1, & \forall j \in V \\
& \quad \sum_{i \in W, j \notin W} x_{ij} \geq 1, & \forall W \subseteq V, 1 < |W| < |V| - 1 \\
& \quad x_{ij} \in \{0, 1\}.
\end{aligned}$$

Para todo subconjunto W de tamanho entre 2 e $|V| - 1$, garantimos que pelo menos um arco sairá dele e consequentemente nenhum subciclo ocorrerá.

Uma forma alternativa de representar as mesmas desigualdades de eliminação de subciclos é através das inequações:

$$\sum_{(i,j) \in W} x_{ij} \leq |W| - 1, \quad \forall W \subset V, 1 < |W| < |V| - 1 \quad (6.2)$$

Nesta versão, dizemos que o número de arcos entre vértices de W que fazem parte da solução ($x_{ij} = 1$) deve ser no máximo $|W| - 1$. Se houvesse $|W|$ ou mais arcos entre vértices do mesmo subconjunto, obrigatoriamente teríamos um subciclo.

Exercício 77. Teremos algum problema para obter a relaxação linear da formulação acima?

Neste momento vem a questão: como resolver esta formulação se, mesmo para V relativamente baixo, o número de restrições é tão alto que nem conseguimos escrevê-las na memória do computador mais poderoso que se conhece?

Pela mesma lógica do algoritmo de planos de corte! Geralmente um número exponencial de planos de corte são necessários para descrever completamente a envoltória convexa de um problema inteiro. Mas na prática conseguimos em muitos casos encontrar a solução ótima inteira ao adicionar apenas uma fração dos planos de corte. No caso do TSP, vale a mesma lógica. Assim temos o seguinte algoritmo Branch-and-cut:


1. Inicie o branch-and-bound para a formulação do TSP sem incluir as desigualdades de eliminação de subciclos.
2. Resolva o subproblema atual do Branch-and-bound.
3. Verifique se pelo menos uma restrição de eliminação de subciclos é violada pela solução da relaxação linear do subproblema resolvido.
 - (a) Caso sim, adicione ao modelo uma ou mais dentre as restrições violadas identificadas e volte ao passo 2, resolvendo novamente o subproblema.
 - (b) Senão, continue com o branching normalmente.

O que vemos na prática é que é possível terminar o branch-and-bound e provar a otimalidade de instâncias de tamanho considerável ao adicionar apenas uma fração pequena do conjunto completo de desigualdades de eliminação de subciclos. Algoritmos branch-and-cut baseados nesta formulação são os melhores algoritmos exatos conhecidos para o TSP. Para mais detalhes, dê uma olhada em:

<http://www.math.uwaterloo.ca/tsp/>

Ficou apenas uma dúvida: como descobrir se alguma restrição de eliminação de subciclos é violada pela solução da relaxação linear do subproblema atual? Este problema é chamado de **problema de separação** e necessitamos de um algoritmo capaz de resolvê-lo. Para o TSP, há dois casos possíveis.

Caso 1: Durante a resolução de algum subproblema do branch-and-bound, podemos obter uma solução desconectada e inteira. Neste caso devemos verificar se o grafo induzido por aquela solução é conectado. Senão for, podemos utilizar um algoritmo de busca em largura ou busca em profundidade para encontrar as componentes desconectadas do grafo. Por exemplo, considere a seguinte solução inteira para o TSP relaxado:



O grafo induzido é aquele que mantém apenas os arcos (i, j) cujo valor $x_{ij} = 1$. No exemplo acima, o grafo original é completo, mas todos os arcos omitidos tiveram, na solução encontrada, $x_{ij} = 0$.

Ao realizar a busca em profundidade ou largura, encontraremos três componentes conexas, compostas por $W_1 = \{1, 2, 3\}$, $W_2 = \{4, 5, 6\}$ e $W_3 = \{7, 8, 9\}$. Considerando que o vértice 1 seja a origem do caixeiro, podemos extrair os seguintes cortes para cada componente conexa:

$$\sum_{i \in W_2} \sum_{j \in W_2, i \neq j} x_{ij} \leq 2 \quad (6.3)$$


$$\sum_{i \in W_3} \sum_{j \in W_3, i \neq j} x_{ij} \leq 2 \quad (6.4)$$

O corte (6.3) indica que no máximo duas arestas devem ser escolhidas no subconjunto W_2 , senão obteremos um ciclo (como mostrado no exemplo). O corte (6.4) diz o mesmo para o subconjunto W_3 .

Podemos também combinar W_2 e W_3 fazendo $W = W_2 \cup W_3$ e adicionando:

$$\sum_{i \in W} \sum_{j \in W, i \neq j} x_{ij} \leq 5 \quad (6.5)$$

Note que a solução inteira acima, contendo subciclos, viola todas estas restrições. Podemos adicionar uma restrição para cada componente conexa que não contém a origem, ou uma restrição geral contendo a união de todas as componentes conexas. A tendência é que a primeira opção diminua mais a chance de outros subciclos acontecerem, mas pode tornar o modelo mais pesado por conter mais restrições (no exemplo, adicionaríamos (6.3) e (6.4)). A segunda opção é o contrário. Por exemplo, se adicionarmos apenas a restrição (6.5), podemos obter a solução abaixo:



que não viola (6.5) nem (6.4), mas viola (6.3). Se adicionarmos apenas (6.3) e (6.4), a solução acima não poderia acontecer.

Adicionamos a(s) restrição(ões) ao subproblema atual do branch-and-bound e resolvemos novamente a relaxação linear. Continuamos neste processo enquanto não encontrarmos uma solução conectada. Além disso, as restrições são adicionadas globalmente, ou seja, elas valem para todos os subproblemas ainda não explorados. Assim, se ao final do branch-and-bound encontrarmos uma solução inteira conectada, ela é ótima. A lógica de adicionar o corte globalmente é que as mesmas componentes desconectadas podem reaparecer em outros subproblemas da árvore.

Caso 2: Agora imagine que, ao resolvermos a relaxação linear de uma instância de 4 vértices do TSP sem as restrições (6.2), obtivéssemos o seguinte grafo induzido:

Note que a solução acima não viola nenhuma das demais restrições do TSP: em todo vértice, entra 1 e sai 1. Porém, observe que se considerarmos $W = \{3, 4\}$, obtemos a seguinte desigualdade do tipo (6.2):

$$x_{34} + x_{43} \leq 1 \quad (6.6)$$

Ao substituírmos os valores da relaxação linear, veremos que ela é violada:




Figura 6.1.1: Solução válida fracionária da relaxação linear

$$\frac{2}{3} + \frac{2}{3} = \frac{4}{3} > 1$$

Alternativamente, podemos obter a seguinte desigualdade do tipo (6.1):

$$x_{41} + x_{42} + x_{31} + x_{32} \geq 1 \quad (6.7)$$

Ao substituírmos os valores da relaxação linear, veremos que ela também é violada:

$$\frac{1}{3} + 0 + 0 + \frac{1}{3} = \frac{2}{3} < 1$$

Porém, todo o grafo é conectado. Existe alguma forma de encontrar possíveis restrições violadas em grafos conectados, mas fracionários?

A resposta é sim! Para tal, pense no grafo induzido da Figura 6.1.1 como um problema de fluxo: qual deveria ser o fluxo entre a origem (vértice 1) e o vértice 4, por exemplo? Em uma solução válida do caixeiro viajante, o valor do fluxo deveria ser 1. Na prática, porém, conseguimos ver que neste exemplo o valor é $\frac{2}{3}$. Como ele é menor que 1, encontramos uma desigualdade violada, pois sabemos que pelas restrições (6.1) o fluxo entre duas componentes quaisquer do grafo deve ter capacidade de pelo menos 1.

Podemos então encontrar cortes violados em grafos conectados a partir de soluções não-inteiras ao resolver o algoritmo de fluxo máximo entre a origem e todos os demais vértices do grafo. O problema de separação é então resolvido em tempo polinomial. Veja abaixo o algoritmo de separação completo, expandindo o passo 3 visto acima:

3. Verificação se restrição de eliminação de subciclos é violada:

- Começamos com uma solução viável $\mathbf{x}$ para a relaxação da (PI) correspondente ao vértice corrente.
- Criamos um grafo dirigido, cada vértice é uma cidade.
- Para cada $x_{ij} > 0$, adicionamos um arco de i para j com capacidade x_{ij} .

- (d) Verificamos se o grafo é desconectado e se a solução obtida é inteira. Se ambos os casos forem verdade, adicionamos os cortes necessários e voltamos ao passo 2. Senão, continue.
- (e) Se a solução é fracionária, seja 1 o vértice de origem. Calculamos o fluxo máximo de 1 para todos os demais vértices u do grafo.
 - i. Se o fluxo é menor que 1, significa que o corte mínimo entre esses vértices é menor que 1, e portanto existe um subconjunto U contendo u e não contendo 1 tal que

$$\sum_{i \in U, j \notin U} x_{ij} < 1.$$

Neste caso, adicionamos apenas esta restrição à relaxação da (PI) e repetimos.

- ii. Se o fluxo é maior que 1, significa que o corte mínimo entre esses vértices é maior que 1, e portanto para todos os subconjuntos U contendo u e não contendo 1, temos

$$\sum_{i \in U, j \notin U} x_{ij} \geq 1.$$

Não é necessária adicionar nenhuma restrição.

- (f) Se alguma restrição violada foi adicionada, retornamos ao passo 2 descrito acima. Senão, continuamos com o branching normalmente.

O algoritmo de fluxo máximo é executado muitas vezes: para cada relaxação linear resolvida e cujo grafo induzido é conectado e fracionário, resolvemos $|V| - 1$ vezes o fluxo máximo. Isto não parece tão eficiente, e na verdade nem é obrigatório: se apenas adicionarmos restrições quando encontrarmos soluções inteiras desconectadas, resolvemos o problema do mesmo jeito. Porém, na prática observamos que uma boa implementação do problema de separação utilizando fluxo máximo é capaz de acelerar consideravelmente a resolução do TSP.

Exercício 78. Considere agora um grafo não direcionado $G = (V, A)$ onde há apenas uma aresta entre i e j com distância d_{ij} . Este exemplo implica a simetria nas distâncias entre i, j e j, i . Reescreva a formulação do TSP baseada em um número exponencial de restrições de eliminação de subciclos para este caso. Utilize uma notação matemática apropriada.

Exercício 79. Desafio Imagine o mapa de uma cidade onde as esquinas são vértices e as ruas conectando as esquinas são arcos. Pense em algo parecido com um *grid*. Este grafo claramente não é completo. Também pode ter ruas que são mão mas não são contra-mão, etc. Considere um grafo $G(V, A)$ não completo que modele este mapa. Considere também um caminhão que deve partir de um ponto de origem, entregar encomendas em um subconjunto K de vértices na cidade ($K < V$) e voltar ao ponto de origem.

Escreva uma formulação inteira que não assuma um grafo completo e que encontre a rota mínima para o caminhão. Considere que pode não haver ligação direta entre dois pontos quaisquer de K .

6.1.2 Formulação alternativa: MTZ (opcional)

A formulação acima, que possui um número exponencial de restrições, é a única forma de resolver o TSP via Programação Inteira? Na verdade não: existem formulações para o TSP que possuem

um número de restrições polinomial em relação a $|V|$. Chamamos tais formulações de **compactas**, no sentido de que “para instâncias moderadas ou relativamente grandes, suas restrições cabem inteiramente na memória de um computador comum”. Para tentar resolver estas formulações, não é necessário um algoritmo branch-and-cut contendo algoritmos de separação. Porém, veremos nesta seção que uma formulação compacta não é necessariamente melhor que uma formulação com um número exponencial de restrições.

Em 1960, Miller, Tucker e Zimler propuseram uma formulação compacta que viria a ser conhecida como formulação MTZ para o TSP. Eles utilizaram variáveis inteiras adicionais que permitiram reformular o problema com menos restrições. Em conjunto com as variáveis x_{ij} , incluíram variáveis inteiras (mas não binárias) u_i para todo vértice $i \in V$.

A ideia é a seguinte: Suponha sem perda de generalidade que o caixeiro sempre comece da cidade 1. Então, $u_1 = 1$. A segunda cidade visitada, chamada de i , deve ter $u_i = 2$. A terceira visitada, j deve ter $u_j = 3$, e assim sucessivamente. A última cidade k visitada antes de voltar à origem deve ter $u_k = |V|$. O seguinte conjunto de restrições, que substitui as desigualdades de eliminação de subciclos acima, garante que isso aconteça:

$$\begin{aligned} u_1 &= 1 \\ 2 &\leq u_i \leq |V| && \forall i \in V, i \neq 1 \\ u_i - u_j + 1 &\leq (|V| - 1)(1 - x_{ij}) && \forall (i, j) \in A, i \neq 1, j \neq 1 \end{aligned}$$

As primeiras restrições garantem que os u_i 's devem ter valores entre 1 e $|V|$, com $u_1 = 1$. O último conjunto de restrições é menos intuitivo, mas verifique você mesmo que elas garantem a sequência de números correta:

- Se $x_{ij} = 1$, isto é, atravessamos o arco (i, j) , então o lado direito é zero e temos que $u_i + 1 \leq u_j$. Ou seja, u_j deve ser pelo menos uma unidade maior que u_i . O conjunto completo destas restrições em conjunto com as restrições de limite garantem que se $x_{ij} = 1$, a diferença $u_j - u_i$ será efetivamente 1. A sequência será preservada pois nunca ocorrerão u_i 's repetidos.
- Se $x_{ij} = 0$, então temos que a diferença entre u_i e u_j é pelo menos $|V| - 2$. Todo par u_i, u_j entre 2 e $|V|$ respeita este caso.

Exercício 80. Mostre que o número máximo de restrições que garantem a não ocorrência de subciclos na formulação MTZ é $|V|^2 - 2|V| + 1$.

Comparação entre formulações

Qual formulação é melhor? Se você tivesse que resolver o TSP, qual escolheria?

Nem sempre é fácil responder a esta pergunta, mas no caso dessas duas formulações para o TSP possuímos uma resposta. Contra-intuitivamente, como mencionado no início desta seção, sabemos que a formulação original é objetivamente melhor que a MTZ.

Uma forma objetiva de comparar duas formulações é medir o quão próximo do ótimo está o valor da relaxação linear de cada uma delas. Vamos fazer isso indiretamente. Ignore no momento a questão do número exponencial de restrições de eliminação de subciclos na primeira formulação.

Vamos começar, na MTZ, reordenando os termos das restrições que garantem a sequência correta dos u_i . Considere um arco (i, j) qualquer:

$$\begin{aligned}
u_i - u_j + 1 &\leq (|V| - 1)(1 - x_{ij}) \\
\frac{u_i - u_j + 1}{|V| - 1} &\leq 1 - x_{ij} \\
x_{ij} &\leq 1 - \left(\frac{u_i - u_j + 1}{|V| - 1} \right) \\
x_{ij} &\leq \left(\frac{u_j - u_i}{|V| - 1} \right) + \left(1 - \frac{1}{|V| - 1} \right)
\end{aligned}$$

Agora imagine um ciclo formado por vértices em um subconjunto W . Este ciclo possui $|W|$ arcos. Ao somar a restrição acima para todos os arcos do ciclo, temos que:

$$\sum_{(i,j) \text{ no ciclo}} x_{ij} \leq \left(1 - \frac{1}{|V| - 1} \right) |W| \quad (6.8)$$

Observe que os termos $\left(\frac{u_j - u_i}{|V| - 1} \right)$ se cancelam. Para verificar, considere $W = (i, j, k)$ com um ciclo formado pelos arcos (i, j) , (j, k) , (k, i) . Ao somar os termos:

$$\left(\frac{u_j - u_i}{|V| - 1} \right) + \left(\frac{u_k - u_j}{|V| - 1} \right) + \left(\frac{u_i - u_k}{|V| - 1} \right) = 0$$

Agora vamos lembrar a segunda versão da restrição de eliminação de subciclos da primeira formulação, para o mesmo subconjunto W :

$$\sum_{(i,j) \in W} x_{ij} \leq |W| - 1$$

Observe como o lado direito da desigualdade (6.2) é mais apertado que o da desigualdade (6.8). Em especial, $1 > \frac{|W|}{|V| - 1}$ pois $|W| < |V| - 1$. Restrições mais apertadas podem ser vistas como uma melhor aproximação da envoltória convexa do problema, e consequentemente proveem valores de relaxação linear mais próximos do ótimo inteiro.

Geometricamente, ao adicionarmos as variáveis u_i , estamos aumentando a dimensão do problema, o que por outro lado nos permite reduzir o número de restrições. Se para todo subconjunto $W \subset V$ fizermos a mesma soma acima, estamos eliminando totalmente as variáveis u_i da formulação e reescrevendo a mesma como uma formulação com um número exponencial de desigualdades, mas com dimensão menor. Diz-se que estamos **projetando** uma formulação com dimensão maior em uma outra com dimensão menor e a projeção é equivalente à formulação MTZ original. Como as desigualdades de eliminação de subciclos são mais apertadas na primeira que na projeção da segunda, podemos inferir que a primeira formulação é mais forte.

A MTZ não é a única formulação do TSP com um número polinomial de restrições. Há também, por exemplo, formulações baseadas em fluxo de uma ou múltiplas commodities. Porém, nenhuma delas é mais forte que a formulação original vista acima.

6.2 Problema da mochila

Suponha que uma mochila pode carregar o peso máximo b . Existem n tipos de itens, e cada item tem peso $a_i > 0$, e valor c_i . Queremos escolher itens para carregar na mochila que maximizem o seu valor. Ou seja,

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \sum_{i=1}^n a_i x_i \leq b \\ & \mathbf{x} \geq 0, \quad \mathbf{x} \text{ inteiro.} \end{aligned}$$

Exercício 81. Prove que é impossível carregar a mochila com um valor maior do que $(c_i/a_i)b$ para todo i . Ache o ótimo da relaxação linear.

Se apenas um item de cada tipo pode ser selecionado, então precisamos forçar $\mathbf{x} \leq \mathbf{1}$. Este é o problema da mochila 0-1. Definimos

$$K = \left\{ \mathbf{x} \in \{0, 1\}^n : \sum_{i=1}^n a_i x_i \leq b \right\}.$$

Exercício 82.

- (a) No problema 0-1, imagine que o item j só tem valor se o item i for levado também. Como representar este fato na formulação?
- (b) Imagine que é necessário levar ao menos i ou j . Como representar isso?
- (c) Agora, não podemos levar i e j juntos. Como formular?

Vamos agora apresentar uma formulação alternativa. Um subconjunto $C \subset \{1, \dots, n\}$ é uma cobertura para a mochila se

$$\sum_{i \in C} a_i > b,$$

ou seja, é um subconjunto tal que nem todos os itens cabem na mochila ao mesmo tempo.

O subconjunto C é uma cobertura minimal se, para todo $j \in C$, vale que

$$\sum_{i \in C \setminus \{j\}} a_i \leq b.$$

Em palavras, se removermos qualquer elemento de C , é possível colocar todos os itens restantes na mochila. Considere agora

$$R = \left\{ \mathbf{x} \in \{0, 1\}^n : \text{Para todo } C \text{ cobertura minimal de } K, \sum_{i \in C} (1 - x_i) \geq 1. \right\}$$

As restrições $\sum_{i \in C} (1 - x_i) \geq 1$ podem ser equivalentemente reescritas como $\sum_{i \in C} x_i \leq |C| - 1$.

Exercício 83. Seja $K = \{\mathbf{x} \in \{0, 1\}^3 : 3(\mathbf{x}_1 + \mathbf{x}_2 + \mathbf{x}_3) \leq 5\}$.

- (i) Calcule todos os pontos de K .
- (ii) Quais são todas as coberturas minimais?
- (iii) Expresse as desigualdades que definem todas as coberturas minimais.
- (iv) Expresse todos os pontos de R .
- (v) Conclua que otimizar em K é a mesma coisa que otimizar em R .
- (vi) Mostre entretanto que as relaxações lineares de K e R são diferentes. Se você fosse resolver a PI da mochila usando os algoritmos vistos, qual formulação teria sido melhor?

Exercício 84. Considere um problema da mochila 0-1 com $n = 3$ produtos, pesos $\mathbf{a} = (3 \ 2 \ 3)$, $\mathbf{c} = (1 \ 1 \ 1)$ e capacidade da mochila $b = 6$.

- (i) Escreva a formulação tradicional de programação inteira para resolver este problema.
- (ii) Escreva a formulação baseada em coberturas minimais para o mesmo problema.
- (iii) Calcule (na mão) os valores das relaxações lineares das duas formulações e diga qual é a mais forte.

Exercício 85. Mostre que, independente do exemplo, sempre teremos que $K = R$.

Estes exercícios mostraram que não existe uma única forma possível de modelar o problema da mochila, e que a formulação do tipo R , baseada em coberturas minimais, apresenta um limite de relaxação linear mais apertado que a formulação K , original. Porém, a formulação do tipo R pode possuir um número enorme de restrições, uma para cada possível cobertura minimal.

Na prática, podemos nos aproveitar das duas formulações utilizando um **branch-and-cut**. Em cada nó do branch-and-bound, resolvemos a relaxação linear. Porém, antes de prosseguir com o branching, executamos um algoritmo de separação para verificar se há alguma cobertura minimal cuja restrição associada é violada pela solução da relaxação linear. Se encontrarmos, podemos adicioná-la ao modelo e resolver o mesmo nó novamente, obtendo um valor menor e que pode reduzir nosso gap de otimalidade, facilitando a poda da árvore pelo branch-and-bound.

6.3 Problema das “várias mochilas”, ou geração de colunas

Considere o seguinte problema. Um chapa de metal de largura W é cortada em tiras mais finas. A indústria pode cortar tiras de m larguras diferentes. Ela recebe uma encomenda de b_i tiras de largura w_i , para cada $i = 1, \dots, m$. Qual é o número mínimo de chapas necessário para suprir a demanda?

Vamos supor que p seja um número grande o suficiente, maior que a quantidade de chapas necessária.

Exercício 86. Dê um exemplo de um valor razoável para p .

Temos então que p é o número de chapas disponíveis, onde assumimos que toda a demanda pode ser cumprida. Para modelar o problema, podemos definir variáveis de decisão z_{ij} que indicam quantas chapas de largura w_i serão cortadas na chapa j , onde i vai de 1 a m e j de 1 a p . Vamos definir também variáveis y_j que indicam se a chapa j será utilizada ou não.

Exemplo 20. Imagine que $W = 10$, $m = 3$, $w_1 = 3$, $w_2 = 4$, e $w_3 = 5$. Digamos $b_1 = 4$, $b_2 = 3$ e $b_3 = 3$. Certamente usaremos no máximo 10 chapas (quantas seriam se utilizássemos o critério discutido no Exercício acima?). Então teremos variáveis z_{ij} indicando quantas tiras do tipo i serão cortadas da chapa j , e variáveis y_j indicando quais das 10 chapas serão utilizadas. Daí teremos:

$$\begin{aligned} \min \quad & y_1 + \dots + y_{10} \\ \text{sujeito a} \quad & 3z_{1j} + 4z_{2j} + 5z_{3j} \leq 10y_j \text{ para todo } j = 1, \dots, 10 \\ & z_{i1} + \dots + z_{i10} \geq b_i, \text{ para } i = 1, 2, 3 \\ & \mathbf{y} \in \{0, 1\} \quad \mathbf{z} \geq 0 \quad \mathbf{z} \in \mathbb{Z}. \end{aligned}$$

Ou seja, minimizamos as chapas usadas, garantimos que cada chapa usada seja cortada de acordo com seu limite, cortamos o máximo de cada tira que precisamos, e garantimos que as variáveis são inteiros que fazem sentido.

Exercício 87. Escreva a formulação geral para este problema.

Infelizmente a formulação que você inventou acima não é muito boa na prática: o ótimo da PI costuma ficar longe do ótimo da relaxação linear, tornando algoritmos do tipo Branch-and-bound bastante ineficientes.

Exercício 88. Qual é o ótimo da relaxação linear?

Vamos inventar uma nova formulação para o problema. Definimos o conjunto:

$$S = \left\{ \mathbf{s} \in \mathbb{Z}^m : \sum_{i=1}^m \mathbf{w}^T \mathbf{s} \leq W, \quad \mathbf{s} \geq 0. \right\}$$

Ou seja, S representa o conjunto de todas as possíveis maneiras que podemos cortar a chapa de metal nas larguras limitadas.

Exercício 89. No exemplo acima, liste todos os vetores em S .

Sejam agora x_s variáveis inteiras de decisão que indicam quantas vezes utilizaremos a forma $s \in S$ para cortar uma chapa. Então temos a seguinte formulação:

$$\begin{aligned} \min \quad & \sum_{s \in S} x_s \\ \text{sujeito a} \quad & \sum_{s \in S} \mathbf{s}_i x_s \geq b_i \quad \text{para todo } i = 1, \dots, m \\ & \mathbf{x} \geq 0 \quad \mathbf{x} \text{ inteiro.} \end{aligned}$$

Exercício 90. Pare para ler e entender a formulação acima. Qual o problema desta formulação?

A parte boa é que, na prática, o ótimo da relaxação linear costuma estar muito perto do ótimo inteiro. As vezes basta apenas arredondar o ótimo da relaxação linear.

Dada a dificuldade exposta acima, vamos agora estudar uma estratégia para resolver este problema.

Exercício 91. Escreva a relaxação linear da formulação acima e a sua dual (use variáveis duais u_i para $i = 1, \dots, m$). Note que teremos uma restrição para cada $\mathbf{s} \in S$.

O problema dual não possui um número potencialmente enorme de variáveis, mas possui um número enorme de restrições. Imagine então que no problema original utilizamos apenas um subconjunto de S , digamos S' , para definir variáveis - ou seja, estamos relaxando o problema ao eliminar diversas variáveis. Então na dual teremos apenas as restrições indexadas por S' .

Assuma que resolvemos as relaxações lineares do modelo acima contando apenas com as colunas em S' . Sejam $\bar{\mathbf{x}}$ e $\bar{\mathbf{u}}$ um par primal-dual de soluções ótimas para os problemas indexados por S' . Estendemos $\bar{\mathbf{x}}$ para uma solução viável da relaxação linear fazendo $\bar{x}_s = 0$ para todo $\mathbf{s} \in S \setminus S'$.

Exercício 92. Por que esta solução ainda é viável? Por que ela não é necessariamente ótima?

Exercício 93. Argumente que se $\bar{\mathbf{u}}$ é viável para a dual original, então a nova $\bar{\mathbf{x}}$ estendida é ótima para a relaxação original (teorema forte? folgas complementares?).

Observe que, no problema dual, relaxamos as seguintes restrições:

$$\sum_{i=1}^m \mathbf{s}_i u_i \leq 1 \quad \forall \mathbf{s} \in S \setminus S'$$

Note então que $\bar{\mathbf{u}}$ será ótima para a relaxação original do dual se e somente se o valor abaixo é no máximo 1 (senão, uma restrição deixada de fora do dual foi violada).

$$\begin{aligned} \max \quad & \sum \bar{\mathbf{u}}_i \mathbf{s}_i \\ \text{sujeito a} \quad & \mathbf{s} \in S \end{aligned}$$

No dual, $\mathbf{u}$ são variáveis e $\mathbf{s}_i$ parâmetros ($\mathbf{s}_i$ diz quantas tiras de tamanho w_i serão tiradas quando utilizarmos a maneira $\mathbf{s}$ de cortar uma chapa). Agora, vamos pensar diferente: como conhecemos a solução do dual $\bar{\mathbf{u}}$, vamos tratar os $\mathbf{s}$ como variáveis. Queremos encontrar alguma forma de cortar a chapa $\mathbf{s}$ onde $\sum \mathbf{s}_i u_i > 1$, com a condição de que a forma $\mathbf{s}$ seja fisicamente possível de ser executada. Para isso escrevemos o modelo abaixo:

$$\begin{aligned} \max \quad & \sum \bar{\mathbf{u}}_i \mathbf{s}_i \\ \text{sujeito a} \quad & \sum_{i=1}^m w_i \mathbf{s}_i \leq W \\ & \mathbf{s} \geq 0 \quad \mathbf{s} \text{ inteiro.} \end{aligned}$$

Observe que temos exatamente o problema da mochila com valores iguais a $\bar{\mathbf{u}}$, pesos iguais a $\mathbf{w}$ e capacidade igual a W !

Digamos que $\mathbf{s}^*$ seja a solução ótima deste problema. Se o valor da função objetivo de $\mathbf{s}^*$ for maior que 1, então encontramos a restrição do dual que é a mais violada pela candidata a ótimo $\bar{\mathbf{u}}$. Então adicionamos a variável $x_{\mathbf{s}^*}$ à formulação restrita de (P), ou seja, $S' = S' \cup \mathbf{s}^*$. Em seguida, repetimos o processo, resolvendo a primal de novo, obtendo o valor dual e verificando se o ótimo do problema da mochila correspondente é menor ou igual a um.

Exemplo 21. Volte ao exemplo corrente desta seção. Comece com um conjunto $S' = \{(0, 0, 2), (2, 1, 0)\}$.

(i) Resolva o programa (P) e (D) de acordo com S' , ou seja, resolva o par

$$\begin{array}{ll}
 \min & \mathbf{x}_1 + \mathbf{x}_2 \\
 \text{sujeito a} & 0\mathbf{x}_1 + 2\mathbf{x}_2 \geq 4 \\
 & 0\mathbf{x}_1 + 1\mathbf{x}_2 \geq 3 \\
 & 2\mathbf{x}_1 + 0\mathbf{x}_2 \geq 3 \\
 & \mathbf{x} \geq 0.
 \end{array}
 \quad (P) \quad
 \begin{array}{ll}
 \max & 4\mathbf{u}_1 + 3\mathbf{u}_2 + 3\mathbf{u}_3 \\
 \text{sujeito a} & 2\mathbf{u}_3 \leq 1 \\
 & 2\mathbf{u}_1 + 1\mathbf{u}_2 \leq 1 \\
 & \mathbf{u} \geq 0.
 \end{array}
 \quad (D)$$

(ii) Note que o ótimo é $\bar{\mathbf{x}} = (3/2, 3)$ e $\bar{\mathbf{u}} = (0, 1, 1/2)$

(iii) Resolva agora a PI

$$\begin{array}{ll}
 \max & 0\mathbf{s}_1 + 1\mathbf{s}_2 + (1/2)\mathbf{s}_3 \\
 \text{sujeito a} & 3\mathbf{s}_1 + 4\mathbf{s}_2 + 5\mathbf{s}_3 \leq 10 \\
 & \mathbf{s} \geq 0 \quad \mathbf{s} \text{ inteiro.}
 \end{array}$$

(iv) Note que o ótimo é $\mathbf{s}^* = (0, 2, 0)$, de valor objetivo 2. Maior do que 1. Portanto precisamos adicionar este elemento no conjunto S' e recomeçar.

(v) Exercício: faça mais uma iteração.

Conteúdo extra Ao terminar o processo acima, resolvemos a relaxação linear e obtivemos a solução $\bar{\mathbf{x}} = (3/2, 2, 1/2)$ com os demais $x_s = 0$. Para continuar resolvendo o problema inteiro, temos que seguir com o branch-and-bound e fazer o branch na variável x_1 ou x_3 . Note que ao criar um novo subproblema na árvore (colocando, por exemplo, a restrição $x_1 \leq 1$), devemos resolver novamente a relaxação linear. Pode ser que esta relaxação necessite de mais colunas dentre as que ficaram de fora. Sabemos até agora que 4 é um limite inferior para o valor ótimo inteiro, mas ainda não temos a solução inteira ótima.

Este tipo de algoritmo, que mistura branch-and-bound com geração de colunas, é chamado de **branch-and-price** - o nome *price* é porque o problema de encontrar novas colunas é geralmente chamado de problema de *pricing*.

Note que é possível encontrar, na mão, uma solução ótima inteira de valor 4, cortando as seguintes chapas:

$$\begin{pmatrix} 2 & 1 & 0 \end{pmatrix} \\
 \begin{pmatrix} 2 & 1 & 0 \end{pmatrix} \\
 \begin{pmatrix} 0 & 0 & 2 \end{pmatrix} \\
 \begin{pmatrix} 0 & 1 & 1 \end{pmatrix}$$

Note que o corte da chapa $(0 \ 1 \ 1)$ não está ali nas colunas ótimas da relaxação linear. Ela eventualmente apareceria em um subproblema na árvore do branch-and-bound.

6.4 Alguns truques de formulação

Nesta breve seção, iremos fazer uma revisão de como formular como programação linear ou inteira algumas funções objetivo.

Valor absoluto

Considere:

$$\begin{array}{ll} \max & \sum c_j |x_j| \\ \text{sujeito a} & \mathbf{Ax} \leq \mathbf{b} \\ & \mathbf{x} \text{ livre.} \end{array}$$

Como reescrever a PL acima para que seja linear? Dica: transforme cada x_j em duas variáveis.

Máximos ou mínimos dentro da função objetivo

Imagine que temos várias funções objetivo $\mathbf{c}_1, \dots, \mathbf{c}_m$, e calculamos, para todo $k = 1, \dots, m$,

$$\begin{array}{ll} \max & \mathbf{c}_k \mathbf{x} \\ \text{sujeito a} & \mathbf{Ax} \leq \mathbf{b} \\ & \mathbf{x} \geq 0. \end{array}$$

Dentre todos eles, queremos o mínimo. Ou seja, estamos procurando

$$\begin{array}{ll} \min & \max_{k=1}^m \mathbf{c}_k \mathbf{x} \\ \text{sujeito a} & \mathbf{Ax} \leq \mathbf{b} \\ & \mathbf{x} \geq 0. \end{array}$$

Como modelar o problema acima como uma única programação linear? Dica: crie uma única nova variável que limite todas as programações de máximo originais.

Exercício 94. No problema abaixo, estamos procurando o vetor $\mathbf{x}$ que satisfaz as restrições e possui a maior entrada possível.

$$\begin{array}{ll} \max & \max_{k=1}^n \mathbf{x}_n \\ \text{sujeito a} & \mathbf{Ax} \leq \mathbf{b} \\ & \mathbf{x} \geq 0. \end{array}$$

Como adaptar o que vimos acima para este problema? Ou seja, quem são os $\mathbf{c}_k$?

Função objetivo fracionária

$$\begin{array}{ll} \min & \left(\frac{\mathbf{c}^T \mathbf{x} + \alpha}{\mathbf{d}^T \mathbf{x} + \beta} \right) \\ \text{sujeito a} & \mathbf{Ax} \leq \mathbf{b} \\ & \mathbf{x} \geq 0. \end{array}$$

No caso, α e β são constantes na função objetivo. A função objetivo é não linear, mas é possível linearizá-la utilizando a transformação de Charnes-Cooper, de 1962. Defina uma nova variável:

$$t = \frac{1}{\mathbf{d}^T \mathbf{x} + \beta}$$

Isto não altera as restrições, mas transforma a função objetivo em

$$\min(\mathbf{c}^T \mathbf{x} + \alpha)t$$

Continuamos tendo um termo não linear. Porém agora podemos definir variáveis $\mathbf{y} = t \cdot \mathbf{x}$. Multiplicando as restrições por t , a formulação passa a ser:

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{y} + \alpha t \\ \text{sujeito a} \quad & \mathbf{A}\mathbf{y} \leq \mathbf{b}t \\ & \mathbf{y} \geq 0 \\ & t \geq 0 \end{aligned}$$

Como $\mathbf{y} \geq 0$ e $\mathbf{x} \geq 0$, $t \geq 0$. Temos também:

$$t = \frac{1}{\mathbf{d}^T \mathbf{x} + \beta} \implies (\mathbf{d}^T \mathbf{x} + \beta)t = 1 \implies \mathbf{d}^T \mathbf{y} + \beta t = 1$$

O modelo completo fica:

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{y} + \alpha t \\ \text{sujeito a} \quad & \mathbf{A}\mathbf{y} \leq \mathbf{b}t \\ & \mathbf{d}^T \mathbf{y} + \beta t = 1 \\ & \mathbf{y} \geq 0 \\ & t \geq 0 \end{aligned}$$

Temos agora um problema de programação linear! Ao final, obtemos o vetor solução $(\mathbf{y}, t)$. Podemos obter o valor $\mathbf{x}$ original ao fazer $\mathbf{x} = \frac{\mathbf{y}}{t}$.


Capítulo 7

Otimização em grafos

7.1 Grafos

Esta seção está aqui apenas para estabelecer uma notação geral sobre grafos, reutilizando também a notação introduzida na última seção. Estes conceitos serão utilizados nas próximas aulas.

Um grafo $G(V, E)$ é um conjunto V de vértices e um conjunto E de arestas entre pares de vértices. Essas arestas podem ou não ter pesos associados. Se há uma aresta (de peso diferente de 0) entre dois vértices, eles são chamados de vizinhos. A soma dos pesos das arestas incidentes a um vértice é o seu grau. Se as arestas tem peso unitário, o grau corresponde ao número de vizinhos do vértice.



Caminhos

Dados dois vértices a e b , um caminho entre a e b é uma sequência de vértices


$$v_0 v_1 v_2 \dots v_n$$

tais que $v_0 = a$, v_i é vizinho de v_{i+1} e $v_n = b$. Um ciclo é um caminho entre a e a tal que o único vértice que aparece duas vezes é a . O comprimento de um caminho (ou ciclo) é o número de arestas contido na sua extensão.

Um grafo conexo é um grafo tal que entre quaisquer dois vértices há pelo menos um caminho. Uma árvore é um grafo conexo sem ciclos.


Direcionado

Um grafo é *direcionado* se cada aresta possui uma direção. Uma aresta com direção é chamada de arco. Para cada par de vértices definindo um arco, um deles é chamado de cauda e o outro de cabeça. Neste caso, utilizamos a notação $G(V, A)$ para representar um grafo com conjunto de vértices V e arcos A .




Matrizes

Nossa maneira favorita de representar grafos será usando matrizes. Há essencialmente dois tipos de matrizes que representam grafos. Numa matriz de adjacência, linhas e colunas são indexadas por vértices, e as entradas são 0 se eles não são vizinhos, ou 1 se eles são. No caso de grafos com peso, trocamos 1 pelo peso da aresta correspondente.




Alternativamente, podemos representar um grafo com uma matriz de *incidência*. Neste caso, linhas são indexadas por vértices, colunas por arestas, e entradas são diferentes de 0 se o vértice incide à aresta. A vantagem desta maneira é que ela permite codificar grafos dirigidos mais naturalmente. Neste caso, colocamos -1 se o vértice é a cauda do arco, e $+1$ se é a cabeça.



Cortes

Vamos considerar a seguinte notação. Se $S \subset V$, então $\delta(S)$ é o conjunto de arestas que são incidentes a exatamente um vértice de S (e portanto a um vértice fora de S). Se $v \in V$, então $\delta(v)$ será simplesmente o conjunto de arestas incidente a v .

Considere o grafo abaixo:




Exercício 95. Descreva o conjunto $\delta(\{s, a\})$.

Um st -corte é um conjunto de arestas da forma $\delta(U)$, onde $s \in U$ mas $t \notin U$. Note que, necessariamente, a remoção de um st -corte desconectará s de t no grafo.

Exercício 96. Expresse todos os st -cortes do grafo acima.


Fluxos

Um fluxo em um grafo $G(V, A)$ é uma atribuição de valores para os arcos de um grafo dirigido tal que, com exceção de uma fonte e um sorvedouro, a entrada é igual à saída em todos os vértices. Ou seja, um vértice, tipicamente chamado s , envia um fluxo através de cada arco em direção a um vértice t . Todos os vértices do grafo recebem e repassam este fluxo, sem adicionar ou remover qualquer parte dele. Cada arco, a princípio, só transmite o fluxo em uma determinada direção - portanto o problema é geralmente modelado em um grafo direcionado, onde os pesos dos arcos representam a capacidade máxima de transmissão. Considere a figura abaixo:



Emparelhamentos

Dado um grafo $G = (V, E)$, um subconjunto M de arestas satisfazendo a propriedade que nenhum par de arestas de M é incidente a um mesmo vértice é chamado de um emparelhamento. Ou seja, M define uma coleção de pares disjuntos de vértices do grafo. Um emparelhamento é chamado perfeito se todo vértice é incidente a uma aresta de M .



Vários problemas podem ser modelados como o problema de achar emparelhamentos em grafos. Por exemplo, imagine um grafo bipartido onde uma parte são cursos que devem ser ministrados num determinado horário, e a outra parte são as salas de aula disponíveis. Uma aresta existe se a sala tem tamanho suficiente para o curso correspondente. O problema de alocar cada curso em uma sala é o problema de encontrar um emparelhamento neste grafo.

Coberturas

Uma cobertura por vértices das arestas é uma escolha de alguns vértices tais que todas as arestas do grafo sejam incidentes a pelo menos um vértice da escolha.

Como exemplo de aplicação, considere as arestas como ruas e os vértices como esquinas. Queremos colocar câmeras nas esquinas de forma a cobrir o máximo número de ruas. Ao encontrar a cobertura por vértices mínima, escolhemos onde instalar as câmeras com menor custo.

Exercício 97. Argumente que um tamanho máximo de um emparelhamento é sempre menor ou igual ao tamanho mínimo de uma cobertura por vértices.

Um grafo é chamado de regular se todos os vértices tem o mesmo grau. Um grafo é bipartido se o conjunto de seus vértices pode ser particionado em dois conjuntos, e dentro de cada conjunto não há qualquer aresta.

Exercício 98. Prove que um grafo é bipartido se, e somente se, não há qualquer ciclo com um número ímpar de vértices.

Considere nos exercícios abaixo a matriz de incidência $\mathbf{N}$ como vista acima. Porém, no caso de um grafo não direcionado, substituímos os componentes -1 por 1.

Exercício 99. Dado um grafo $G = (V, E)$ com pesos $c_e > 0$ para cada aresta, formule como uma PI o problema de achar um emparelhamento que tenha peso máximo (o emparelhamento não precisa ser perfeito).

Exercício 100. Dado um grafo $G = (V, E)$ e pesos $c_e > 0$, uma cobertura por arestas é um conjunto de arestas tal que cada vértice do grafo é incidente a pelo menos uma aresta do conjunto. Formule como uma PI o problema de achar uma cobertura por arestas de peso mínimo.


Exercício 101. Dado um grafo $G = (V, E)$ (sem peso algum), uma cobertura por vértices é um conjunto de vértices tal que cada aresta do grafo é incidente a pelo menos um vértice do conjunto. Formule o problema de encontrar uma cobertura por vértices de menor tamanho possível como uma PI.

Exercício 102. Use dualidade para mostrar que o tamanho máximo de um emparelhamento é menor ou igual à quantidade mínima de vértices necessária para formar uma cobertura por vértices.

7.2 Fluxos

Considere a seguinte situação: você deseja ter uma video-conferência com sua colega que se encontra no Japão. Supondo que vocês não tenham acesso direto a um dos cabos submarinos que atravessam o Pacífico, os dados dessa vídeo conferência deverão percorrer uma rede de servidores através do planeta. A questão é: qual a maior quantidade de dados que podem atravessar a rede?

Naturalmente, modelamos este problema como um problema em grafos. Um vértice, tipicamente chamado s , envia um fluxo através de cada arco em direção a um vértice t . Todos os vértices do grafo recebem e repassam este fluxo, sem adicionar ou remover qualquer parte dele. Cada arco, a princípio, só transmite o fluxo em uma determinada direção - portanto o problema será modelado em um grafo direcionado, e possui uma capacidade máxima de transmissão. Considere a figura abaixo:



Em termos da matriz de incidência, codificamos da seguinte forma. Se um arco “chega” em um vértice, ela incide como $+1$. Se ela “sai” de um vértice, ela incide como -1 . Dessa forma, ao olharmos para a matriz, sabemos exatamente a direção de cada arco (e esses sinais também serão convenientes da modelagem do problema como uma PL):

$$\mathbf{N} = \begin{pmatrix} -1 & -1 & 0 & 0 & 0 & 0 \\ +1 & 0 & -1 & +1 & -1 & 0 \\ 0 & +1 & +1 & -1 & 0 & -1 \\ 0 & 0 & 0 & 0 & +1 & +1 \end{pmatrix}.$$

As linhas representam na ordem os vértices s, a, b, t .

Um fluxo é uma atribuição de valores para cada arco, digamos dada por um vetor $\mathbf{x} \in \mathbb{R}^{|A|}$, e deve satisfazer duas propriedades: deve ser menor que a capacidade do arco, e com exceção dos vértices s e t , o fluxo que entra deve ser igual ao que sai. Seja $\mathbf{N}'$ a matriz de incidência do grafo que tem as linhas correspondentes a s e t removidas. Quando dizemos que para todos os outros vértices o fluxo que entra é igual ao que sai, estamos dizendo que

$$\mathbf{N}'\mathbf{x} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$


Dizer que o fluxo é menor do que a capacidade é equivalente a

$$\mathbf{x} \leq (30 \ 20 \ 30 \ 10 \ 25 \ 15)^T.$$

A função objetivo é o fluxo que sai de s (e que será igual ao que chega em t). Ou seja, o problema se torna

$$\begin{aligned}
 &\max && x_{sa} + x_{sb} \\
 \text{sujeito a} &&& x_{sa} - x_{ab} + x_{ba} - x_{at} = 0 \\
 &&& x_{sb} + x_{ab} - x_{ba} - x_{bt} = 0 \\
 &&& 0 \leq \mathbf{x} \leq (30 \ 20 \ 30 \ 10 \ 25 \ 15)^T
 \end{aligned}$$


Note agora que para cada conjunto de vértices U contendo s e não contendo t , o fluxo máximo de s para t não pode ser maior que a capacidade das arestas indo de dentro para fora de U .



Em outras palavras: o menor valor possível de todos os st -cortes é um limitante superior para o valor máximo de um st -fluxo. Veremos a seguir dois fatos extremamente importantes:

- (i) Se as capacidades de cada arco são números inteiros, então sempre existe um st -fluxo de valor máximo em que todo fluxo é inteiro!
- (ii) O valor máximo de um st -fluxo é igual ao valor mínimo de um st -corte.

Exercício 103. Ache o maior st -fluxo que você consiga no grafo abaixo.



Ache o menor st -corte. Deu o mesmo valor? Se sim, é possível melhorar algum deles?

7.3 Matrizes totalmente unimodulares

Dada uma matriz qualquer $\mathbf{A}$, dizemos que $\mathbf{B}$ é uma submatriz de $\mathbf{A}$ se $\mathbf{B}$ for obtida após algumas linhas e/ou colunas de $\mathbf{A}$ serem deletadas.

Exercício 104. Escreva todas as submatrizes de tamanho 2×2 da matriz abaixo

$$\begin{pmatrix} 2 & 1 & 0 \\ -1 & 3 & 4 \\ -2 & 5 & -3 \end{pmatrix}$$

Exercício 105. Quantas submatrizes 2×2 uma matriz $n \times m$ possui?

- Dizemos que $\mathbf{A}$ é uma matriz *totalmente unimodular* (TU) se o determinante de qualquer submatriz quadrada de $\mathbf{A}$ não-singular for igual a $+1$ ou -1 . Uma matriz TU pode ter também submatrizes singulares com determinante igual a zero.

Exercício 106. Quais são os possíveis números que podem ser entradas de uma matriz totalmente unimodular?

Exercício 107. Quais são as possíveis submatrizes 2×2 que podem aparecer em uma matriz totalmente unimodular?

Exercício 108. A matriz abaixo é totalmente unimodular?

$$\begin{pmatrix} 1 & -1 & 0 \\ 0 & 1 & 1 \\ -1 & 0 & 1 \end{pmatrix}$$

Por que se importar com matrizes totalmente unimodulares? Por conta da Regra de Gabriel¹. A regra diz que:

$$\mathbf{Ax} = \mathbf{b} \iff \mathbf{x} = \mathbf{A}^{-1}\mathbf{b} \iff \forall i : x_i = \frac{\det(\mathbf{A}^i)}{\det(\mathbf{A})}$$

onde $\mathbf{A}^i$ representa a matriz original $\mathbf{A}$ mas com a i -ésima coluna trocada por $\mathbf{b}$.

Note que se a matriz $\mathbf{A}$ for totalmente unimodular e o vetor $\mathbf{b}$ for inteiro, então toda solução básica do sistema $\mathbf{Ax} = \mathbf{b}$ será inteira. Isto ocorre pois para qualquer submatriz quadrada formando uma base $\mathbf{A}_B$, o determinante será -1 ou 1 (considerando o posto completo da base) e o determinante de $\mathbf{A}_B^i$ será também inteiro.

Desta forma, se possuímos uma PI com matriz de restrições $\mathbf{A}$ totalmente unimodular e vetor $\mathbf{b}$ inteiro, então ao resolver sua relaxação linear obteremos uma solução básica ótima que será inteira e resolverá a PL original.

Exercício 109. Encontre todas as soluções do sistema abaixo em que no máximo duas variáveis sejam diferentes de 0.

$$\begin{pmatrix} 1 & -1 & 1 & 0 \\ -1 & 1 & 0 & 1 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 4 \\ 5 \end{pmatrix}$$

Teorema 16. A matriz de incidência de um grafo dirigido é totalmente unimodular.

Demonstração. Vamos mostrar por indução. No caso base, note que todas as matrizes 1×1 tem determinante igual a 0, $+1$ ou -1 . Agora suponha que todas as submatrizes de tamanho $r \times r$ tem determinante 0, $+1$ ou -1 . Considere $\mathbf{B}$ uma matriz $(r+1) \times (r+1)$. Três casos:

¹Gabriel... Cramer

- Alguma coluna de $\mathbf{B}$ é nula. Então $\mathbf{B}$ tem determinante zero.
- Alguma coluna de $\mathbf{B}$ tem uma única entrada não-nula. Então fazendo a expansão de Laplace por coluna, o determinante de $\mathbf{B}$ será $\pm$ o determinante de uma matriz $r \times r$, e portanto o de $\mathbf{B}$ será 0, +1 ou -1.
- Todas as colunas de $\mathbf{B}$ possuem duas entradas não nulas. Neste caso a soma de todas as linhas de $\mathbf{B}$ é 0, e portanto o determinante de $\mathbf{B}$ é 0.

□

Exemplo 22. Considere a matriz do exemplo anterior:

$$\mathbf{N} = \begin{pmatrix} -1 & -1 & 0 & 0 & 0 & 0 \\ +1 & 0 & -1 & +1 & -1 & 0 \\ 0 & +1 & +1 & -1 & 0 & -1 \\ 0 & 0 & 0 & 0 & +1 & +1 \end{pmatrix}.$$

Teorema 17. *Seja $\mathbf{M}$ uma matriz totalmente unimodular. Então*

- (i) $\mathbf{M}^T$ é totalmente unimodular.
 - (ii) $(\mathbf{M}|\mathbf{I})$ é totalmente unimodular.
 - (iii) $(\mathbf{M}|\mathbf{0})$ é totalmente unimodular.
 - (iv) Qualquer submatriz de $\mathbf{M}$ é totalmente unimodular.
-

Agora vamos formalizar o resultado discutido anteriormente para alguns tipos de PLs:

Teorema 18. *Seja $\mathbf{M}$ uma matriz totalmente unimodular. Se cada uma das PLs abaixo for limitada e viável, então existem soluções ótimas que são inteiras.*

- (i) $\max \mathbf{c}^T \mathbf{x}$ com $\mathbf{M}\mathbf{x} = \mathbf{b}$ e $\mathbf{x} \geq 0$, desde que $\mathbf{b}$ seja inteiro.
 - (ii) $\max \mathbf{c}^T \mathbf{x}$ com $\mathbf{M}\mathbf{x} = 0$ e $0 \leq \mathbf{x} \leq \mathbf{d}$, desde que $\mathbf{d}$ seja inteiro.
 - (iii) $\min \mathbf{d}^T \mathbf{y}$ com $(\mathbf{M}|\mathbf{I})\mathbf{y} \geq \mathbf{c}$, desde que $\mathbf{c}$ seja inteiro.
-

A idéia do teorema acima é que as soluções ótimas básicas das PLs são obtidas resolvendo sistemas de equações formados por submatrizes de $\mathbf{M}$ quadradas, isto é, com o mesmo número de variáveis e equações, e portanto unimodulares. Se o lado direito é inteiro, soluções desses sistemas só podem ser inteiras devido à Regra de Cramer.

Teorema 19. *Em um problema de achar o fluxo máximo com capacidades inteiras nos arcos, qualquer solução básica ótima será um fluxo inteiro.*

Demonstração. Segue basicamente do fato que o problema é modelado com uma PL do tipo

$$\begin{aligned} \max \quad & \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{M}\mathbf{x} = 0 \\ & 0 \leq \mathbf{x} \leq \mathbf{d}, \end{aligned}$$


onde $\mathbf{M}$ é uma matriz totalmente unimodular.

□

7.3.1 Exemplo

Exercício 110. Escreva a PL seguinte, correspondente à figura abaixo, no formato matricial. Em seguida escreva a sua dual.

$$\begin{aligned}
 \max \quad & \mathbf{x}_1 + \mathbf{x}_2 \\
 \text{sujeito a} \quad & \mathbf{x}_1 - \mathbf{x}_3 + \mathbf{x}_4 - \mathbf{x}_5 = 0 \\
 & \mathbf{x}_2 + \mathbf{x}_3 - \mathbf{x}_4 - \mathbf{x}_6 = 0 \\
 & 0 \leq \mathbf{x} \leq (30 \ 20 \ 30 \ 10 \ 25 \ 15)^T
 \end{aligned}$$



Teremos

$$\begin{aligned}
 \max \quad & (1 \ 1 \ 0 \ 0 \ 0 \ 0) \mathbf{x} \\
 \text{sujeito a} \quad & \begin{pmatrix} 1 & 0 & -1 & 1 & -1 & 0 \\ 0 & 1 & 1 & -1 & 0 & -1 \\ 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix} \mathbf{x} \leq \begin{pmatrix} 0 \\ 0 \\ 30 \\ 20 \\ 30 \\ 10 \\ 25 \\ 15 \end{pmatrix} \\
 & \mathbf{x} \geq 0.
 \end{aligned}$$

Cuja formulação dual é:

$$\begin{aligned}
 \min \quad & (0 \ 0 \ 30 \ 20 \ 30 \ 10 \ 25 \ 15)^T \mathbf{y} \\
 \text{sujeito a} \quad & \begin{pmatrix} 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ -1 & 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & -1 & 0 & 0 & 0 & 1 & 0 & 0 \\ -1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & -1 & 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix} \mathbf{y} \geq \begin{pmatrix} 1 \\ 1 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix} \\
 & \mathbf{y}_1, \mathbf{y}_2 \text{ livres, e } \mathbf{y}_3, \dots, \mathbf{y}_8 \geq 0
 \end{aligned}$$

Note os fatos a seguir a respeito do dual:

- (i) Está no formato do item (iii) do Teorema 18, logo qualquer solução básica ótima será inteira. Ou seja, os itens (ii) e (iii) são um par primal-dual.

- (ii) Pela regra de Cramer e uma vez que o vetor de restrições só tem entradas iguais a $+1$ ou 0 , os valores da solução serão $+1$ ou 0 .
- (iii) As duas primeiras colunas da matriz correspondem aos dois vértices diferentes de s e t (no caso, a e b) e as demais à cada arco do grafo. Seja U o conjunto de vértices cujo valor foi igual a $+1$, adicionado de s .
- (iv) As linhas da matriz correspondem aos arcos. Se $u \in U$ (ou seja, $\mathbf{y}_u = 1$) então a linha correspondente a qualquer arco saindo de u terá um -1 . Se o vértice de chegada também está em U , então fica $-1 + 1 = 0$, ok. Se o vértice de chegada não está em U , teremos que adicionar a variável correspondente a este arco.
- (v) Ou seja: as entradas iguais a $+1$ na solução identificarão um conjunto de vértices U e um conjunto de arcos que vão de dentro pra fora deste conjunto, ou seja, $\delta^-(U)^2$, que é exatamente um st -corte. O valor objetivo da solução será precisamente a soma das capacidades deste conjunto.
- (vi) Se as capacidades não fossem necessariamente inteiras, toda a análise das regiões viáveis acima valeria - a única diferença é que o valor objetivo do corte seria possivelmente não-inteiro.

Através do exemplo acima, o teorema a seguir fica claro:

Teorema 20. *O valor máximo de um st -fluxo é igual ao valor mínimo de um st -corte.*

Exercício 111. Volte ao exercício 103. Escreva as PI's correspondentes aos problemas de achar um st -fluxo máximo e um st -corte mínimo, em formatos correspondentes ao Teorema 18. Exiba as soluções $\mathbf{x}$ e $\mathbf{y}$, e verifique que (1) $\mathbf{x}$ é inteira; (2) $\mathbf{y}$ identifica um corte, como feito acima; (3) ambos os ótimos das PLs são iguais.

Exercício 112. Se um arco pertence a um st -corte de capacidade mínima, o que podemos dizer a respeito do fluxo através deste arco em um st -fluxo de valor máximo?

Exercício 113. É verdade que os arcos cujo fluxo é igual à sua capacidade são os que pertencem a um corte mínimo?


7.4 O método de Ford e Fulkerson — um algoritmo primal-dual (leitura opcional)

Como vimos, para resolver um problema de fluxo-máximo em uma rede direcionada, é suficiente resolver a programação linear. Isso pode ser feito de forma satisfatoriamente eficiente, através do simplex, por exemplo. Entretanto, por ser um problema tão relevante e ubíquo, métodos específicos para o problema de fluxo máximo existem. O mais antigo e famoso deles é o método de Ford e Fulkerson.


Explicaremos a seguir como funciona. Primeiro, faremos a descrição combinatória. Depois entenderemos como este método na verdade pode ser visto como uma maneira de resolver as programações primais e duais baseados nas condições de folga complementares.

²Se em um grafo não direcionado $\delta(U)$ é o conjunto de arestas entre U e o complemento de U , em um grafo direcionado podemos extrapolar a notação e definir $\delta^-(U)$ como os arcos que saem de U para seu complemento e $\delta^+(U)$ como os arcos que chegam em U vindos do complemento.


- (a) Como entrada do problema, temos um grafo dirigido G , com uma fonte s e sorvedouro t . Todos os arcos possuem uma capacidade.




- (b) Começamos com um fluxo viável. No caso, o óbvio: o fluxo em todos os arcos igual a 0. Para auxílio na visualização, colocarei ao lado direito o grafo com a capacidade disponível.




- (c) Encontramos então um caminho de s para t cuja capacidade disponível seja positiva em todos os arcos. Aumentamos o fluxo o máximo possível, e diminuimos a capacidade disponível de acordo.




- (d) Repetimos.



- (e) O ponto crucial do algoritmo de Ford e Fulkerson é que estes caminhos não precisam ter a mesma direção dos arcos. De fato, podemos achar um arco no sentido oposto ao caminho, e ao invés de aumentarmos o fluxo neste arco, iremos diminuir. Portanto: nos arcos na mesma direção do caminho, precisamos ter capacidade disponível (logo algo > 0 no grafo da direita). Nos arcos no sentido oposto, precisamos ter fluxo disponível para retirar (logo algo > 0 no grafo original, na esquerda).



- (f) Concluimos então repetindo os passos acima, sempre que possível. No caso abaixo, acabamos escolhendo mais dois caminhos onde somente fizemos aumentar o fluxo em qualquer arco.



Observação: Os passos de “encontrar o caminho” foram descritos de modo abstrato, motivo pelo qual nos referimos ao Método de Ford e Fulkerson, e não Algoritmo. Ao fazer estas escolhas, determinamos qual foi a prioridade para escolher os caminhos. Por exemplo, se usarmos BFS, o algoritmo é então conhecido como Edmonds-Karp, e tem complexidade $O(|E|^2|V|)$.

Note que em cada passo, o algoritmo sempre aumenta o valor do fluxo em pelo menos uma unidade. Portanto não é possível que ele não termine.

Vamos agora entender como este algoritmo pode ser visto como um algoritmo de atualização de valores de variáveis primal-dual.

Neste exemplo acima, temos:

$$\begin{array}{ll}
 \max & (1 \ 1 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0) \mathbf{x} \\
 \text{sujeito a} & \begin{pmatrix} 1 & 0 & -1 & -1 & -1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 1 & -1 & 0 & 0 \\ 0 & 1 & 1 & 0 & 0 & -1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 1 & -1 & 0 & -1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \end{pmatrix} \mathbf{x} \begin{array}{l} = \\ = \\ = \\ = \\ \leq \\ \leq \\ \leq \\ \leq \\ \leq \\ \leq \\ \leq \\ \leq \\ \leq \end{array} \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 10 \\ 10 \\ 2 \\ 4 \\ 8 \\ 9 \\ 10 \\ 6 \\ 10 \end{pmatrix} \\
 & \mathbf{x} \geq 0.
 \end{array}$$

Cuja formulação dual é:

$$\begin{array}{ll}
 \min & (0 \ 0 \ 0 \ 0 \ 10 \ 10 \ 2 \ 4 \ 8 \ 9 \ 10 \ 6 \ 10)^T \mathbf{y} \\
 \text{sujeito a} & \begin{pmatrix} 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ -1 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ -1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ -1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & -1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & -1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & -1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix} \mathbf{y} \geq \begin{pmatrix} 1 \\ 1 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix} \\
 & \mathbf{y}_1, \dots, \mathbf{y}_4 \text{ livres, e } \mathbf{y}_3, \dots, \mathbf{y}_{11} \geq 0
 \end{array}$$

(a) Começamos com as soluções abaixo, de mesmo valor objetivo.

$$\mathbf{x}^T = (0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0)$$

$$\mathbf{y}^T = (1 \ 1 \ 1 \ 1 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0)$$

Note que as condições de folga complementares estão “satisfeitas”, mas que $\mathbf{y}$ não é viável. Lembre-se que as primeiras quatro variáveis do $\mathbf{y}$ correspondem a vértices. O fato de eles serem 1 indicam para nós que este vértice é “alcançável” a partir de s . Iremos agora atualizar ambas as soluções, de modo que as CFC permaneçam “satisfeitas”, mas que $\mathbf{y}$ se aproxime de ser viável.

(b) Aumentamos o $\mathbf{x}$. Ainda não é possível alterar o $\mathbf{y}$.

$$\mathbf{x}^T = (8 \ 0 \ 0 \ 0 \ 8 \ 0 \ 0 \ 0 \ 8)$$

$$\mathbf{y}^T = (1 \ 1 \ 1 \ 1 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0)$$

(c) Sempre que possível, atualizaremos o y para que se torne mais viável.

$$\mathbf{x}^T = (8 \ 2 \ 0 \ 0 \ 8 \ 2 \ 0 \ 0 \ 10)$$

$$\mathbf{y}^T = (1 \ 1 \ 1 \ 1 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 1)$$

(d) Nada se altera no $\mathbf{y}$. Todos os vértices permanecem “alcançáveis”, e não é possível aumentar a penúltima variável sem destruir as CFC.

$$\mathbf{x}^T = (8 \ 6 \ 0 \ 4 \ 4 \ 6 \ 0 \ 4 \ 10)$$

$$\mathbf{y}^T = (1 \ 1 \ 1 \ 1 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 1)$$

(e) O vértice (a) deixou de ser “alcançável”. Seu 1 é removido. Para não piorar a viabilidade, podemos adicionar uma aresta, e nota que isso não piora as CFC (pois (a) deixou de ser alcançável com uma aresta que ficou satisfeita com igualdade).

$$\mathbf{x}^T = (10 \ 6 \ 0 \ 4 \ 6 \ 6 \ 2 \ 6 \ 10)$$

$$\mathbf{y}^T = (0 \ 1 \ 1 \ 1 \ 1 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 1)$$

(f) Os vértices (d) e (b) deixaram de ser “alcançáveis”. Seus 1s são removidos. Note que (d) ainda é “vizinho” de vértices alcançável, portanto precisamos compensar aquela aresta. Os vértices não alcançáveis porque não tem vizinhos alcançáveis não criam problemas. A aresta que havia sido adicionada para o (d) deve ser removida junto com ele.

$$\mathbf{x}^T = (10 \ 9 \ 0 \ 4 \ 6 \ 9 \ 5 \ 9 \ 10)$$

$$\mathbf{y}^T = (0 \ 0 \ 1 \ 0 \ 1 \ 0 \ 0 \ 0 \ 0 \ 1 \ 0 \ 0 \ 0)$$

Note que as CFC permanecem válidas, mas $\mathbf{y}$ ficou viável. Ademais, o vetor $\mathbf{y}$ indica precisamente um corte de valor mínimo: $U = \{S, c\}$ com as arestas 1a e 6a definindo o corte, de valor 19.

7.5 Emparelhamentos e coberturas


Relembrando:

- Dado um grafo $G = (V, E)$, não direcionado, um emparelhamento M é um subconjunto de E tal que nenhum vértice do grafo é incidente a duas arestas de M .

Um emparelhamento é chamado de perfeito se todo vértice do grafo é incidente a exatamente uma aresta do emparelhamento. Em geral, estaremos interessados em dois tipos de questões acerca de emparelhamentos:

- Qual é o emparelhamento máximo? Aqui, “máximo” pode significar “de maior tamanho” ou “de maior custo”.
- Qual é o emparelhamento perfeito de custo mínimo? Aqui, assumimos que existe um emparelhamento perfeito, e dentre todos eles procuramos o de custo mínimo.

Seja $\mathbf{N}$ a matriz de incidência do grafo não direcionado. Por exemplo, para o grafo:



a matriz correspondente é:

$$\mathbf{N} = \begin{pmatrix} 1 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 & 0 \end{pmatrix}$$

A matriz de incidências em um grafo não direcionado não é necessariamente totalmente unimodular. Por exemplo, note que a matriz de incidências de um grafo completo com três vértices possui determinante igual a -2:

$$\mathbf{N} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix}$$

Para responder a pergunta (i) ali em cima, formulamos a PI:

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{N}\mathbf{x} \leq \mathbf{1} \\ & \mathbf{x} \geq 0 \\ & \mathbf{x} \text{ inteiro.} \end{aligned}$$

No caso, $\mathbf{x}$ é vetor de variáveis de decisão indicando se a aresta $e \in E$ faz parte do emparelhamento ou não.

Quando $\mathbf{c} = \mathbf{1}$, estamos basicamente buscando o emparelhamento de maior cardinalidade. As desigualdades $\mathbf{N}\mathbf{x} \leq \mathbf{1}$ dizem precisamente que para cada vértice, a soma das variáveis em $\mathbf{x}$ correspondentes às arestas incidentes àquele vértice é menor ou igual a 1. Se essas variáveis forem 0 ou 1, então necessariamente apenas uma delas poderá ser positiva, e esta será a aresta escolhida para o emparelhamento.

No caso da segunda pergunta, a formulação será

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{N}\mathbf{x} = \mathbf{1} \\ & \mathbf{x} \geq 0 \\ & \mathbf{x} \text{ inteiro.} \end{aligned}$$

Aqui codificamos o fato de que o emparelhamento procurado é perfeito, uma vez que $\mathbf{N}\mathbf{x} = \mathbf{1}$ diz que para cada vértice, exatamente uma aresta incidente a ele será escolhida. Note que se tivéssemos escrito simplesmente $\mathbf{N}\mathbf{x} \leq \mathbf{1}$, a solução da PL seria trivialmente $\mathbf{x} = 0$.

Dual - cobertura por vértices

No problema da cobertura por vértices, estamos interessados em escolher vértices de modo que todas as arestas do grafo sejam incidentes a pelo menos um vértice da escolha. Ou seja, vamos atribuir valores de 0 ou 1 para os vértices, e para cada aresta, vamos somar os dois valores dos vértices nos quais ela incide. Essa soma precisa ser pelo menos 1. Neste problema de otimização, a pergunta natural é: qual a cobertura por vértices de menor tamanho?

$$\begin{aligned} \min \quad & \mathbf{1}^T \mathbf{y} \\ \text{sujeito a} \quad & \mathbf{N}^T \mathbf{y} \geq \mathbf{1} \\ & \mathbf{y} \geq 0 \\ & \mathbf{y} \text{ inteiro.} \end{aligned}$$

Note que, ignorando as restrições de integralidade, a formulação acima é precisamente a dual da relaxação linear do problema de emparelhamento de cardinalidade máxima. Pelo teorema fraco da dualidade, temos que:

$$\text{cardinalidade de emparelhamento máximo} \leq \text{cardinalidade de cobertura mínima.}$$

Vamos ver abaixo uma classe abrangente de grafos onde a relação acima é, na verdade, uma igualdade. O motivo será, novamente, a total unimodularidade.


Grafos bipartidos

Vamos relembrar o problema de atribuição. Considere F funcionários para os quais T tarefas são atribuídas ($|F| = |T|$). Cada funcionário i gasta c_{ij} horas para executar cada tarefa j . Relembrando a formulação, temos variáveis $x_{ij} = 1$ caso o funcionário i seja atribuído à tarefa j , 0 caso contrário. A formulação é dada por:

$$\begin{aligned}
& \min \quad \sum_{i \in F} \sum_{j \in T} c_{ij} x_{ij} \\
& \text{sujeito a} \quad \sum_{j \in T} x_{ij} = 1 \quad \forall i \in F \\
& \quad \quad \quad \sum_{i \in F} x_{ij} = 1 \quad \forall j \in T \\
& \quad \quad \quad \mathbf{x} \in \mathbb{B}.
\end{aligned}$$

Observe que podemos modelar este problema como um problema em grafos ao definirmos um grafo $G = (V, E)$ onde $V = F \cup T$ e para cada possível atribuição de funcionário à tarefa criamos uma aresta $e \in E$ conectando um vértice em F a um vértice em T . O problema de atribuição se resume a encontrar um emparelhamento perfeito de custo mínimo neste grafo (confira que a formulação acima é equivalente à formulação discutida anteriormente).

Observe que em G não há arestas conectando vértices em F e nem arestas conectando vértices em T . Diz-se que o grafo correspondente é portanto bipartido. O grafo mostrado na figura acima é um exemplo de grafo bipartido (repetido aqui por conveniência):



Estes grafos são importantes pois sua matriz de incidência possui a propriedade de total unimodularidade.

Teorema 21. *Se G é um grafo bipartido e $\mathbf{N}$ é a sua matriz de incidência vértice $\times$ aresta, então $\mathbf{N}$ é totalmente unimodular.*

Demonstração. Vamos mais uma vez provar por indução. Novamente suponha que todas as submatrizes de tamanho $r \times r$ possuem determinante 0, +1 ou -1 e considere $\mathbf{B}$ uma matriz $(r+1) \times (r+1)$. No caso base, toda matriz 1×1 possui determinante 1 ou 0. De novo, temos três possibilidades para $\mathbf{B}$:

- $\mathbf{B}$ possui uma coluna com apenas zeros: Então o determinante é zero.
- $\mathbf{B}$ possui alguma coluna com exatamente um 1: Então pela expansão de Laplace por colunas, o determinante de $\mathbf{B}$ será $\pm$ o determinante de uma matriz $r \times r$, e portanto o de $\mathbf{B}$ será 0, +1 ou -1
- $\mathbf{B}$ possui todas as colunas com dois 1's e os demais elementos iguais a zero. Como o grafo é bipartido, podemos particionar a matriz B em duas onde todos os elementos de um lado do grafo estão numa partição e todos do outro estão em outra partição, de forma que cada partição contenha apenas um valor 1 por coluna. Multiplicamos uma das partições por -1 e somamos todas as linhas de ambas as partições. O resultado é zero e com isso mostramos que as linhas são linearmente dependentes e o determinante é zero.

Por conta do teorema acima, sabemos que sempre será possível encontrar soluções ótimas para problemas de otimização de emparelhamentos em grafos bipartidos resolvendo as relaxações lineares das PIs correspondentes. Temos então o Teorema de Konig:

Teorema 22. *Em um grafo bipartido, o tamanho de um emparelhamento máximo é igual ao tamanho de uma cobertura por vértice mínima.*

Demonstração. Considere as programações lineares abaixo:


$$\begin{array}{ll|ll} \max & \mathbf{1}^T \mathbf{x} & & \min & \mathbf{1}^T \mathbf{y} \\ \text{(P)} & \text{sujeito a} & \mathbf{N}\mathbf{x} \leq \mathbf{1} & \text{(D)} & \text{sujeito a} & \mathbf{N}^T \mathbf{y} \geq \mathbf{1} \\ & & \mathbf{x} \geq 0 & & & \mathbf{y} \geq 0. \end{array}$$

A matriz N é totalmente unimodular, assim como N^T . Logo há soluções ótimas que são inteiras para ambas as programações, portanto o valor objetivo ótimo de (P) é o tamanho de um emparelhamento máximo, ao passo que o valor objetivo ótimo de (D) é o tamanho de uma cobertura por vértices mínima. Como este é um par primal-dual, estes valores são iguais. $\square$

Apesar do fato de que resolver PLs é suficiente para resolver problemas de emparelhamento em grafos bipartidos, há algoritmos famosos. O mais tradicional é o método Húngaro (década de 50), que usa uma estratégia primal-dual para encontrar um emparelhamento perfeito de custo mínimo.

Grafos gerais (não necessariamente bipartidos)

Para grafos gerais, a relaxação linear da PI possui vértices que não são inteiros. Por exemplo, considere um grafo completo com 3 vértices (um triângulo). A solução da relaxação linear da formulação que busca o emparelhamento de cardinalidade máxima e a matriz de incidência N do grafo são dadas por:



$$\begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \end{pmatrix}$$

A solução inteira é 1, mas a solução da relaxação é $\frac{3}{2}$.

É possível provar, porém, que existe uma solução ótima para a relaxação onde todas as variáveis possuem valores 0, 1 ou $\frac{1}{2}$. A partir disto é possível descrever todas as desigualdades que delimitam os pontos inteiros, mas se fizermos isto obteremos um número exponencial de desigualdades. Entretanto, há um famoso algoritmo (Algoritmo Blossom de Edmonds de 1961) que resolve o problema de achar emparelhamentos máximos em grafos quaisquer em $O(|V|^2|E|)$.

7.5.1 Cobertura por vértices em grafos quaisquer

(este é um material de leitura opcional)

Considere a relaxação linear da PI que procura a cobertura mínima por vértices

$$\begin{aligned} \min \quad & \mathbf{1}^T \mathbf{y} \\ \text{sujeito a} \quad & \mathbf{N}^T \mathbf{y} \geq \mathbf{1} \\ & \mathbf{y} \geq 0. \end{aligned}$$

Assuma que $\mathbf{y}$ seja uma solução viável, e assumamos que existe uma entrada de $\mathbf{y}$ que é diferente de 0, 1/2 ou 1. Ou seja, existe $v \in V(G)$ tal que

$$\mathbf{y}_v \notin \{0, 1/2, 1\}.$$

Seja $V^+ = \{v \in V(G) : 1/2 < \mathbf{y}_v < 1\}$, e $V^- = \{v \in V(G) : 0 < \mathbf{y}_v < 1/2\}$. Seja ϵ pequeno o suficiente, e defina dois vetores $\mathbf{z}^+$ e $\mathbf{z}^-$ tais que

$$\mathbf{z}_v^+ = \begin{cases} \mathbf{y}_v + \epsilon & \text{se } v \in V^+, \\ \mathbf{y}_v - \epsilon & \text{se } v \in V^-, \\ \mathbf{y}_v & \text{caso contrário.} \end{cases}$$

$$\mathbf{z}_v^- = \begin{cases} \mathbf{y}_v - \epsilon & \text{se } v \in V^+, \\ \mathbf{y}_v + \epsilon & \text{se } v \in V^-, \\ \mathbf{y}_v & \text{caso contrário.} \end{cases}$$

Note que

- (i) $\mathbf{z}^+$ é viável. De fato, se ϵ for pequeno o suficiente, então $\mathbf{z}^+ \geq 0$. Ademais, seja uv uma aresta. Se originalmente $\mathbf{y}_u + \mathbf{y}_v > 1$, então com ϵ pequeno o suficiente, ainda teremos $\mathbf{z}_u^+ + \mathbf{z}_v^+ > 1$. Se $\mathbf{y}_u + \mathbf{y}_v = 1$, então ou ambos eram iguais a 1/2, e neste caso nada mudou em $\mathbf{z}^+$, ou um deles era maior 1/2 e o outro menor. Mas então $\mathbf{z}^+$ somou e subtraiu ϵ , e nada mudou.
- (ii) O mesmo vale para $\mathbf{z}^-$.
- (iii) $\mathbf{y}$ é combinação convexa de $\mathbf{z}^+$ e $\mathbf{z}^-$. Portanto $\mathbf{y}$ não pode ser vértice do poliedro.

Exercício 114. Como exatamente você escreve $\mathbf{y}$ como combinação convexa de $\mathbf{z}^+$ e $\mathbf{z}^-$?

Como consequência da discussão acima, temos que as soluções ótimas de

$$\begin{aligned} \min \quad & \mathbf{1}^T \mathbf{y} \\ \text{sujeito a} \quad & \mathbf{N}^T \mathbf{y} \geq \mathbf{1} \\ & \mathbf{y} \geq 0. \end{aligned}$$

tem entradas iguais a 0, 1/2 ou 1.

Exercício 115. Mostre como é possível usar a informação acima para achar uma cobertura por vértices das arestas de tamanho no máximo duas vezes a ótima, resolvendo apenas uma programação linear.

7.5.2 Um algoritmo primal-dual para emparelhamento perfeito de menor custo

Um dos exercícios da lista 8 era o conhecido Teorema de Hall, que caracteriza grafos bipartidos que possuem emparelhamentos perfeitos:

Teorema 23 (Hall). *Em um grafo bipartido, seja A e B os conjuntos de vértices de cada lado. Suponha que $|A| = |B|$.*

Então existe um emparelhamento perfeito se, e somente se, para todo subconjunto S de vértices em A , o número total de vizinhos desses vértices em B é maior ou igual que $|S|$.

Vamos agora usar este resultado e uma estratégia primal-dual para resolvermos (exatamente) o problema de encontrar um emparelhamento perfeito de grau mínimo em um grafo bipartido. Relembre a formulação como PI deste problema (suponha que $\mathbf{c} \geq 0$).

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{N}\mathbf{x} = \mathbf{1} \\ & \mathbf{x} \geq 0 \\ & \mathbf{x} \text{ inteiro.} \end{aligned}$$

A dual da relaxação linear:

$$\begin{aligned} \max \quad & \mathbf{1}^T \mathbf{y} \\ \text{sujeito a} \quad & \mathbf{N}^T \mathbf{y} \leq \mathbf{c} \\ & \mathbf{y} \text{ livre.} \end{aligned}$$

Exercício 116. Explique com palavras o que a dual está encontrando no grafo.

Lembre-se agora que a matriz $\mathbf{N}$ é totalmente unimodular. Logo, se a PI for viável, há soluções ótimas para a sua relaxação linear que são inteiras, e portanto satisfarão as condições de folga complementares com um ótimo da dual.

Exercício 117. O que dizem as condições de folga complementares?

Exercício 118. Encontre uma solução viável para a dual que não seja muito besta.

Seja $G = (V, E)$ um grafo bipartido, e sejam A e B os subconjuntos de vértices que forma a bipartição. Assuma que $|A| = |B|$. Para um subconjunto $S \subset A$, seja $N_G(S)$ os vizinhos de S em B .

Algoritmo:


- (1) Seja α o menor valor dentre os custos $\mathbf{c}$. Faça $\mathbf{y}_v = \alpha/2$ para todo $v \in V$. Note que é viável para a dual do problema de emparelhamento.
- (2) Seja H um grafo com os mesmos vértices de G , e cujas arestas são aquelas $uv \in E(G)$ tais que $\mathbf{y}_u + \mathbf{y}_v = \mathbf{c}_{uv}$.
- (3) Se H possui um emparelhamento perfeito, PARE. Neste caso, este emparelhamento é um emparelhamento perfeito de custo mínimo no grafo G (por que?!).

- (4) Caso contrário, existe um conjunto $S \subset A$ tal que $|N_H(S)| < |S|$ (por que?!)
- (5) Se $|N_G(S)| < |S|$, PARE. Neste caso, não existe qualquer emparelhamento perfeito em G (por que?!)
- (6) Escolha ϵ maior possível que permita aumentar a variável $\mathbf{y}$ de cada vértice de S por ϵ , diminuir a variável $\mathbf{y}$ de cada vértice de $N_H(S)$ por ϵ , e deixar as demais constantes; mas garantindo que $\mathbf{y}$ permaneça viável em G . Note que $\epsilon > 0$ (por que?!).
- (7) Volte para (2).

Exercício 119. Responda os “por que”s.

Exercício 120. Qual ponto do algoritmo acima é o mais delicado (do ponto de vista de complexidade).

Exercício 121. Aplique o algoritmo ao grafo abaixo.



Exercício 122. Considere um grafo bipartido completo cujos pesos são dados na tabela abaixo. Ache um emparelhamento perfeito de custo máximo usando o algoritmo visto.

	g	h	i	j
a	2	7	1	2
b	3	4	3	2
c	6	5	5	5
d	2	6	2	3

Exercício 123. Mostre que se os pesos são positivos, então um algoritmo que encontre um emparelhamento perfeito de custo máximo pode ser usado para encontrar um emparelhamento máximo de custo máximo.

Exercício 124. Considere a PL


$$\begin{array}{ll} \max & 0 \\ \text{sujeito a} & \mathbf{N}\mathbf{x} = \mathbf{1} \\ & \mathbf{x} \geq 0 \end{array}$$

. Seja G um grafo bipartido, e S subconjunto de uma das partições. Mostre que se $|S| > |N(S)|$, então a dual da PL acima é ilimitada (e portanto a PL é inviável). Dica: olhe para o algoritmo visto.

7.6 Caminho mínimo


Nesta seção, vamos tratar o problema de encontrar o caminho de menor distância entre dois vértices em um grafo. Considerando dois vértices s (origem) e t (destino), modelaremos o problema de achar o caminho mais curto entre s e t como um problema de fluxos (não exatamente de fluxo máximo). Suponha um grafo direcionado.

Considere o grafo abaixo:



Exercício 125. Identifique no grafo a seguir três exemplos distintos de st -fluxos de valor 1 que sejam necessariamente fluxos inteiros em todos os arcos. Em geral, um st -fluxo inteiro de valor 1 determina que tipo de subgrafo?

Suponha que as arestas possuam um custo associado, e que gostaríamos de encontrar o st -fluxo de valor 1 que minimiza os custos dos arcos:



Ou seja, nesta interpretação os custos **não representam as capacidades dos arcos**. As capacidades de cada arco são iguais a 1.

Seja M a matriz de incidência do grafo dirigido acima, e $\mathbf{c}$ o vetor dos custos dos arcos, e $\mathbf{b} = (-1 \ 0 \ 0 \ \dots \ 0 \ 1)^T$. Em formato conciso matricial a formulação como PI do problema de achar um caminho entre s e t de custo mínimo é dada por:

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{M}\mathbf{x} = \mathbf{b} \\ & \mathbf{x} \geq 0. \\ & \mathbf{x} \text{ inteiro.} \end{aligned}$$

Para o grafo acima:

$$\mathbf{M} = \begin{matrix} & \begin{matrix} sa & sb & sc & ac & ad & ba & bc & be & cd & ce & ct & de & dt & et \end{matrix} \\ \begin{matrix} s \\ a \\ b \\ c \\ d \\ e \\ t \end{matrix} & \begin{bmatrix} -1 & -1 & -1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & -1 & -1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & -1 & -1 & -1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 1 & 0 & 0 & 1 & 0 & -1 & -1 & -1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & -1 & -1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 1 & 0 & 1 & 0 & -1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 1 & 1 \end{bmatrix} \end{matrix} \quad \mathbf{b} = \begin{pmatrix} -1 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 1 \end{pmatrix}$$

Observe que o fluxo que sai de s e que chega em t já é fixo em 1, e as demais restrições garantem que tudo que entra em vértice, sai. Como consequência, as variáveis $\mathbf{x}$ não conterão o valor do peso da aresta, mas um fluxo de 0 ou 1. Somente a função objetivo utiliza os pesos, para calcular o tamanho do caminho.

Exercício 126. Considere a relaxação linear do modelo acima. Uma solução ótima da PL será necessariamente inteira? Por que?

O par primal-dual será da seguinte forma:

$$\begin{array}{ll|ll} \min & \mathbf{c}^T \mathbf{x} & \max & \mathbf{b}^T \mathbf{y} \\ \text{(P)} \text{ sujeito a } & \mathbf{M}\mathbf{x} = \mathbf{b} & \text{(D)} \text{ sujeito a } & \mathbf{M}^T \mathbf{y} \leq \mathbf{c} \\ & \mathbf{x} \geq 0. & & \mathbf{y} \text{ livre} \end{array}$$

Na dual, há uma variável para cada vértice. Vamos então propor um algoritmo para encontrar uma solução viável (e ótima) para a dual. Para o exemplo acima, escrevemos a dual explicitamente:

$$\begin{array}{ll} \max & -y_s + y_t \\ \text{sujeito a} & \begin{array}{ll} -y_s + y_a \leq 4 & -y_s + y_b \leq 1 \\ -y_s + y_c \leq 8 & -y_a + y_c \leq 3 \\ -y_a + y_d \leq 5 & -y_b + y_a \leq 2 \\ -y_b + y_c \leq 5 & -y_b + y_e \leq 9 \\ -y_c + y_d \leq 7 & -y_c + y_e \leq 1 \\ -y_c + y_t \leq 6 & -y_d + y_e \leq 2 \\ -y_d + y_t \leq 5 & -y_e + y_t \leq 2 \end{array} \end{array}$$

Neste algoritmo, comece fazendo $y_s = 0$. Em seguida, siga as restrições do problema, ajustando os valores das variáveis correspondentes para que possuam o maior valor possível, sem violar nenhuma restrição. Com o exemplo acima, fazemos:

$$(a) \quad -y_s + y_a \leq 4 \quad \rightarrow \quad y_a = 4 \text{ (pois } y_s = 0)$$

Este é o máximo que conseguimos colocar em y_a .

$$(b) \quad -y_s + y_b \leq 1 \quad \rightarrow \quad y_b = 1 \text{ (pois } y_s = 0)$$

$$(c) \quad -y_s + y_c \leq 8 \quad \rightarrow \quad y_c = 8 \text{ (pois } y_s = 0)$$

$$(d) \quad -y_a + y_c \leq 3 \quad \rightarrow \quad y_c = 7 \text{ (pois } y_a = 4)$$

Note que foi necessário reduzir y_c para a restrição ficar viável. A restrição $-y_s + y_c \leq 8$ passou a ser folgada.

$$(e) \quad -y_a + y_d \leq 5 \quad \rightarrow \quad y_d = 9 \text{ (pois } y_a = 4)$$

$$(f) \quad -y_b + y_a \leq 2 \quad \rightarrow \quad y_a = 3 \text{ (pois } y_b = 1)$$

Como y_a já esteve do lado esquerdo de restrições processadas anteriormente, e teve seu valor reduzido, devemos retornar às restrições afetadas e atualizar os valores das demais variáveis:

$$(i) \quad -y_a + y_c \leq 3 \quad \rightarrow \quad y_c = 6 \text{ (pois } y_a = 3)$$

$$(ii) \quad -y_a + y_d \leq 5 \quad \rightarrow \quad y_d = 8 \text{ (pois } y_a = 3)$$

Se houvesse restrições já processadas onde y_c ou y_d estivessem do lado esquerdo, seria necessário continuar o processo recursivamente.

$$(g) \quad -y_b + y_c \leq 5 \quad \rightarrow \quad y_c = 6 \text{ (pois } y_b = 1, \text{ mantém o valor anterior)}$$

$$(h) \quad -y_b + y_e \leq 9 \quad \rightarrow \quad y_e = 10 \text{ (pois } y_b = 1)$$

$$(i) \quad -y_c + y_d \leq 7 \quad \rightarrow \quad y_d = 8$$

Mesmo que esta restrição permita que $y_d = 13$, se o fizéssemos violaríamos a restrição anterior $-y_a + y_d \leq 5$.

$$(j) \quad -y_c + y_e \leq 1 \quad \rightarrow \quad y_e = 7 \text{ (pois } y_c = 6)$$

$$(k) \quad -y_c + y_t \leq 6 \quad \rightarrow \quad y_t = 12 \text{ (pois } y_c = 6)$$

$$(l) \quad -y_d + y_e \leq 2 \quad \rightarrow \quad y_e = 7 \text{ (devido à restrição anterior)}$$

$$(m) \quad -y_d + y_t \leq 5 \quad \rightarrow \quad y_t = 12 \text{ (devido à restrição anterior)}$$

$$(n) \quad -y_e + y_t \leq 2 \quad \rightarrow \quad y_t = 9 \text{ (pois } y_e = 7)$$


Ao final do processo, temos os seguintes valores das variáveis:

$$\begin{array}{llll} y_s = 0 & y_a = 3 & y_b = 1 & y_c = 6 \\ y_d = 8 & y_e = 7 & y_t = 9 & \end{array}$$

Verificamos a viabilidade da solução e calculamos o valor da função objetivo:


$$\begin{array}{ll} \max & -y_s + y_t = 9 \\ \text{sujeito a} & \begin{array}{ll} -y_s + y_a \rightarrow 3 < 4 & -y_s + y_b \rightarrow 1 = 1 \\ -y_s + y_c \rightarrow 6 < 8 & -y_a + y_c \rightarrow 3 = 3 \\ -y_a + y_d \rightarrow 5 = 5 & -y_b + y_a \rightarrow 2 = 2 \\ -y_b + y_c \rightarrow 5 = 5 & -y_b + y_e \rightarrow 6 < 9 \\ -y_c + y_d \rightarrow 2 < 7 & -y_c + y_e \rightarrow 1 = 1 \\ -y_c + y_t \rightarrow 3 < 6 & -y_d + y_e \rightarrow -1 < 2 \\ -y_d + y_t \rightarrow 1 < 5 & -y_e + y_t \rightarrow 2 = 2 \end{array} \end{array}$$

A partir de t , voltamos pelas restrições apertadas e conseguimos deduzir dois caminhos: $s \rightarrow b \rightarrow c \rightarrow e \rightarrow t$ e $s \rightarrow b \rightarrow a \rightarrow c \rightarrow e \rightarrow t$. Ao somar as capacidades dos arcos correspondentes, observamos que o valor será 9 em ambos os casos, o mesmo valor da função objetivo da dual. Podemos ver os caminhos no gráfico abaixo:



Acabamos de resolver o problema pelo algoritmo de Dijkstra.

Exercício 127. Considere o grafo abaixo.



Encontre o caminho mínimo entre s e t através do dual da formulação apresentada nesta seção. Indique os valores das variáveis duais.

7.7 Problema do transporte

Suponha que uma companhia possua m centros de distribuição e n pontos de varejo, e deseje transportar produtos dos centros de distribuição para os pontos de varejo. Cada um dos centros de distribuição possui um estoque, cada um dos pontos de varejo possui uma demanda, e o custo de transportar produtos entre cada centro de distribuição para cada ponto de varejo são conhecidos. Como, portanto, modelar o problema de realizar essa distribuição com custo mínimo?

- Suponha que o estoque de cada centro seja dado por S_i , com $i = 1, \dots, m$.
- Suponha que a demanda de cada ponto seja dada por D_j , com $j = 1, \dots, n$.
- Suponha que o custo de transportar um produto do centro i para o ponto j seja dado por c_{ij} .
- Defina variáveis x_{ij} que determinarão quanto será transportado de i para j , onde $i = 1, \dots, m$ e $j = 1, \dots, n$.

Com as definições acima, fica fácil modelar o problema:

$$\begin{aligned}
 \min \quad & \sum_{i=1}^m \sum_{j=1}^n x_{ij} c_{ij} \\
 \text{sujeito a} \quad & \sum_{i=1}^m x_{ij} \geq D_j \quad \text{para todo } j = 1, \dots, n, \\
 & \sum_{j=1}^n x_{ij} \leq S_i \quad \text{para todo } i = 1, \dots, m, \\
 & x_{ij} \geq 0, \\
 & x_{ij} \in \mathbb{Z}.
 \end{aligned}$$

Exercício 128. Seja D a demanda total, ou seja, $D = D_1 + \dots + D_n$, e seja S o estoque total, ou seja, $S = S_1 + \dots + S_m$. Naturalmente, se a empresa consegue suprir a demanda em cada ponto, então $S \geq D$. Assuma que a empresa pode descartar o excesso de estoque, ou seja, assuma que $S = D$. Mostre que, neste caso, podemos reescrever a formulação acima trocando todas as desigualdades por igualdades sem qualquer prejuízo na modelagem do problema.

Pelo exercício acima, a formulação do problema de transporte pode ser expressa por

$$\begin{aligned}
 \min \quad & \sum_{i=1}^m \sum_{j=1}^n x_{ij} c_{ij} \\
 \text{sujeito a} \quad & \sum_{i=1}^m x_{ij} = D_j \quad \text{para todo } j = 1, \dots, n, \\
 & \sum_{j=1}^n x_{ij} = S_i \quad \text{para todo } i = 1, \dots, m, \\
 & x_{ij} \geq 0, \\
 & x_{ij} \in \mathbb{Z}.
 \end{aligned}$$

Exercício 129. Considere um grafo dirigido com dois tipos de vértices: um representa os centros, e o outro representa os pontos de venda. Conecte com arcos dirigidos todos os centros aos pontos de venda. Seja $\mathbf{N}$ a matriz de incidência deste grafo dirigido.

(i) Modele a PI acima no formato:

$$\begin{aligned}
 \min \quad & \mathbf{c}^T \mathbf{x} \\
 \text{sujeito a} \quad & \mathbf{N}\mathbf{x} = \mathbf{b} \\
 & \mathbf{x} \geq 0 \\
 & \mathbf{x} \text{ inteiro.}
 \end{aligned}$$

Ou seja, explicita o que significam $\mathbf{c}$, $\mathbf{x}$ e $\mathbf{b}$.

(ii) Mostre que as soluções da relaxação linear são inteiras se os estoques e demandas forem inteiros.

Exercício 130. Reduza o problema de transporte a um problema de fluxo entre dois vértices s e t .

7.8 Cobertura por conjuntos

Imagine agora que o problema seja o seguinte. Dada uma coleção de n elementos, e m subconjuntos $S_1, \dots, S_m$, como achar a menor quantidade possível de subconjuntos tais que cada elemento pertença a pelo menos 1? Ou seja, como achar a menor cobertura por conjuntos possível? Definimos os vetores característicos de cada conjunto - $\mathbf{a}_1, \dots, \mathbf{a}_m$. Cada vetor possui dimensão n e é formado por 0s (caso o elemento não pertença ao conjunto) e 1s (caso pertença). Agrupamos estes vetores como colunas de uma matriz $\mathbf{A}$.

A formulação do problema de minimizar o número de conjuntos suficientes para cobrir todos os elementos é dada por:

$$\begin{aligned} \min \quad & \mathbf{1}^T \mathbf{y} \\ \text{sujeito a} \quad & \mathbf{A} \mathbf{y} \geq \mathbf{1} \\ & \mathbf{y} \in \mathbb{B}^m. \end{aligned}$$

Exemplo 23. Além dos médicos de plantão no pronto socorro, um hospital precisa manter outros médicos em *stand-by*. Isto é necessário pois o hospital precisa garantir que haverá um indivíduo qualificado para executar qualquer procedimento cirúrgico que possa ser necessário. Para cada um dos diversos médicos disponíveis para *stand-by*, o salário adicional e os procedimentos que é capaz de executar são conhecidos. O objetivo é escolher médicos tais que todos os procedimentos são cobertos ao custo mínimo.

Considere a tabela abaixo:

	Med. 1	Med. 2	Med. 3	Med. 4	Med. 5	Med. 6
Proc. 1	✓			✓		
Proc. 2	✓				✓	
Proc. 3		✓	✓			
Proc. 4	✓					✓
Proc. 5		✓	✓			✓
Proc. 6		✓		✓		

Cada médico $j = 1, \dots, m$ representa um subconjunto cujos elementos são os procedimentos $i = 1, \dots, n$ que pode executar. A tabela representa a matriz $\mathbf{A}$ e, por exemplo, o vetor $\mathbf{a}_1 = (1 \ 1 \ 0 \ 1 \ 0 \ 0)^T$. Considere c_j o salário adicional do médico j caso fique em *stand-by*.

Escolhemos variáveis de decisão y_j se o médico ficará de *stand-by* ou não. Temos a seguinte formulação:

$$\begin{aligned} \min \quad & \sum_{j=1}^m c_j y_j \\ \text{sujeito a} \quad & \sum_{j=1}^m a_{ij} y_j \geq 1 \quad \forall i = 1, \dots, n \\ & \mathbf{y} \in \mathbb{B}^m. \end{aligned}$$

Observe como, se tivermos mesmo salário c_j para todos, temos exatamente a formulação vista acima: o cálculo do menor número de médicos de forma que todo procedimento seja coberto.

Este é o problema da cobertura por conjuntos, ou *set covering problem* em inglês.

Exercício 131. Formule o problema de cobertura por conjuntos como um problema de achar uma certa cobertura por vértices em um grafo bipartido. A matriz de incidência de um grafo bipartido é totalmente unimodular. Sendo assim, o problema de cobertura de conjuntos pode ser resolvido eficientemente?

O problema de cobertura por conjuntos possui uma infinidade de aplicações práticas (além da vista acima).

1. Imagine que um programador da área de segurança está escrevendo um anti-vírus. Após estudar um conjunto de 15000 vírus conhecidos, ele deseja encontrar substrings de no máximo 20 bytes consecutivos que estejam presentes nestes vírus. Ele então seleciona 5000 strings de 20 bytes. Ao tentar achar o menor número de strings tal que para cada vírus, ao menos uma delas pertença ao vírus, este programador estará precisamente resolvendo um problema de cobertura por conjuntos.
2. Posicionamento de prestadores de serviço para cobrir regiões de um mapa: delegacias ou hospitais em uma cidade, armazéns de uma companhia distribuidora, etc.

O problema de cobertura por conjunto é NP-difícil. De fato, ele é um dos problemas originais apresentados por Karp na década de 70. Abaixo veremos um algoritmo para lidar com ele. Vamos antes, porém, apresentar alguns problemas relacionados.

Exercício 132. Escreva a dual da relaxação da formulação do problema de cobertura de conjuntos. Tente achar uma interpretação combinatória quando adiciona-se restrições de integralidade.

O problema do exercício é o chamado problema de empacotamento de conjuntos (*set packing*). O que estamos observando nesses exemplos é a clássica dualidade entre empacotamento e cobertura. A palavra “empacotar” - no caso - se refere ao fato de que ao adicionarmos um ponto, o espaço disponível para adicionarmos mais pontos se reduz. E cobertura porque queremos que os subconjuntos unidos contenham todos os pontos.

Aplicações do problema de empacotamento não são tão óbvias, mas diversos problemas possuem características de empacotamento de conjuntos como parte de um modelo mais completo.

Se as restrições de cobertura são igualdades, temos o problema de partição de conjuntos - *set partitioning*. Por exemplo:

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{y} \\ \text{sujeito a} \quad & \mathbf{A}\mathbf{y} = \mathbf{1} \\ & \mathbf{y} \in \mathbb{B}. \end{aligned}$$

No problema de partição de conjuntos, cada elemento deve estar presente em exatamente um conjunto (nem mais, nem menos). Assumimos um custo associado a um conjunto. Uma de suas aplicações mais conhecidas é no problema de alocação de tripulação a voos.

Exemplo 24. O custo com pessoal é o segundo maior de uma companhia aérea, perdendo apenas para custos com combustível. O uso efetivo de tripulações pode resultar em economias enormes de custos. Há, porém, diversas regulações impostas por sindicatos e órgãos de controle (tipo a ANAC

no Brasil ou FAA nos EUA). Por exemplo, há horas de descanso mínimas, ou tripulações maiores para ciclos de voos mais longos, etc.

No final dos anos 80, a American Airlines desenvolveu para este problema um sistema de otimização que veio a se tornar extremamente lucrativo para a empresa. Na formulação que desenvolveram, uma variável binária x_i é atribuída para cada possível trajeto que uma tripulação pode legalmente voar. Por exemplo, podemos ter um trajeto onde a tripulação sai de São Paulo 7:00 e chega ao Rio de Janeiro às 8:00. Saem do Rio às 9:00 em direção a Belo Horizonte, chegando às 10:00. Saindo às 11:00, chega em São Paulo 12:00, terminando o percurso. Outro trajeto é sair de São Paulo à Londres, esperar 36 horas (obrigatórias pela legislação) e voltar a São Paulo.

Assim, cada possível trajeto representa um conjunto, e cada voo individual um elemento. Cada voo deve ser parte de exatamente um conjunto na solução final. Suponha que um determinado voo esteja nos possíveis trajetos i, j, k e l . Então teremos que:

$$x_i + x_j + x_k + x_l = 1$$


Teremos uma restrição deste tipo para cada voo. O problema de particionamento de conjuntos é então minimizar os custos dos trajetos de forma que todo voo seja coberto por exatamente um trajeto. As regulamentações às quais as tripulações estão sujeitas são implícitas pois apenas trajetos válidos são considerados.

Naturalmente, no exemplo acima podem haver um número enorme de trajetos - combinações de voos que “fazem sentido”. Isto leva a um número enorme de variáveis, cenário ideal para o desenvolvimento de um algoritmo de geração de colunas.

Diversas PIs podem ser resolvidas com algoritmos de geração de colunas, e em certos casos estes algoritmos são os melhores conhecidos para tais problemas.

7.8.1 Algoritmo primal-dual

Voltamos agora ao problema de cobertura de conjuntos. Suponha que em um dado conjunto de pontos e subconjuntos, o maior número de vezes que qualquer um dos pontos pertence a diferentes subconjuntos é f . Por exemplo, no sistema abaixo, $f = 3$.



O algoritmo que vamos apresentar agora é um algoritmo de aproximação. Significa que ele não necessariamente achará o ótimo, mas sim uma solução que está garantidamente próxima do ótimo. O fator de aproximação mede o quão bom o algoritmo é. Neste caso, o algoritmo achará uma solução que é no máximo f vezes maior que a melhor possível.

É uma estratégia simples e gulosa. Dado um conjunto de n pontos U e subconjuntos $S_1, \dots, S_m$ desses pontos:

- (i) Comece considerando uma coleção vazia destes subconjuntos.
- (ii) Ache um elemento $a \in U$ que não esteja coberto por qualquer subconjunto da coleção. Dentre os subconjuntos que contêm a , adicione aquele de menor custo, ou que contenha mais elementos não cobertos, à coleção.
- (iii) Repita o passo (ii) até não haverem mais elementos não cobertos.

Esta estratégia provavelmente adicionará mais conjuntos do que o necessário, mas quão mais? Mostraremos agora duas coisas simultaneamente: como realizar uma análise cautelosa do desempenho deste algoritmo, e como adaptá-lo para resolver a versão com pesos do problema da cobertura por conjuntos. Ambas as coisas serão feitas utilizando dualidade e folgas complementares.

Considere a formulação de programação inteira do problema com pesos

$$\begin{array}{ll} \min & \mathbf{c}^T \mathbf{y} \\ \text{sujeito a} & \mathbf{A}\mathbf{y} \geq \mathbf{1} \\ & \mathbf{y} \geq 0 \\ & \mathbf{y} \in \mathbb{Z}^m. \end{array}$$

Considere a relaxação linear da PI acima e a sua dual:

$$\begin{array}{ll|ll} \min & \mathbf{c}^T \mathbf{y} & & \max & \mathbf{1}^T \mathbf{x} \\ \text{(P) sujeito a} & \mathbf{A}\mathbf{y} \geq \mathbf{1} & & \text{(D) sujeito a} & \mathbf{A}^T \mathbf{x} \leq \mathbf{c} \\ & \mathbf{y} \geq 0 & & & \mathbf{x} \geq 0. \end{array}$$


Dada qualquer coleção $\mathcal{C}$ de subconjuntos, seja $\mathbf{y}_{\mathcal{C}}$ o vetor 0-1 de dimensão m correspondente, ou seja, 1 se o subconjunto pertence a $\mathcal{C}$, e 0 caso contrário.

Entrada: elementos de um conjunto U e subconjuntos $S_1, \dots, S_m$ destes elementos.

Saída: uma coleção $\mathcal{C}$ de subconjuntos que cobrem os elementos, e uma solução viável $\mathbf{x}$ para (D).

- (i) **Faça** $\mathbf{x} = 0$ e $\mathcal{C} = \emptyset$. Note que $\mathbf{x}$ é viável para (D), mas $\mathbf{y}_{\mathcal{C}}$ é inviável para (P).
- (ii) **Enquanto** existir $a \in U$ que não esteja coberto por qualquer subconjunto de $\mathcal{C}$, **faça**:
 - (a) **Aumente** $\mathbf{x}_a$ ao máximo de modo que $\mathbf{x}$ permaneça viável, ou seja, $\mathbf{A}^T \mathbf{x} \leq \mathbf{c}$.
 - (b) **Identifique** alguma linha de $\mathbf{A}^T \mathbf{x} \leq \mathbf{c}$ onde ocorreu a igualdade. Esta linha corresponde a um conjunto S .
 - (c) **Adicione** S a $\mathcal{C}$.
- (iii) **Retorne** $\mathcal{C}$ e $\mathbf{x}$.

Exercício 133. Aplique no problema abaixo:



O algoritmo acima é do tipo primal-dual. Ele começa com uma solução inviável da primal e uma solução viável da dual. A cada rodada ele implementa mudanças em ambas as soluções. Essas mudanças satisfazem algumas propriedades

- (i) A solução da dual permanece viável.
- (ii) A solução da primal vai se aproximando cada vez mais de ser viável, inclusive se mantendo sempre inteira.
- (iii) Condições de folgas complementares vão sendo satisfeitas. Em particular, temos dois tipos de condição:
 - (a) Se $y_i > 0$, então $\sum_{a \in S_i} x_a = c_i$.
 - (b) Se $x_a > 0$, então $\sum_{S_i \ni a} y_i = 1$.

Obviamente se todas as condições de ambos os tipos fossem satisfeitas, as soluções seriam ótimas para as PLs. Então nos contentamos ao longo da solução do algoritmo em forçar que todas as condições do primeiro tipo sejam satisfeitas, ignorando as do segundo tipo.

O teorema a seguir estabelece um limite para quão distante do ótimo o algoritmo nos leva.

Teorema 24. *Se f é a maior quantidade de subconjuntos que contém um mesmo elemento de U , então o algoritmo acima possui fator de aproximação no máximo igual a f .*

Demonstração. Seja y^Z o vetor característico dos conjuntos escolhidos no algoritmo (a solução primal final no algoritmo), ou seja, y^Z tem dimensão m , e $y_i^Z = 1$ se S_i foi escolhido, e $y_i^Z = 0$ caso contrário.

Sejam y^I o ótimo da PI da cobertura por conjuntos, y^L um ótimo da PL (P), e x o vetor obtido do algoritmo viável para a dual. Segue que

$$c^T y^Z \geq c^T y^I \geq c^T y^L \geq \mathbb{1}^T x. \quad (*)$$

Note agora que, por conta do ponto (a) acima (complementaridade de folga), cada conjunto S_i que foi adicionado a $\mathcal{C}$ satisfaz

$$\sum_{a \in S_i} x_a = c_i.$$

Ou seja,

$$c^T y^Z = \sum_{S \in \mathcal{C}} \sum_{a \in S} x_a.$$

Para cada $a \in U$, a variável $\mathbf{x}_a$ aparece no máximo f vezes na soma acima - uma para cada conjunto S que a contém. Logo

$$\mathbf{c}^T \mathbf{y}^Z \leq f \cdot \mathbf{1}^T \mathbf{x}.$$


Por outro lado, por conta de (*), temos $f \cdot \mathbf{1}^T \mathbf{x} \leq f \cdot \mathbf{c}^T \mathbf{y}^I$. Segue portanto que

$$\mathbf{c}^T \mathbf{y}^Z \leq f \cdot \mathbf{c}^T \mathbf{y}^I,$$

ou seja, a solução encontrada é no máximo f vezes o ótimo da PI. $\square$

Exercício 134. O problema de cobertura por vértices é um sub-caso do problema de cobertura por conjuntos: cada vértice determina um subconjunto de arestas do grafo - aquelas que são a ele incidentes. Usando o algoritmo acima, qual o fator de aproximação que conseguiremos ao resolver o problema de cobertura por vértices em um grafo arbitrário?

Exercício 135. Use o algoritmo acima para encontrar uma cobertura por vértices nos grafos abaixo:



7.8.2 Algoritmo guloso para o problema de cobertura de conjuntos sem pesos

Vamos agora apresentar um algoritmo guloso para resolver a versão sem pesos do cobertura por conjuntos. Ou seja, queremos resolver

$$\begin{aligned} \min \quad & \mathbf{1}^T \mathbf{y} \\ \text{sujeito a} \quad & A\mathbf{y} \geq \mathbf{1} \\ & \mathbf{y} \geq 0 \\ & \mathbf{y} \in \mathbb{Z}^m. \end{aligned}$$

Procedemos com um algoritmo guloso bem simples:

- (i) Enquanto há elementos descobertos, escolha o subconjunto que contém mais elementos descobertos.

Para cada inteiro m , seja

$$H_n = \sum_{k=1}^n \frac{1}{k}.$$

Teorema 25. O algoritmo guloso é no máximo $H(n)$ vezes o ótimo.

Exercício 136. Qual o ótimo do problema abaixo?

○	○ ○	○ ○ ○ ○	○ ○ ○ ○ ○ ○ ○ ○
○	○ ○	○ ○ ○ ○	○ ○ ○ ○ ○ ○ ○ ○

E o que o algoritmo guloso encontra?

Algumas observações:

- (i) Para problemas em que cada elemento aparece em no máximo poucos conjuntos, o algoritmo primal-dual acima é muito bom.
- (ii) Em particular, é provado que uma aproximação melhor do que $\approx 1,36$ para o problema da cobertura por vértices implicaria que $P = NP$.
- (iii) Algumas pessoas acreditam haver motivos razoavelmente fortes para acreditar que 2 é o melhor possível, a não ser, novamente, que $P = NP$.
- (iv) Em termos de n , é provado que a aproximação em $O(\log(n))$ do algoritmo guloso é essencialmente a melhor possível, a não ser que $P = NP$.

7.9 Empacotamento, partição e coberturas — uma revisão

Dados um conjunto $P = \{1, \dots, n\}$ de pontos e uma família $F = \{F_1, \dots, F_m\}$ de subconjuntos de P , um subconjunto S de P é chamado de...

- (i) *empacotador* se S intersecta cada F_i no máximo uma vez;
- (ii) *particionador* se S intersecta cada F_i exatamente uma vez;
- (iii) *cobertor* se S intersecta cada F_i pelo menos uma vez.

Se N é a matriz de incidência do sistema, ou seja, uma matriz 0-1 em que cada linha é indexada por P e cada coluna por F , e uma entrada é 1 se e somente se o ponto da linha pertence ao subconjunto da coluna, então as coleções de todos os conjuntos...

- (i) *empacotadores* é determinada por $S^E = \{\mathbf{x} \in \{0, 1\}^n : \mathbf{N}\mathbf{x} \leq \mathbf{1}\}$;
- (ii) *particionadores* é determinada por $S^P = \{\mathbf{x} \in \{0, 1\}^n : \mathbf{N}\mathbf{x} = \mathbf{1}\}$;
- (iii) *cobertores* é determinada por $S^C = \{\mathbf{x} \in \{0, 1\}^n : \mathbf{N}\mathbf{x} \geq \mathbf{1}\}$.

Em geral, a não ser que $\mathbf{N}$ possua uma estrutura especial, otimizar em conjuntos das formas acima são problemas difíceis.

Exemplo 25. Atenção! Note que originalmente quando falamos de coberturas, estávamos cobrindo pontos escolhendo subconjuntos. Aqui é ao contrário, ou ao menos assim parece à primeira vista: estamos cobrindo os subconjuntos escolhendo pontos (ou fazendo hitting). Os dois problemas são contudo equivalentes: basta inverter os nomes do que é ponto e o que é subconjunto, mantendo a mesma regra de incidência...

Considere um grafo G , vértices V e arestas E .

Exercício 137.

- (a) Um emparelhamento em um grafo é uma estrutura de qual tipo acima? Quem são os pontos e os subconjuntos?
- (b) Uma cobertura por vértices de arestas em um grafo é uma estrutura de qual tipo acima? Quem são os pontos e os subconjuntos?
- (c) Uma coloração em um grafo é uma estrutura de qual tipo acima? Quem são os pontos e os subconjuntos?
- (d) Um conjunto independente em um grafo é um problema de qual tipo acima? Quem são os pontos e os subconjuntos?
- (e) Um clique em um grafo é um problema de qual tipo acima? Quem são os pontos e os subconjuntos?

Como visto acima, um conjunto S de vértices é chamado de *independente* se nenhum par dentro do conjunto são vizinhos. Ou seja, se N é a matriz de incidência vértice $\times$ aresta do grafo, então a coleção de todos os conjuntos independentes é determinada por

$$\text{stab}(G) = \{\mathbf{x} \in \{0, 1\}^n : \mathbf{N}\mathbf{x} \leq \mathbf{1}\}$$

O problema de achar um conjunto independente de tamanho máximo é geral formulado como $\max\{\mathbf{1}^T \mathbf{x} : \mathbf{x} \in \text{stab}(G)\}$, ou seja

$$\begin{aligned} \max \quad & \mathbf{1}^T \mathbf{x} \\ \text{sujeito a} \quad & \mathbf{N}\mathbf{x} \leq \mathbf{1} \\ & \mathbf{x} \geq 0 \quad \mathbf{x} \text{ inteiro.} \end{aligned}$$

Vamos discutir abaixo como trocar as desigualdades $\mathbf{N}\mathbf{x} \leq \mathbf{1}$ por outras mais restritas, que tornem a relaxação linear mais próxima da programação inteira.

Seja K um clique (conjunto de vértices em que todos se ligam a todos), e seja $\mathbf{v}_K$ seu vetor de incidência (vetor de n entradas 0/1 que indica quais vértices pertencem a K). Note que se $\mathbf{x}$ é um conjunto independente, então necessariamente teremos

$$\mathbf{v}_K^T \mathbf{x} \leq 1.$$

Ou seja, todo conjunto independente possui no máximo um vértice de cada clique.


Exercício 138. Considere o grafo que possui três vértices a , b e c , e todos são conectados. Mostre que há soluções $0 \leq \mathbf{x} \leq \mathbf{1}$ fracionárias que satisfazem $\mathbf{N}\mathbf{x} \leq \mathbf{1}$ mas que não satisfazem $\mathbf{x}_a + \mathbf{x}_b + \mathbf{x}_c \leq 1$. Conclua que a formulação das desigualdades lineares para o problema de achar conjuntos independentes em um grafo é mais restrita se usarmos uma desigualdade para cada clique, ao invés de uma desigualdade para cada aresta.

Exercício 139.

- Demonstre que o número cromático de um grafo é sempre maior ou igual do que o tamanho do maior clique do grafo.
- Mostre que mesmo o ótimo da relaxação linear da formulação do problema de coloração como no Exercício 137 ainda é maior ou igual que o tamanho do maior clique de um grafo.

7.10 Colorações

Vamos agora olhar para mais um problema em grafos. Suponha que desejamos colorir os vértices de um grafo de modo que vértices vizinhos recebam cores diferentes.



O primeiro é uma boa coloração com 4 cores, o segundo é uma má coloração, e o terceiro é uma boa coloração com 3 cores. Parece fácil, até que tornamos isso em um problema de otimização:

- Qual o mínimo número de cores necessário para colorir os vértices de um grafo de modo que vizinhos não recebam a mesma cor?

Exercício 140. Quais são os grafos que podem ser coloridos com duas cores?

Exercício 141. Dê exemplo de um grafo com 6 vértices que precise exatamente de 6 cores para ser colorido.

Por exemplo, imagine que os vértices representem eventos. Cada aresta representa eventos que não podem ocorrer simultaneamente, por exemplo, porque dependem dos mesmos participantes. O problema da coloração portanto é a modelagem combinatória do problema de encontrar o menor número possível de horários para sediar todos os eventos!

Note que o problema de coloração é, em certo sentido, um problema de cobertura. Especificamente: desejamos cobrir os vértices do grafo com escolhas de conjuntos de vértices que sejam independentes! Se $\mathcal{I}$ é o conjunto de todos os conjuntos independentes do grafo, então rapidamente chegamos à clássica formulação do problema de cobertura:

$$\begin{aligned} \min \quad & \sum_{I \in \mathcal{I}} x_I \\ \text{sujeito a} \quad & \sum_{v \in I} x_I \geq 1 \quad \text{para todo } v \in V(G) \\ & x_I \geq 0 \\ & x_I \in \mathbb{Z}. \end{aligned}$$

Exercício 142. Fora ser uma formulação com restrições de integralidade, qual um grave problema da restrição acima?

De fato, achar o ótimo da relaxação linear da PI acima é um problema NP-difícil!!

Exercício 143. Como formular o problema de achar uma coloração de um grafo com um número mínimo de cores como uma PI com um número “pequeno” de restrições?

- Dica: suponha que você tem n vértices. Claramente n cores seriam suficientes. Podemos fazer com menos? Bem, use dois tipos de variáveis: variáveis y_k , com $k = 1, \dots, n$, que indicariam se a cor k seria utilizada. E use variáveis x_{ik} que indicariam se a cor k será ou não aplicada no vértice i .
- Escreva a função objetivo, as restrições específicas (são 3 tipos), as restrições de não negatividade e as de integralidade.

Exercício 144. Qual o ótimo da relaxação linear da PI acima?

Exercício 145. Se um grafo G tem grau máximo Δ , ache um algoritmo guloso que colore G com no máximo $\Delta + 1$ cores.

Exercício 146. Ache um grafo de grau máximo 6 mas que só precisa de duas cores para ser colorido.

7.11 Localização de instalações (facility location)

Lembre-se do exercício na parte de modelagem sobre a decisão de onde abrir quartéis do corpo de bombeiros para atender cidades. Alternativamente, pense por exemplo em uma empresa de logística deseja abrir alguns armazéns para atender a alguns pontos de venda no varejo. Ambos os problemas podem ser modelados formalmente da seguinte forma:

- (i) Um grafo G , com vértices V e arestas E .
- (ii) Um subconjunto dos vértices chamados de instalações, digamos, $F \subseteq V$.
- (iii) Um subconjunto dos vértices chamados de clientes, digamos, $C \subseteq V$. Podemos assumir que $V = F \cup C$.
- (iv) Uma função custo em cada uma das arestas (por exemplo, o custo de transporte ou a distância), ou seja, $c \in \mathbb{R}^E$. No caso especial que discutimos aqui, esta função será uma métrica, ou seja, o custo de conectar i a j não é maior do que o de conectar i a j_1 , j_1 a i_2 e i_2 a j .
- (v) Um custo para abrir cada uma das instalações, ou seja, $f \in \mathbb{R}^F$.

Após a escolha de um subconjunto possível das instalações, cada cliente será pareado com uma instalação aberta, e o custo do pareamento será o custo do caminho mínimo no grafo entre eles. O objetivo é minimizar o custo total de abertura das instalações, e o custo total dos pareamentos. Ou seja, temos variáveis y_i para cada $i \in F$ que indicarão a abertura ou não da instalação, e variáveis x_{ij} que indicarão se o cliente j é pareado com a instalação i . Daí

$$\begin{aligned}
 & \min \quad \sum_{i \in F} f_i y_i + \sum_{i \in F, j \in C} c_{ij} x_{ij} \\
 & \text{sujeito a} \quad \sum_{i \in F} x_{ij} \geq 1, \quad \forall j \in C, \\
 & \quad x_{ij} \leq y_i, \quad \forall i \in F, j \in C, \\
 & \quad \mathbf{x} \text{ e } \mathbf{y} \geq 0, \text{ e inteiros.}
 \end{aligned}$$

Começamos escrevendo a programação dual da relaxação linear. Teremos variáveis para cada restrição do tipo $\sum x_{ij} \geq 1$, digamos u_j , e outras para cada $x_{ij} \leq y_i$, digamos v_{ij} . Daí

$$\begin{aligned}
 & \max \quad \sum_{j \in C} u_j \\
 & \text{sujeito a} \quad u_j - v_{ij} \leq c_{ij}, \quad \forall i \in F, j \in C, \\
 & \quad \sum_{j \in C} v_{ij} \leq f_i, \quad \forall i \in F, \\
 & \quad \mathbf{u} \text{ e } \mathbf{v} \geq 0.
 \end{aligned}$$

É possível interpretar a dual como um problema em que cada cliente está pagando para a abertura das instalações. Assim, uma possível interpretação para as variáveis duais é a seguinte:

- (i) Cada u_j é quanto cada cliente está disposto a pagar no total.

(ii) Cada v_{ij} é quanto está disposto a pagar para abrir a instalação i .

De fato, se $(\mathbf{x}, \mathbf{y})$ e $(\mathbf{u}, \mathbf{v})$ formam um par primal-dual viável e ótimo, as condições de folga complementar implicam que

- (i) Se $y_i > 0$, então $\sum v_{ij} = f_i$, ou seja, instalações abertas foram pagadas inteiramente pelos clientes.
- (ii) Se $v_{ij} > 0$, então $y_i = x_{ij}$, ou seja, se o cliente j para por i , então ele a utiliza.
- (iii) Se $x_{ij} > 0$, então $u_j = c_{ij} + v_{ij}$, ou seja, se o cliente j usa i , então o total que ele gasta é exatamente o custo do pareamento mais a sua fração na abertura de i .

7.11.1 Algoritmo primal-dual

Descrevemos agora um método primal-dual para o problema de localização de instalações.

- (1) Começamos com $\mathbf{y} = 0$, e $\mathbf{u} = 0$.
- (2) Aumentamos os valores de u_j para cada cliente que não esteja ainda conectado, de modo constante e uniforme.
- (3) Inicialmente, todas as instalações ainda estão fechadas.
- (4) Quando u_j ultrapassa c_{ij} para algum i , começamos a aumentar os valores de v_{ij} , de modo constante e uniforme. Lembre-se que precisamos de $u_j \leq c_{ij} + v_{ij}$.
- (5) Quando $\sum_j v_{ij} = f_i$, abrimos a instalação i , e conectamos todos os clientes j desconectados e com $u_j \geq c_{ij}$ para a instalação i . Seja $i(j)$ a instalação que o cliente j conectou.
- (6) Voltamos a aumentar cada u_j . Dessa vez, assim que u_j atingir algum c_{ij} de um i já aberto, conectamos j a i , e paramos de aumentar u_j , e definimos esta i como $i(j)$. Caso contrário, voltamos para (4).

Ao término, cada cliente estará “conectado” a uma única instalação. Entretanto, mais instalações do que o necessário foram abertas, e clientes estão contribuindo para instalações as quais não conectaram. Vamos descrever agora um esquema que fechará algumas delas.

- (a) Crie um grafo cujos vértices são as instalações abertas, e duas delas vizinhas se e somente se há um cliente que contribui para abrir ambas.
- (b) Ache um conjunto independente maximal neste grafo, digamos, T , começando na ordem em que as instalações foram temporariamente abertas. Este será o conjunto de instalações oficialmente abertas.
- (c) Para cada cliente j , se $i(j)$ está em T , declare então j oficialmente pareado com $i(j)$. Se $i(j) \notin T$, seja i' a instalação de T que conflita com $i(j)$ (e que, portanto, foi aberta antes que $i(j)$). Declare j oficialmente pareado a i' .

Temos alguns fatos:

- (i) Nenhum cliente j contribui para duas instalações oficialmente abertas.

(ii) Se $i \in T$, e $S \subseteq C$ são os clientes j tais que $i(j) = i$, então

$$f_i + \sum_{j \in S} c_{ij} = \sum_{j \in S} u_j.$$

De fato, temos, por construção da primeira parte do algoritmo, que

$$f_i = \sum_{j \in S} v_{ij}.$$

Como $v_{ij} = u_j - c_{ij}$, a equação é verdadeira.

(iii) Se j está oficialmente conectado a $i \in T$, mas $i(j) \neq i$, então

$$c_{ij} \leq 3u_j.$$

Para ver este, note que precisa haver j' que contribui originalmente para i e para $i(j)$, logo $u_{j'} \geq c_{ij'}$ e $\geq c_{i(j)j'}$. Também sabemos que $u_j \geq c_{i(j)j}$. Como i abriu antes que $i(j)$ (e portanto ficou em $T...$), e como os u s aumentam juntos e de modo uniforme, teremos que $u_{j'} \leq u_j$. Logo

$$c_{ij} \leq c_{i(j)j} + c_{i(j)j'} + c_{ij'} \leq u_j + u_{j'} + u_{j'} \leq 3u_j.$$

Segue portanto que o custo total da solução inteira é no, máximo, $3 \sum_{j \in C} u_j$, que é no máximo 3 vezes o ótimo da dual da relaxação linear. Portanto a solução inteira encontrada é, no pior caso possível, 3 vezes o ótimo inteiro do problema!

7.12 Árvores geradoras

Considere o problema de encontrar uma árvore geradora máxima (AGM): dado um grafo $G = (V, E)$ com pesos nas arestas $c_e \in \mathbb{R}$, trata-se do subconjunto S de arestas que conecta todos os vértices em V , sem ciclos, e que maximiza $\sum_{e \in S} c_e$. Uma árvore que conecta todos os vértices em G possui $|V| - 1$ arestas. Note que os problemas de árvore geradora máxima e mínima são equivalentes.

Vamos modelar o problema de achar uma árvore geradora máxima como uma PI. Teremos variáveis x_e para cada aresta, onde $x_e \in \{0, 1\}$ indica se a aresta e pertence ou não à árvore. Com um vetor $\mathbf{c}$ de custos, teremos...

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & ??? \\ & \mathbf{x} \in \mathbb{B}. \end{aligned}$$

Nosso primeiro objetivo é escrever as restrições que faltam, aquelas que garantem que o conjunto de arestas escolhidas formam uma árvore. Seja $S \subset V$ um subconjunto de vértices, e $E(S)$ as arestas que estão dentro de S .

Exercício 147. Exatamente, quantas variáveis x_e serão iguais a 1? E, para um S arbitrário, qual será o número de arestas que a árvore possuirá em $E(S)$?

A partir da resposta do exercício, vamos então encontrar as restrições que faltam. Para todo $S \subset V$, $S \neq V$, $\sum_{e \in E[S]} x_e \leq |S| - 1$. Temos também que $\sum_{e \in E(G)} x_e = |V| - 1$. Note que essas restrições já contem $x_e \leq 1$!

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \sum_{e \in E(G)} x_e = |V| - 1 \\ & \sum_{e \in E(S)} x_e \leq |S| - 1 \quad \forall S \subset V, S \neq V \\ & \mathbf{x} \geq 0, \mathbf{x} \text{ inteiro.} \end{aligned}$$

Assumindo, sem perda de generalidade, que $\mathbf{c} \geq 0$, podemos alterar a formulação para:

$$\begin{aligned} \max \quad & \mathbf{c}^T \mathbf{x} \\ \text{sujeito a} \quad & \sum_{e \in E(S)} x_e \leq |S| - 1 \quad \forall S \subseteq V \\ & \mathbf{x} \geq 0, \mathbf{x} \text{ inteiro.} \end{aligned}$$


O número de restrições é da ordem de $O(2^n)$, semelhante ao que vimos na formulação do caixeiro viajante. Porém, sabemos que o problema da AGM é fácil de resolver, conhecemos pelo menos dois algoritmos eficientes: Kruskal e Prim. A razão para isso está fora do escopo deste curso - para as pessoas interessadas em saber mais, busquem informações sobre matróides e algoritmos gulosos.

Vamos analisar a dual da relaxação linear do modelo acima. O par primal-dual é dado por:

$$\begin{array}{ll} \max & \sum_{e \in E} c_e x_e \\ \text{(P) sujeito a} & \sum_{e \in E(S)} x_e \leq |S| - 1 \quad \forall S \subseteq V \\ & \mathbf{x} \geq 0. \end{array} \quad \left| \quad \begin{array}{ll} \min & \sum_{S \subseteq V} (|S| - 1) y_S \\ \text{(D) sujeito a} & \sum_{e \in E[S]} y_S \geq c_e \quad \forall e \in E \\ & \mathbf{y} \geq 0. \end{array} \right.$$

No dual, possuímos uma variável y_S para cada subconjunto $S \subseteq V$. Para uma aresta e , sua restrição correspondente diz que “a soma das variáveis relativas a todos os subconjuntos que contém e deve ser maior ou igual a c_e ”.

Exemplo 26. Considere o exemplo abaixo:



Pelo algoritmo de Kruskal, as arestas escolhidas são, na ordem: (c, d) , (a, b) , (a, c) , (d, e) , com valor objetivo 18. Vamos agora encontrar uma solução viável para a dual com o mesmo valor.

Podemos ver o algoritmo de Kruskal como primal-dual. No caso, para cada aresta incluída na solução há um novo subconjunto S conectado. Fazemos o valor y_S igual ao peso da aresta incluída que criou aquele componente conectado menos o peso da primeira aresta posterior incluída que conecta S a outro componente, criando um componente maior que contém S . Exemplo:

- 1a aresta: (c, d) , fazemos $y_{c,d} = 10$.
- 2a aresta: (a, b) , fazemos $y_{a,b} = 5$.
- 3a aresta: (a, c) . Esta aresta conectou os componentes anteriores, portanto fazemos $y_{c,d} = y_{c,d} - 2 = 8$, $y_{a,b} = y_{a,b} - 2 = 3$ e fazemos $y_{a,b,c,d} = 2$.
- 4a aresta: (d, e) . Esta aresta conectou e a (a, b, c, d) , portanto fazemos $y_{a,b,c,d} = y_{a,b,c,d} - 1 = 1$ e $y_{a,b,c,d,e} = 1$.

Custo da solução: $1 \cdot y_{c,d} + 1 \cdot y_{a,b} + 3 \cdot y_{a,b,c,d} + 4 \cdot y_{a,b,c,d,e} = 8 + 3 + 3 + 4 = 18$. O custo da solução primal também é 18, o que mostra a otimalidade do algoritmo.